REDES NEURAIS CONVOLUCIONAIS

KAMILA AMÉLIA SOUSA GOMES

EXPEDIENTE

Coordenador(a) de Conteúdo
Greisse Moser Badalotti
Projeto Gráfico e Capa
Arthur Cantareli Silva
Editoração
Isabella Santos Magalhães
Design Educacional
Amanda Peçanha dos Santos
Revisão Textual
Ariane Andrade Fabreti
Ilustração
Bruno Cesar Pardinho Figueiredo
Geison Ferreira da Silva
Wellington Vainer
Fotos
Shutterstock e Envato

FICHA CATALOGRÁFICA

N964 Núcleo de Educação a Distância. **GOMES,** Kamila Amélia Sousa.

Redes Neurais Convolucionais / Kamila Amélia Sousa Gomes. - Florianópolis, SC: Arqué, 2025.

208 p.

ISBN digital 978-65-5466-674-9

1. Redes 2. Neurais 3. Convolucionais 4. EaD. I. Título.

CDD - 006.32

Bibliotecária: Leila Regina do Nascimento - CRB- 9/1722.

Ficha catalográfica elaborada de acordo com os dados fornecidos pelo(a) autor(a).

Ano de impressão:

Impresso por:

AVALIE ESTE LIVRO!

CRIAR MOMENTOS DE APRENDIZAGENS INESQUECÍVEIS É O NOSSO OBJETIVO E POR ISSO, **GOSTARIAMOS DE SABER COMO FOI SUA EXPERIENCIA.**

Conta para nós! Leva ***menos de 2 minutos****. Vamos lá?!*

RECURSOS DE IMERSÃO

PENSANDO JUNTOS

Este item corresponde a uma proposta de reflexão que pode ser apresentada por meio de uma frase, um trecho breve ou uma pergunta.

APROFUNDANDO

Utilizado para temas, assuntos ou conceitos avançados, levando ao aprofundamento do que está sendo trabalhado naquele momento do texto.

PRODUTOS AUDIOVISUAIS

Os elementos abaixo possuem recursos audiovisuais. **Recursos de mídia disponíveis no conteúdo digital do ambiente virtual de aprendizagem.**

PLAY NO CONHECIMENTO

Professores especialistas e convidados, ampliando as discussões sobre os temas por meio de fantásticos podcasts.

EU INDICO

Utilizado para agregar um conteúdo externo.

EM FOCO

Utilizado para aprofundar o conhecimento em conteúdos relevantes utilizando uma linguagem audiovisual.

ZOOM NO CONHECIMENTO

Utilizado para desmistificar pontos que possam gerar confusão sobre o tema. Após o texto trazer a explicação, essa interlocução pode trazer pontos adicionais que contribuam para que o estudante não fique com dúvidas sobre o tema.

INDICAÇÃO DE FILME

Uma dose extra de conhecimento é sempre bem-vinda. Aqui você terá indicações de filmes que se conectam com o tema do conteúdo.

INDICAÇÃO DE LIVRO

Uma dose extra de conhecimento é sempre bem-vinda. Aqui você terá indicações de livros que agregarão muito na sua vida profissional.

CAMINHOS DE APRENDIZAGEM

7

UNIDADE 1

INTRODUÇÃO ÀS REDES NEURAIS PROFUNDAS 8

31

UNIDADE 2

FUNDAMENTOS DAS REDES NEURAIS CONVOLUCIONAIS 32

NORMALIZAÇÃO E REGULARIZAÇÃO EM CNN 54

77

UNIDADE 3

LENET E AS PRIMEIRAS CNN 78

ALEXNET E A REVOLUÇÃO NO RECONHECIMENTO DE IMAGEM 98

119

UNIDADE 4

VGG E A ESTRUTURA DE CAMADAS PROFUNDAS 120

RESNET E CONEXÕES RESIDUAIS. 138

161

UNIDADE 5

DENSENET E CONECTIVIDADE OTIMIZADA 162

APLICAÇÕES E FUTURO DAS REDES CONVOLUCIONAIS 184

Unicesumar

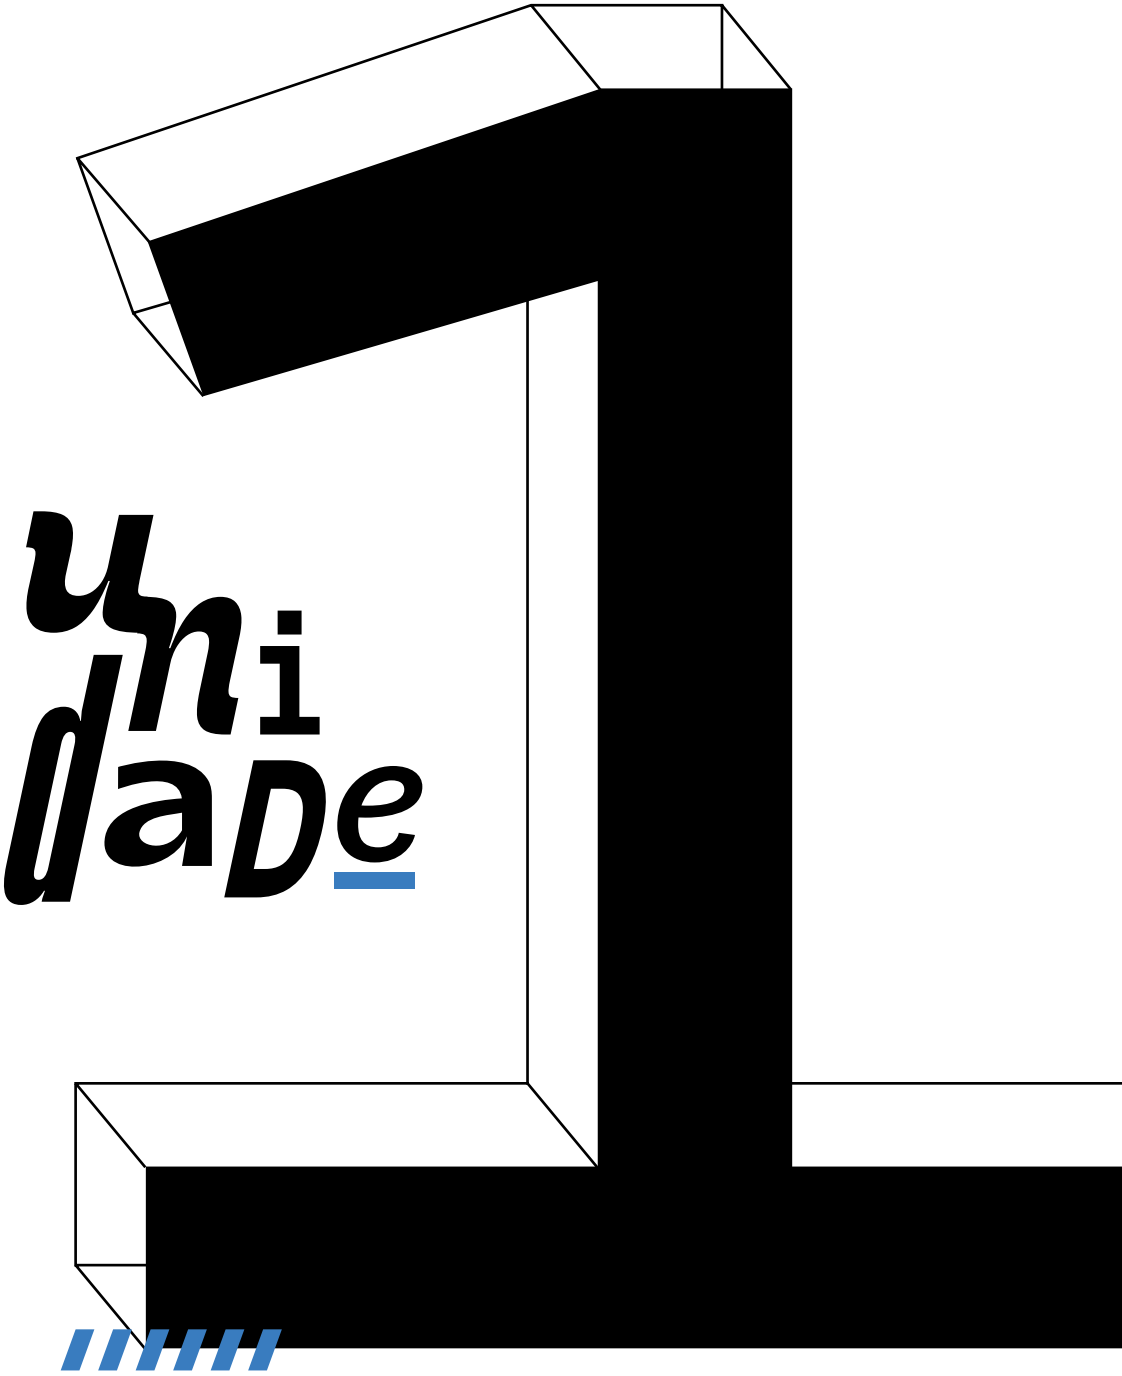

TEMA DE APRENDIZAGEM 1

INTRODUÇÃO ÀS REDES NEURAIS PROFUNDAS

MINHAS METAS

- Compreender o conceito básico de redes neurais tradicionais.
- Analisar o modelo Perceptron e suas limitações.
- Explorar a estrutura do Perceptron Multicamadas (MLP).
- Diferenciar redes neurais rasas e profundas.
- Identificar os fatores que impulsionaram o avanço do deep learning
- Estudar a estrutura das Redes Neurais Convolucionais (CNN).
- Analisar as arquiteturas modernas de CNN e suas contribuições.

INICIE SUA JORNADA

Vivemos em uma era na qual a inteligência artificial (IA) já faz parte do nosso cotidiano, impactando desde recomendações de filmes até diagnósticos médicos. À medida que a tecnologia avança, o conhecimento sobre redes neurais profundas torna-se um passo essencial para qualquer estudante que deseja se destacar no mercado. Mais do que entender algoritmos, é necessário refletir sobre o impacto e as possibilidades deles, tornando-os protagonistas dessa transformação digital.

As **redes neurais profundas** imitam a maneira como o cérebro humano processa informações, permitindo que máquinas reconheçam padrões, interpretem dados e até mesmo tomem decisões. Elas são aplicadas em áreas de segurança digital, automação industrial e criação de conteúdo. Compreender o funcionamento dessas redes é essencial para quem busca atuar em setores que demandam inovação e análise de dados avançada.

Para entender melhor o impacto dessas redes, podemos explorar exemplos práticos, como o treinamento de um modelo de reconhecimento facial ou a criação de um sistema que identifica sentimentos em textos. A **experiência prática** permite visualizar como camadas de neurônios artificiais extraem características e refinam previsões, tornando a IA cada vez mais precisa.

No diagnóstico médico, por exemplo, redes neurais profundas estão sendo usadas para detectar doenças em estágios iniciais com precisão comparável ou até superior à de médicos experientes. Em **serviços de *streaming***, tais quais Netflix ou Spotify, a IA é fundamental no momento de recomendar filmes, músicas ou séries com base nos gostos e no comportamento do usuário. Isso tudo acontece porque as redes neurais podem aprender a partir de enormes quantidades de dados e encontrar padrões difíceis para os humanos perceberem.

Diante desse cenário, surge **um questionamento**: como podemos nos preparar para esse novo contexto profissional? O aprendizado de redes neurais profundas não se limita a um campo específico, mas se torna essencial a engenheiros, cientistas de dados, profissionais de TI e até mesmo às áreas de marketing e saúde. A IA não veio para substituir profissionais, mas sim ampliar as possibilidades, exigindo tanto adaptação quanto novas habilidades.

PLAY NO CONHECIMENTO

Já imaginou como as redes neurais transformam setores como saúde e judiciário? Nesse podcast, exploraremos o impacto dessa na análise de processos judiciais. Também abordaremos um exemplo real que analisou mais de 660 mil processos, melhorando a eficiência nas decisões. Não perca! **Recursos de mídia disponíveis no conteúdo digital do ambiente virtual de aprendizagem.**

VAMOS RECORDAR?

Quando bebê, a primeira vez que você reconheceu sua mãe ou alguém importante foi um aprendizado marcante. No início, via apenas borrões, mas seu cérebro foi criando conexões e ajustando a percepção. Ao observar mais vezes esses rostos, "treinou-se" para identificar traços, como a forma da face e a voz. Esse processo é parecido com o das redes neurais profundas. Assim como o cérebro forma conexões para identificar rostos, as redes neurais "aprendem" com exemplos. Começam sem saber nada, mas, ao receber dados, ajustam suas conexões, ou pesos, até reconhecer padrões em imagens, ou sons. Com o tempo, assim como você distinguiu sua mãe de outras pessoas, as redes neurais tornam-se cada vez mais precisas. Esse aprendizado mostra que o reconhecimento humano se assemelha ao funcionamento das redes neurais profundas, projetadas para aprender por experiências repetidas.

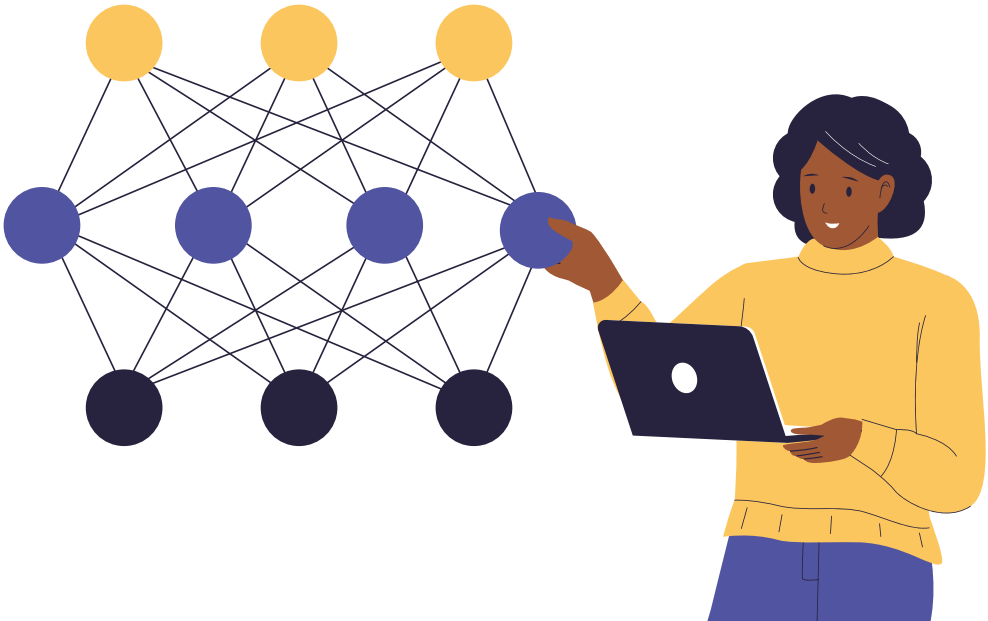

DESENVOLVA SEU POTENCIAL

DA NEUROCIÊNCIA À INTELIGÊNCIA COMPUTACIONAL

O estudo sobre redes neurais artificiais teve origem na tentativa de compreender e replicar o funcionamento do cérebro humano. Inspirados pelos avanços da neurociência, pesquisadores começaram a desenvolver modelos matemáticos que simulassem como os neurônios biológicos processam informações. No século XIX, o neurologista Ramón y Cajal foi um dos pioneiros, ao descrever detalhadamente a estrutura dos neurônios e suas conexões, a demonstrando que o sistema nervoso é composto por células individuais interligadas transmissoras de sinais elétricos (Kovács, 2006).

As redes neurais artificiais surgiram como uma tentativa de imitar o processo de aprendizado do cérebro humano, uma das estruturas mais complexas e eficientes da natureza. Inspiradas no funcionamento dos neurônios biológicos, essas redes são projetadas para aprender a partir de dados e realizar tarefas como reconhecimento de padrões, previsão e tomada de decisões. A ideia central é a seguinte: assim como os neurônios humanos conectam-se e comunicam-se para processar informações, as redes neurais artificiais conectam "neurônios" artificiais que trabalham juntos para identificar padrões e aprender com exemplos (Binoti; Binoti; Leite, 2014).

A importância das redes neurais está no poder delas de resolver problemas complexos, por exemplo, reconhecimento de imagens, voz e texto, além de otimizar processos em áreas como saúde, finanças e automação. Essas redes conseguem lidar com grandes volumes de dados, mas também aprender de forma autônoma, adaptando-se e melhorando com o tempo, assim como o cérebro humano, que se refina por meio da experiência. Esse poder de aprendizado automático e adaptativo é o que torna as redes neurais uma das tecnologias mais importantes da IA, com enorme potencial para transformar diferentes setores da sociedade.

O funcionamento do cérebro pode ser entendido como um processo dividido em três etapas principais: percepção, processamento e resposta, tal qual mostrado na Figura 1. O cérebro recebe informações dos receptores sensoriais, que convertem estímulos do corpo e do ambiente em impulsos elétricos. Esses impulsos são então processados pela rede neural, a qual envia comandos aos atuadores, gerando respostas físicas ou comportamentais discerníveis. Embora os neurônios biológicos sejam mais lentos do que os circuitos eletrônicos, o cérebro compensa essa limitação por meio da sua vasta rede de conexões, tornando-se extremamente eficiente em termos de consumo energético (Haykin, 2001).

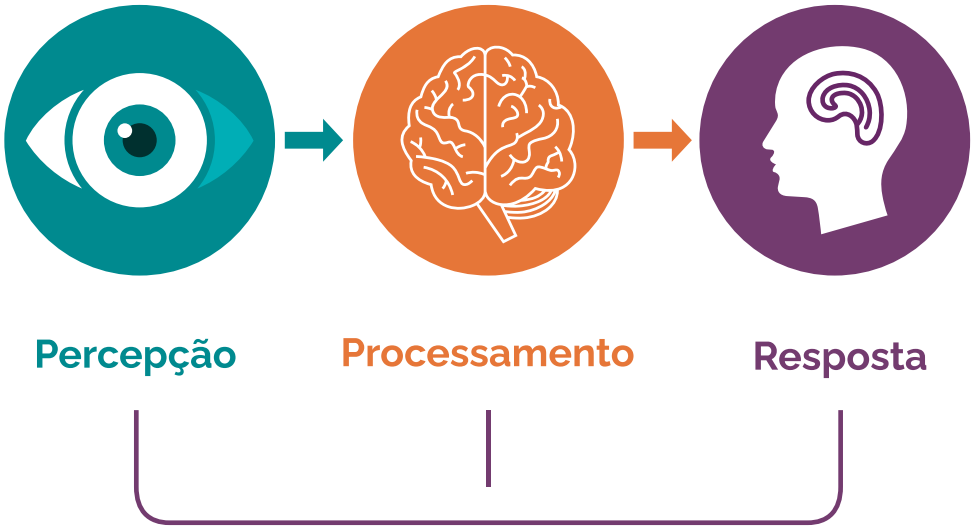

Figura 1 – Diagrama das etapas de percepção, processamento e resposta / Fonte: a autora.

Descrição da Imagem: diagrama das etapas de percepção, processamento e resposta. A imagem apresenta três círculos alinhados horizontalmente, cada um com um ícone dentro e uma palavra abaixo. À esquerda, há um círculo verde-água com o desenho de um olho estilizado no centro; abaixo dele está a palavra "Percepção", também em verde-água. Ao centro, um círculo laranja exibe o contorno de um cérebro em branco, abaixo está a palavra "Processamento" em laranja. À direita, um círculo roxo mostra o perfil de uma cabeça humana de lado, em branco, com um desenho de ouvido e parte do cérebro indicados em roxo, abaixo está a palavra "Resposta", na mesma cor. Setas unem os círculos da esquerda para a direita, e há uma linha roxa, em forma de colchete, conectando os três círculos na parte inferior. O fundo é branco e não há outros elementos na imagem. O olho representa a percepção, o cérebro simboliza o processamento, e o rosto humano indica a resposta. Setas conectam as etapas, ilustrando o fluxo sequencial do processo cognitivo. Fim da descrição.

Com base nesse modelo biológico, os cientistas passaram a construir Redes Neurais Artificiais (RNA) formadas por unidades de processamento simples, chamadas de neurônios artificiais. Essas redes recebem os dados iniciais, em seguida, processam as informações, por fim, fornecem a resposta ou decisão final. As conexões entre os neurônios de diferentes camadas possuem pesos associados, ajustados durante o processo de treinamento. Esse avanço resultou na criação de sistemas computacionais capazes de resolver problemas complexos em áreas como reconhecimento de imagens, linguagem natural e IA (Binoti; Binoti; Leite, 2014).

Rede neural Perceptron

O Perceptron foi um dos primeiros modelos formais de RNA, introduzido por Frank Rosenblatt, em 1958. Inspirado na estrutura dos neurônios biológicos, ele representa um modelo matemático simples que realiza a classificação de padrões com base em um conjunto de entradas ponderadas e uma função de ativação (Binoti; Binoti; Leite, 2014). O modelo básico do Perceptron Simples consiste em:

ENTRADAS (X_1, X_2, ..., X_n)

São os valores numéricos que representam os dados processados pelo modelo.

PESOS (W_1, W_2, ..., W_n)

Cada entrada possui um peso associado que determina a influência dela na decisão final.

SOMA PONDERADA

A combinação linear das entradas e seus pesos, somada a um viés (bias).

FUNÇÃO DE ATIVAÇÃO

Responsável por produzir a saída final do modelo, geralmente, pela aplicação de um limiar, para decidir entre duas classes (exemplo: ativação binária 0 ou 1).

Matematicamente, o Perceptron pode ser representado pela seguinte equação:

$$y = f\sum_{i=1}^{n} w_i x_i + b$$

Onde b é o viés, f é a função de ativação.

Para melhor entendimento, observe a Figura 2, que traz uma representação mais detalhada de como uma MLP funciona: é possível visualizar as camadas de entrada, as camadas ocultas e a camada de saída, mostrando como as informações são processadas em diferentes estágios. Cada camada realiza uma operação específica, permitindo que a rede aprenda representações mais complexas e faça previsões mais precisas. Essa estrutura é essencial para resolver problemas mais avançados e não lineares, como reconhecimento de imagens ou análise de dados.

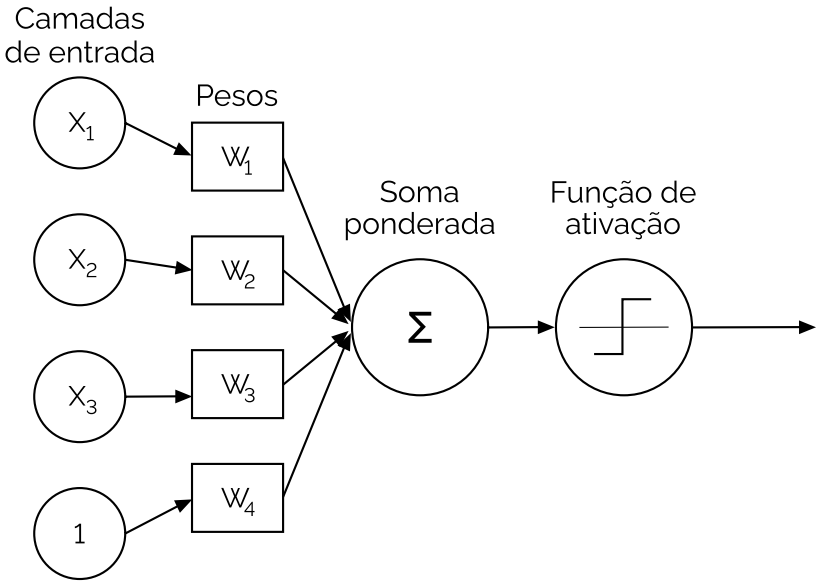

Figura 2 – Arquitetura do Perceptron / Fonte: adaptada de Rosebrock (2018).

Descrição da Imagem: representação de um modelo de RNA em forma de sequência. Primeiro, os dados iniciais são introduzidos no sistema como entradas. Em seguida, uma seta conecta-os aos pesos, ou seja, valores numéricos que determinam a importância de cada entrada. Outra seta liga os pesos ao somatório, onde as entradas são multiplicadas por seus respectivos pesos e somadas. Depois, uma nova seta direciona o resultado para a função de ativação, que processa os dados e decide se a informação deve seguir adiante. Por fim, outra seta conduz o resultado até a saída, que representa o valor final gerado pela rede. Fim da descrição.

Embora o Perceptron Simples tenha sido uma inovação importante na época, sua principal limitação está na incapacidade de resolver problemas não linearmente separáveis, como o problema do XOR. Este foi demonstrado formalmente por Marvin Minsky e Seymour Papert, em 1969, e resultou em um período de estagnação na pesquisa sobre redes neurais (Zhang *et al.*, 2023).

Evolução do Perceptron para redes neurais multicamadas

Para superar as limitações do Perceptron Simples, foi criada a **Rede Neural Multicamadas (MLP – Multi-Layer Perceptron)**. A principal diferença é que, ao contrário do Perceptron Simples, que possui uma estrutura mais simples, a MLP tem **"camadas ocultas"** entre a entrada e a saída. Essas camadas permitem a rede entender e resolver problemas mais complexos, por exemplo, identificar padrões não óbvios à primeira vista. Em outras palavras, a introdução dessas camadas ajuda a rede a **"pensar"** de forma mais avançada, tornando-a capaz de aprender tarefas complicadas, como reconhecer rostos em fotos ou entender o que uma pessoa está dizendo (Zhang *et al.*, 2023).

Um exemplo clássico de aplicação de uma MLP é reconhecer imagens, como em sistemas de reconhecimento facial. Nesses sistemas, as primeiras camadas podem identificar formas simples — linhas e bordas — enquanto as camadas mais profundas identificam características mais complexas, como rostos ou objetos específicos. Esse processo de aprendizagem em múltiplas camadas torna as MLP extremamente poderosas em tarefas de classificação, previsão e análise de grandes volumes de dados.

Segundo Faria (2018), uma MLP típica é composta por três tipos de camadas:

CAMADA DE ENTRADA
Recebe os dados de entrada e os repassa para a próxima camada.
CAMADAS OCULTAS
Extraem características e a transformação dos dados por meio de combinações lineares e funções de ativação não lineares. Quanto mais camadas ocultas uma rede possuir, mais complexas serão as relações que ela pode aprender.
CAMADA DE SAÍDA
Produz a resposta final do modelo, que pode ser uma classificação ou um valor numérico (no caso de regressão).

A inovação que possibilitou o avanço das MLP foi o algoritmo de retropropagação do erro (*backpropagation*), descrito formalmente por Rumelhart, Hinton e Williams (1986). Esse algoritmo permite o ajuste eficiente dos pesos da rede neural, utilizando a regra da cadeia do cálculo diferencial para propagar os erros das camadas finais às iniciais, minimizando a função de perda (Faria, 2018).

O treinamento de uma rede MLP pode ser descrito em três etapas principais (Faria, 2018):

- **Propagação para frente (*forward propagation*)**: o modelo recebe os dados de entrada, realiza as operações de soma ponderada e aplica funções de ativação em cada camada, gerando uma previsão.
- **Cálculo do erro (*loss function*)**: a diferença entre a previsão da rede e o valor real é calculada usando uma função de erro (exemplo: erro quadrático médio para regressão ou entropia cruzada para classificação).
- **Propagação para trás (*backpropagation*)**: o erro calculado é transmitido de volta pela rede, ajustando os pesos dos neurônios por meio de algoritmos de otimização, como o gradiente descendente (*gradient descent*).

A Figura 3 apresenta um exemplo de um MLP, que inclui uma camada oculta entre a de entrada e a de saída, possibilitando a rede aprender padrões e relações mais complexas nos dados. Nesse caso, a camada de entrada recebe os dados brutos, enquanto a oculta processa essas informações para detectar características mais abstratas. Por fim, a camada de saída gera o resultado, como uma classificação ou previsão. A introdução da camada oculta torna a rede mais poderosa e eficiente às diferentes tarefas.

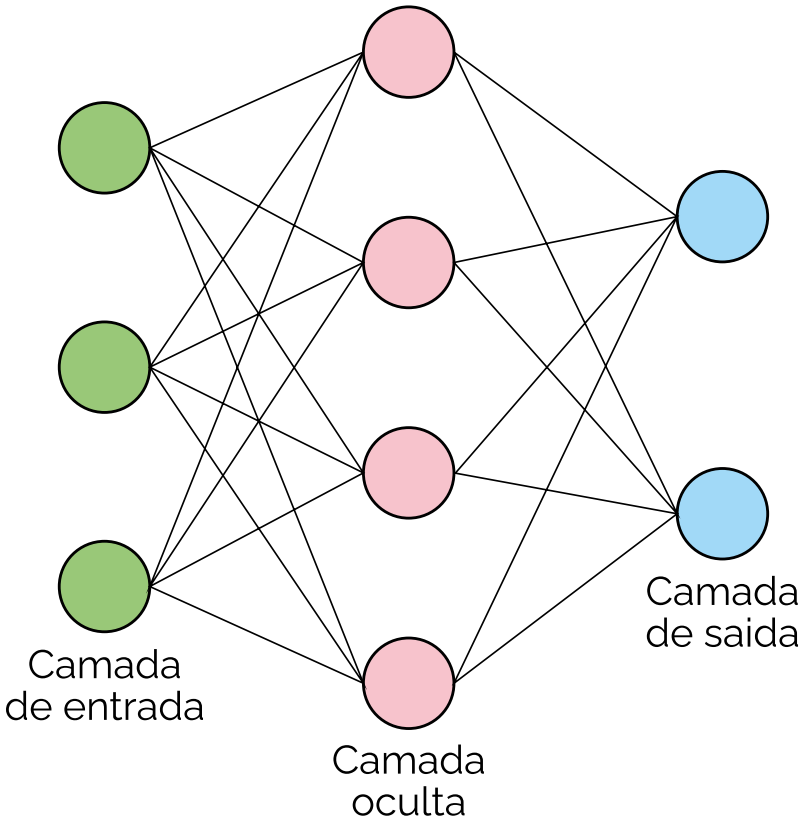

Figura 3 – Representação de uma MLP / Fonte: adaptada de Zhang *et al.* (2023).

Descrição da Imagem: representação de um modelo de MLP. As entradas são os dados iniciais que alimentam a rede, de cada entrada partem setas conectando-se a todas as unidades da primeira camada oculta. Em seguida, cada neurônio dessa camada também tem setas que se ligam a todos os neurônios da próxima camada oculta, caso haja mais de uma. Esse padrão de conexão continua até a camada de saída, onde o resultado é gerado. Esse modelo demonstra como as informações percorrem a rede, passando por várias camadas de processamento antes de produzir a saída. Fim da descrição.

APRENDIZADO PROFUNDO (*DEEP LEARNING*)

As RNA evoluíram significativamente desde os primeiros modelos simples até as avançadas redes neurais profundas, conhecidas como *deep learning*. A principal diferença entre as redes rasas e as profundas está na complexidade estrutural bem como na capacidade de aprender características mais abstratas e complexas.

A principal diferença entre as redes rasas e as profundas está na complexidade estrutural

As **redes neurais rasas** são compostas por poucas camadas, geralmente, uma oculta entre a camada de entrada e a de saída. O modelo mais básico e amplamente utilizado nesse contexto é o Perceptron Multicamadas (MLP). Essas redes são eficazes para tarefas simples e problemas com dados bem definidos, mas apresentam algumas limitações significativas. Como têm poucas camadas, sua capacidade de aprender padrões complexos em grandes volumes de dados é restrita, o que as torna menos eficazes em tarefas de reconhecimento de imagens, processamento de linguagem natural e outros problemas que envolvem dados não lineares ou altamente complexos. Além disso, elas exigem uma intervenção humana significativa para a extração de características importantes dos dados antes do treinamento (LeCun; Bengio; Hinton, 2015).

Em contraste, as **redes neurais profundas** são compostas por múltiplas camadas ocultas, permitindo um aprendizado hierárquico de características. Cada camada sucessiva consegue extrair padrões mais complexos a partir dos padrões extraídos nas camadas anteriores. Isso possibilita que as redes profundas realizem uma extração automática de características, dispensando a intervenção humana para o pré-processamento dos dados.

Essas redes são altamente eficazes para tarefas complexas, como reconhecimento de voz, imagens e até para diagnósticos médicos, cuja capacidade de aprender e identificar padrões mais profundos é fundamental (LeCun; Bengio; Hinton, 2015).

INDICAÇÃO DE FILME

Transcendence

Filme de ficção científica sobre um cientista que transfere sua consciência para um supercomputador, criando uma IA que rapidamente evolui e adquire habilidades autônomas.
Refletindo sobre a história: a relação com redes neurais artificiais e *deep learning* é evidente nesse filme, pois a IA aprende, processa informações e adapta-se em um nível profundo, utilizando redes neurais complexas para melhorar a própria inteligência.

O avanço das redes neurais profundas deve-se a três principais fatores. Primeiro, o aumento da capacidade computacional, por meio do uso dos GPU e TPU, possibilitou o treinamento eficiente de redes com várias camadas. Em segundo lugar, a disponibilidade de grandes volumes de dados (*big data*) forneceu a quantidade necessária de informações para que essas redes profundas pudessem aprender de maneira eficaz. E, por último, o desenvolvimento de algoritmos de otimização mais eficientes, como o Adam e o Batch Normalization, facilitou o processo de treinamento e aumentou a estabilidade das redes (Kelleher, 2019).

Esses avanços fazem o *deep learning* destacar-se em diversas áreas, como: reconhecimento de imagens, no qual as Redes Neurais Convolucionais (CNN) desempenham um papel crucial; processamento de linguagem natural (NLP), que alimenta assistentes virtuais e tradutores automáticos; até mesmo carros autônomos, em que as redes aprendem a processar informações sensoriais em tempo real para tomar decisões.

Em comparação com redes rasas, as redes profundas oferecem uma capacidade de generalização muito maior, permitindo que o modelo lide com novos dados eficientemente, sem a necessidade de novos ajustes manuais (Kelleher, 2019).

REDES NEURAIS CONVOLUCIONAIS (CNN)

As Redes Neurais Convolucionais (CNN) são um tipo especializado de rede neural profunda amplamente utilizada em tarefas de processamento e análise de imagens. O conceito fundamental que distingue as CNN das redes neurais tradicionais é a operação de convolução: ela permite à rede aprender automaticamente características espaciais, por exemplo, bordas, formas e texturas, de maneira tão hierárquica quanto eficiente (Ćosović; Janković, 2020).

Conforme esses mesmos autores, a arquitetura de uma CNN é composta, principalmente, por três tipos de camadas: convolucionais, de *pooling* e totalmente conectadas.

CAMADAS CONVOLUCIONAIS

São o coração das CNN e têm a função de aplicar filtros ou *kernels* sobre a imagem de entrada. Cada filtro é um pequeno conjunto de pesos que realiza uma operação de convolução, ou seja, passa pela imagem ou por uma ativação das camadas anteriores, gerando um mapa de características (*feature map*). Essa operação ajuda a rede a aprender padrões locais, como bordas, texturas e formas em diferentes resoluções. À medida que a rede se aprofunda, as camadas convolucionais sucessivas podem aprender padrões mais complexos, por exemplo, partes de objetos ou objetos inteiros.

CAMADAS DE *POOLING*

Após as camadas convolucionais, as camadas de *pooling* — geralmente, *max pooling* — são usadas para reduzir a resolução espacial da imagem, mantendo as características mais importantes. O *pooling* auxilia a reduzir a complexidade computacional e a sobrecarga de memória, além de promover a invariância a pequenas variações, como deslocamentos ou rotações da imagem. Essa redução de dimensionalidade também evita o *overfitting* e melhora a capacidade de generalização do modelo.

CAMADAS TOTALMENTE CONECTADAS (*FULLY CONNECTED*)

Após a extração das características nas camadas convolucionais e de *pooling*, a CNN utiliza camadas totalmente conectadas para realizar a classificação final ou a previsão. Nessa etapa, os recursos extraídos são "mapeados" em um espaço de alta dimensionalidade e usados na previsão da classe ou do rótulo da imagem, por exemplo. Essas camadas são semelhantes a uma rede neural tradicional e, normalmente, contêm funções de ativação, como ReLU ou Softmax, para garantir que as saídas da rede sejam apropriadas.

O processo de aprendizado nas CNN é alimentado pelo *backpropagation*, um algoritmo de aprendizado de máquina que ajusta os pesos de uma RNA para otimizar os parâmetros e minimizar a função de perda.

Durante o treinamento, as CNN podem aprender uma variedade de representações hierárquicas da imagem, começando de representações simples e locais até representações mais complexas, de alto nível, que correspondem a características mais abstratas.

INDICAÇÃO DE LIVRO

***Deep learning* with Python**

O livro de François Chollet oferece uma conexão profunda com o conteúdo de CNN. Ele explora como as CNN podem ser aplicadas em tarefas de reconhecimento de imagens e visão computacional, abordando a arquitetura, o funcionamento e a implementação prática delas. Por meio do uso da biblioteca Keras, o autor proporciona exemplos tanto práticos quanto teóricos, para o leitor entender como treinar e otimizar CNN, aplicando técnicas avançadas de *deep learning* em Python.

O campo das CNN evoluiu significativamente com o desenvolvimento de novas arquiteturas que impulsionam inovações e aprimoram soluções inteligentes. Modelos como LeNet-5, AlexNet, VGGNet, GoogLeNet (Inception), ResNet e DenseNet, desempenharam um papel fundamental nesse progresso, ao aprimorarem a precisão, a eficiência computacional e a capacidade de generalização dos modelos (Ćosović; Janković, 2020).

LENET-5

Desenvolvida por Yann LeCun, foi uma das primeiras redes neurais convolucionais e pioneira no reconhecimento de dígitos escritos à mão, sendo amplamente utilizada para leitura automatizada de cheques e documentos.

ALEXNET

Revolucionou o campo ao vencer o ImageNet Challenge em 2012, demonstrando que redes profundas, combinadas com grandes volumes de dados e processamento via GPU, poderiam superar abordagens tradicionais de visão computacional.

VGGNET

Propôs uma arquitetura mais profunda e estruturada, utilizando múltiplas camadas convolucionais de pequeno tamanho (3x3), o que possibilitou melhor extração de características e um desempenho mais robusto em tarefas de classificação de imagens.

GOOGLENET (INCEPTION)

Introduziu os módulos Inception, os quais combinam diferentes tamanhos de filtros convolucionais em paralelo, tornando a rede mais eficiente ao reduzir o número de parâmetros sem comprometer a precisão.

RESNET
Trouxe o conceito de conexões residuais, as quais treinam redes extremamente profundas sem os problemas de degradação do gradiente, tornando-as mais eficientes e precisas.
DENSENET
Aprimorou a propagação de informações ao conectar todas as camadas entre si, assim, promoveu melhor fluxo de dados, reduziu redundâncias e melhorou a eficiência do treinamento.

Essas CNN revolucionaram diversos setores ao proporcionar avanços significativos na interpretação de dados visuais (Zhang *et al.*, 2023):

- **Carros autônomos**: as CNN são essenciais para sistemas de visão computacional em veículos autônomos, permitindo a detecção de pedestres, sinais de trânsito, outros veículos e obstáculos em tempo real, com intuito de garantir mais segurança e precisão na navegação.
- **Medicina**: no diagnóstico por imagens, redes como ResNet e DenseNet são amplamente utilizadas para identificar padrões em exames, por exemplo, radiografias, tomografias e ressonâncias magnéticas, a fim de auxiliar médicos na detecção precoce de doenças, principalmente câncer, pneumonia e neuropatias.
- **Processamento de v**ídeos: no setor de segurança, as CNN são empregadas para reconhecimento facial, detecção de comportamentos suspeitos e monitoramento inteligente. No entretenimento, essas redes aprimoram a qualidade de vídeos, geram efeitos visuais avançados e aplicações em realidade aumentada e virtual.

Além disso, essas redes são aplicadas em outras áreas, como a indústria, onde melhoram a inspeção automatizada de produtos, e no comércio, onde otimizam a personalização de recomendações e a experiência do usuário. Com o contínuo desenvolvimento de novas arquiteturas, a IA baseada em CNN continuará a expandir seu impacto na sociedade (Zhang *et al.*, 2023).

EM FOCO

Confira a aula referente a este tema. **Recursos de mídia disponíveis no conteúdo digital do ambiente virtual de aprendizagem.**

NOVOS DESAFIOS

A teoria das redes neurais fornece os alicerces matemáticos e algoritmos necessários para entender o funcionamento dessas redes, envolvendo conceitos como modelos matemáticos de neurônios artificiais, redes multicamadas, algoritmos de treinamento, além de fundamentos como funções de ativação, regularização e otimização. Esses conceitos são essenciais para construir modelos robustos, eficazes.

É na prática, entretanto, que esses conceitos ganham vida e relevância. No mercado de trabalho, as redes neurais, especialmente as redes neurais profundas (*deep learning*), têm ampla aplicação em várias áreas: visão computacional (reconhecimento de imagens, diagnóstico médico por imagens), processamento de linguagem natural (*chatbots*, tradução automática, análise de sentimentos), carros autônomos, finanças (previsão de mercados e detecção de fraudes) e saúde (diagnóstico de doenças, personalização de tratamentos). Profissionais da área precisam, então, dominar ferramentas e tecnologias essenciais para implementar essas redes de maneira eficiente e escalável.

Embora o conhecimento teórico seja fundamental no entendimento dos desafios dos modelos, o **verdadeiro diferencial** está na capacidade de aplicar esses conceitos para otimizar processos e gerar resultados concretos. O mercado de trabalho valoriza profissionais com bom equilíbrio entre o domínio teórico e a habilidade de implementar soluções práticas. A experiência com grandes volumes de dados (*big data*), *deep learning* em larga escala e computação em nuvem são áreas que têm se tornado cada vez mais demandadas.

As perspectivas aos profissionais que dominam as redes neurais são extremamente promissoras. A IA e o *machine learning* estão se tornando cada vez mais presentes em indústrias de automação, saúde, segurança, finanças, *e-commerce* e criatividade. Especialistas em *deep learning* bem como engenheiros de dados têm muitas oportunidades, pois o mercado está em constante evolução, exigindo profissionais atualizados com as novas arquiteturas e algoritmos.

Além disso, esses profissionais precisam conseguir aplicar o conhecimento adquirido em soluções práticas que atendam aos problemas reais do mundo. As redes neurais devem continuar a desempenhar um papel fundamental em inovações futuras, dentre eles, sistemas autônomos e personalização em massa, tornando-se uma parte crucial do avanço tecnológico.

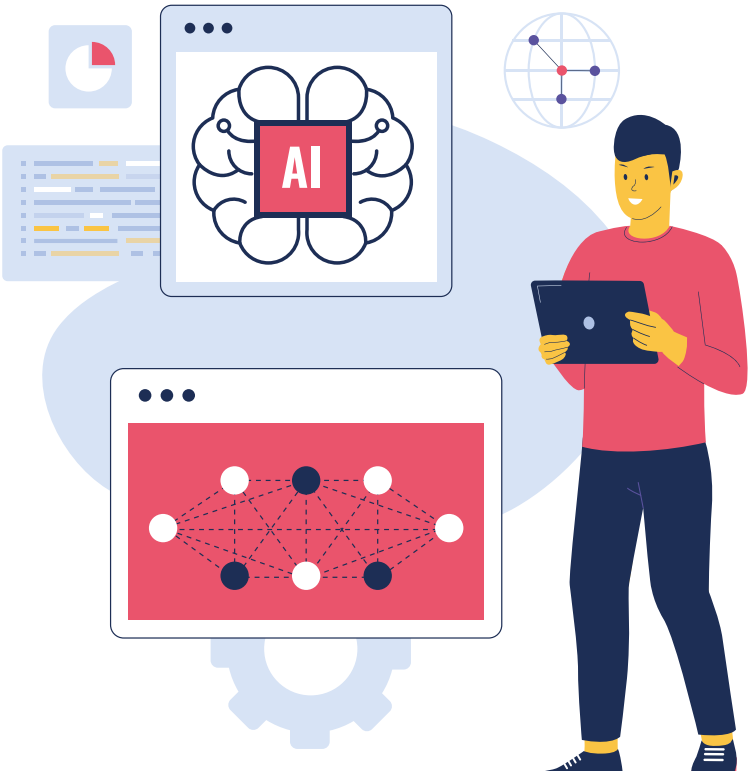

VAMOS PRATICAR

1. As redes neurais têm transformado o mundo e aberto novas possibilidades para o futuro da IA, tornando-se cada vez mais poderosas à medida que a tecnologia avança. Hoje, elas estão presentes em várias áreas do nosso dia a dia, muitas vezes, de forma invisível, mas desempenhando um papel crucial na melhoria de nossas vidas. Essenciais para diversas inovações tecnológicas, as redes neurais possuem a capacidade de aprender e se adaptar continuamente, a fim de possibilitar soluções cada vez mais eficientes e avançadas (Binoti; Binoti; Leite, 2014).

   Qual das alternativas, a seguir, descreve o conceito e o funcionamento das redes neurais?

   a) Modelos matemáticos que utilizam regras fixas e programadas manualmente para tomar decisões, sem a necessidade de aprendizado a partir de dados.
   b) Funcionam como sistemas que imitam a estrutura dos neurônios biológicos, conseguindo aprender padrões e tomar decisões com base em exemplos previamente apresentados.
   c) Algoritmos que funcionam exclusivamente com bases de dados estruturadas, sem a possibilidade de aplicação em reconhecimento de imagens ou processamento de linguagem natural.
   d) Operam apenas por meio de regras estatísticas fixas, sem a capacidade de adaptação a novos padrões de dados.
   e) Baseiam-se em redes elétricas físicas que simulam diretamente o cérebro humano, sem envolver modelos computacionais matemáticos.

2. Com o avanço da tecnologia, as redes neurais profundas evoluíram graças a três fatores principais: o aumento da capacidade de processamento com o uso dos GPU e TPU, a disponibilidade de grandes volumes de dados que permitem um aprendizado mais eficaz e o aprimoramento de algoritmos de otimização, como o Adam e o Batch Normalization, os quais facilitaram o treinamento e melhoraram a estabilidade das redes. Esses elementos, combinados, possibilitaram **às** redes neurais profundas atingir um novo nível de eficiência e precisão (Kelleher, 2019).

   Com base no texto sobre os fatores que impulsionaram o avanço das redes neurais profundas, veja as afirmativas, a seguir:

   I - O desenvolvimento de algoritmos de otimização mais eficientes, como o Adam e o Batch Normalization, foi crucial para a estabilidade e eficiência do treinamento das redes neurais profundas.
   II - A falta de grandes volumes de dados foi um obstáculo para o desenvolvimento das redes neurais profundas, dificultando o aprendizado delas.

III - O aumento da capacidade computacional, com o uso dos GPU e TPU, foi um dos fatores que possibilitaram o treinamento eficiente de redes neurais profundas.

IV - As redes neurais profundas não exigem grandes volumes de dados para serem treinadas eficazmente, pois podem aprender com conjuntos pequenos de informações.

É correto o que se afirma em:

a) I, apenas.
b) II e IV, apenas.
c) III e IV, apenas.
d) I, II e III, apenas.
e) I, II, III e IV.

3. Imagine uma rede neural como um sistema tentando aprender algo, por exemplo, identificar objetos ou prever resultados. Quando recebe dados, ela faz uma previsão, mas pode cometer erros. Para melhorar, ela usa o algoritmo de retropropagação do erro. Antes de corrigir os erros, a rede passa pela propagação para frente, na qual faz os cálculos iniciais e gera uma previsão. Quando o erro é identificado, a retropropagação entra em ação, ajustando os parâmetros internos da rede com intuito de melhorar suas respostas futuras. Esse processo contínuo ajuda a rede a aprender de forma gradual e mais eficiente (Faria, 2018).

Com base nas informações apresentadas, avalie as asserções, a seguir, e a relação proposta entre elas:

I - O algoritmo de retropropagação permite que a rede neural ajuste seus pesos de maneira eficiente, propagando o erro das camadas finais para as iniciais.

PORQUE

II - A propagação para frente é a etapa onde o erro calculado é retropropagado às camadas iniciais para otimizar os pesos, o que ajuda a minimizar a função de perda.

A respeito dessas asserções, assinale a alternativa correta:

a) As asserções I e II são verdadeiras, e a II é uma justificativa correta da I.
b) As asserções I e II são verdadeiras, mas a II não é uma justificativa correta da I.
c) A asserção I é uma proposição verdadeira, e a II é uma proposição falsa.
d) A asserção I é uma proposição falsa, e a II é uma proposição verdadeira.
e) As asserções I e II são falsas.

REFERÊNCIAS

BINOTI, D. H. B.; BINOTI, M. L. M. da S.; LEITE, H. G. Configuração de redes neurais artificiais para estimação do volume de árvores. **Ciência da Madeira**, v. 5, p. 58-67, 2014.

ĆOSOVIĆ, M.; JANKOVIĆ, R. Classificação CNN das imagens do patrimônio cultural. *In:* SIMPÓSIO INTERNACIONAL INFOTEH-JAHORINA, 19., 2020, Sarajevo. **Anais** [...]. Sarajevo: IEEE, 2020. p. 1-6.

FARIA, E. L. de. **Redes neurais convolucionais e máquinas de aprendizado extremo aplicadas ao mercado financeiro brasileiro**. 2018. Tese (Doutorado em Engenharia Civil) – Instituto Alberto Luiz Coimbra, Programa de Pós-Graduação em Engenharia Civil, Universidade Federal do Rio de Janeiro, Rio de Janeiro, 2018.

HAYKIN, S. **Redes neurais**: princípios e prática. Porto Alegre: Bookman, 2001.

KELLEHER, J. D. **Deep learning**. Cambridge: MIT Press, 2019.

KOVÁCS, Z. L. **Redes neurais artificiais**: fundamentos e aplicações. 4. ed. São Paulo: LF Editorial, 2006.

LECUN, Y.; BENGIO, Y.; HINTON, G. *Deep learning*. **Nature**, London, v. 521, n. 7553, p. 436-444, 2015.

ROSEBROCK, A. **Deep learning for computer vision with Python**. 2nd. ed. *[S. l.]:* PyImageSearch, 2018.

RUMELHART, D. E.; HINTON, G. E.; WILLIAMS, R. J. Learning representations by backpropagating errors. **Nature**, London, v. 323, n. 6088, p. 533-538, 1986.

ZHANG, J. *et al.* Applications of artificial neural networks in microorganism image analysis: a comprehensive review from conventional multilayer Perceptron to popular convolutional neural network and potential visual transformer. **Artificial Intelligence Review**, v. 56, n. 2, p. 1013-1070, 2023.

CONFIRA SUAS RESPOSTAS

1. Alternativa B.

   As RNA imitam a estrutura dos neurônios biológicos, mediante aprendizado de padrões a partir de exemplos e ajuste de seus pesos internos para melhorar a precisão das previsões.
   A alternativa A está incorreta, pois afirma que as RNA seguem regras fixas programadas manualmente, quando, na verdade, elas aprendem de forma autônoma.
   A alternativa C está incorreta, pois limita o uso das RNA a bases de dados estruturadas, ignorando aplicações como reconhecimento de imagens e processamento de linguagem natural;
   A alternativa D está incorreta, pois sugere que as RNA operam apenas com regras estatísticas fixas, desconsiderando sua capacidade de adaptação.
   A alternativa E está incorreta, pois se equivoca ao dizer que as RNA são redes elétricas físicas as quais simulam diretamente o cérebro, quando, na realidade, **são modelos computacionais baseados na neurociência**.

2. Alternativa D.

   A afirmativa I está correta, pois o desenvolvimento de algoritmos de otimização mais eficientes, como o Adam e o Batch Normalization, foi crucial para a estabilidade e eficiência do treinamento das redes neurais profundas.
   A afirmativa II está correta, pois a falta de grandes volumes de dados seria, de fato, um obstáculo para o desenvolvimento das redes neurais profundas, dificultando seu aprendizado.
   A afirmativa III está correta, pois o aumento da capacidade computacional, com o uso dos GPU e TPU, foi um dos fatores que possibilitaram o treinamento eficiente de redes neurais profundas.
   A afirmativa IV está incorreta, pois as redes neurais profundas exigem grandes volumes de dados para aprender eficazmente, afinal, quanto mais dados, melhor o aprendizado da rede.

3. Alternativa C.

   A asserção I é verdadeira, pois o algoritmo de retropropagação realmente permite que a rede neural ajuste os pesos eficientemente, propagando o erro das camadas finais para as iniciais.
   A asserção II é falsa, pois a "propagação para frente" (*forward propagation*) não envolve retropropagar o erro. Ela é responsável por gerar a previsão inicial, enquanto a "propagação para trás" (*backpropagation*) é a etapa onde o erro é, de fato, retropropagado para ajustar os pesos.

Unicesumar

unidade

TEMA DE APRENDIZAGEM 2

FUNDAMENTOS DAS REDES NEURAIS CONVOLUCIONAIS

MINHAS METAS

- Compreender o conceito de convolução em redes neurais.
- Estudar as vantagens da convolução para a análise de dados espaciais.
- Analisar a importância do padding na preservação de informações.
- Explorar o impacto do stride na eficiência e extração de características.
- Investigar como o pooling reduz a dimensionalidade e aumenta a robustez.
- Entender a importância da não linearidade em camadas convolucionais.
- Analisar arquiteturas modernas e otimizações de convolução.

INICIE SUA JORNADA

No mundo digital, estamos cercados por imagens, vídeos e grandes volumes de dados visuais. Mas como um computador consegue entender uma foto ou reconhecer um rosto em uma rede social? Diferentemente dos seres humanos, que fazem isso naturalmente, as máquinas precisam de um processo matemático para identificar padrões em imagens. É aqui que entra a convolução, um conceito fundamental nas Redes Neurais Convolucionais (CNN), amplamente usadas para visão computacional e inteligência artificial (IA).

A convolução pode ser entendida como uma maneira inteligente de enxergar pequenas partes de uma imagem e combiná-las visando reconhecer padrões maiores. Imagine que, para identificar um rosto, o computador primeiro detecta bordas, depois, formas como olhos e boca, e só então consegue interpretar o rosto inteiro. Esse processo acontece porque filtros — também chamados de ***kernels*** — percorrem a imagem, destacando informações importantes e reduzindo detalhes irrelevantes.

Para visualizar esse conceito, pense em como nossos olhos percebem o mundo. Quando olhamos uma foto, podemos focar em detalhes, tais como: **cores, sombras e contornos**. No caso de uma CNN, ela aprende automaticamente quais padrões são mais relevantes para diferenciar um gato de um cachorro, por exemplo. Isso acontece porque o processo de convolução treina a rede a reconhecer essas características sem precisar que alguém programe cada regra específica.

A convolução não apenas ajuda computadores a entenderem imagens, mas também impulsiona avanços em medicina, segurança e muitas outras áreas. Sistemas de diagnóstico por imagem, reconhecimento facial e até veículos autônomos dependem dessa tecnologia no momento de tomar decisões com base no que "veem". Refletir sobre isso nos leva a perceber como a IA está cada vez mais presente no nosso cotidiano, tornando muitas tarefas mais rápidas e eficientes. Ao entender esse conceito, damos um passo importante para acompanhar essa revolução tecnológica.

PLAY NO CONHECIMENTO

Você sabia que as CNN podem ser a linha de defesa contra a crescente ameaça dos *deepfakes*? Nesse podcast, exploraremos como essa tecnologia inovadora está ajudando a identificar e combater a desinformação digital. Não fique de fora! **Recursos de mídia disponíveis no conteúdo digital do ambiente virtual de aprendizagem.**

VAMOS RECORDAR?

Relembraremos algumas situações: ao observar uma fotografia ou uma pintura, seu cérebro faz um trabalho incrível ao identificar elementos, por exemplo, pessoas, objetos ou paisagens. Mesmo sem perceber, você distingue entre uma árvore e uma casa ou reconhece o rosto de um amigo por detalhes específicos. Esse processo de reconhecimento e aprendizado é semelhante ao que ocorre nas Redes Neurais Convolucionais (CNN), criadas para interpretar e classificar imagens. Você já se perguntou como uma máquina diferencia uma maçã de uma laranja em uma foto? Assim como o cérebro ajusta conexões pela experiência, as CNN começam sem conhecimento. No início, nada reconhecem, mas, conforme são treinadas com exemplos, identificam padrões como formas, cores e texturas. Com o tempo e várias camadas de processamento, ajustam parâmetros para reconhecer características e classificar imagens com precisão. Esse vídeo mostra como as CNN reconhecem padrões e ficam mais inteligentes.

DESENVOLVA SEU POTENCIAL

CONCEITO DE CONVOLUÇÃO EM REDES NEURAIS

A **convolução** é um conceito fundamental nas CNN, amplamente utilizadas para o processamento de imagens e o reconhecimento de padrões. As imagens são compostas por **pixels**, organizados em matrizes bidimensionais que contêm informações sobre cor e intensidade.

Na IA, especialmente em tarefas de visão computacional, a convolução permite que a rede aprenda a extrair características relevantes das imagens, como bordas, texturas, formas e objetos, de maneira automática e eficiente (Massucatto, 2018).

> A importância da convolução está no fato de ela permitir que a rede neural identifique, com muita precisão, padrões e estruturas em imagens, independentemente de mudanças de posição, escala ou rotação. Por meio desse processo, a rede consegue aprender representações cada vez mais sofisticadas da imagem, possibilitando o reconhecimento de objetos e a análise de imagens complexas. Esse processo é crucial para uma variedade de aplicações, como a detecção de objetos, o diagnóstico médico, o monitoramento de infraestrutura e a visão computacional em veículos autônomos (Marchiori, 2023).

As CNN possuem diversas camadas especializadas, sendo as principais: camadas de convolução e camadas de agrupamento (*pooling*). Em essência, a convolução envolve a aplicação de uma série de "filtros" ao longo de toda a extensão da matriz de entrada, com o objetivo de extrair características relevantes.

Na arquitetura de uma CNN, são utilizadas várias sequências de camadas de convolução, cada uma composta por neurônios que aplicam filtros em regiões específicas da matriz de entrada. O resultado dessas operações é conhecido como mapa de características (*feature map*), o qual indica a localização das características extraídas pelos filtros.

A Figura 1 apresenta uma ilustração da arquitetura geral de uma CNN:

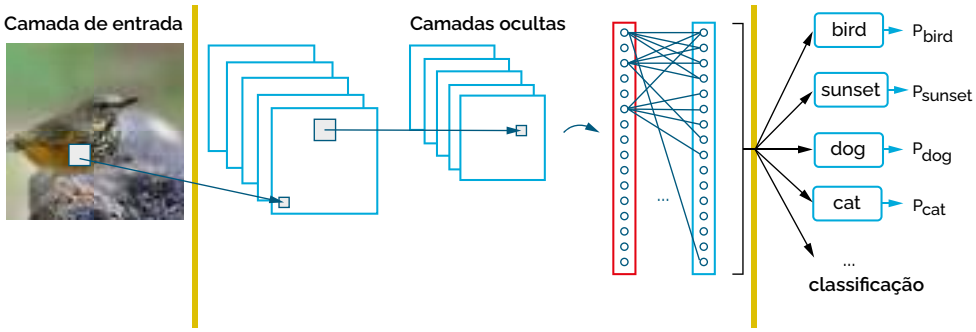

Figura 1 – Exemplo de uma arquitetura de classificação de imagens com CNN
Fonte: adaptada de Data Science Academy (2025).

Descrição da Imagem: diagrama explicativo sobre o funcionamento de uma rede neural convolucional utilizada para classificação de imagens. À esquerda, há uma fotografia nítida de uma ave em perfil. Um quadrado azul está sobreposto ao olho da ave, indicando a área inicial de análise. Acima da foto está escrito "Camada de entrada". No centro da imagem, aparecem diversos retângulos azuis dispostos em camadas, representando as "Camadas ocultas". O fundo da imagem é branco, e os elementos diagramáticos são desenhados com linhas simples, destacando o fluxo desde uma imagem de entrada até o resultado de classificação em categorias. O processo envolve a transformação da imagem em uma representação mais abstrata para permitir o reconhecimento e a classificação correta. Fim da descrição.

Na prática, a convolução funciona da seguinte forma, segundo Marchiori (2023):

- **Aplicação do filtro (*kernel*)**: a convolução começa com a aplicação de um filtro ou *kernel* — uma pequena matriz de valores — sobre a imagem de entrada. O filtro é deslocado por várias regiões da imagem, realizando operações de multiplicação e soma entre os valores do filtro e os valores da imagem. Esse processo faz a rede extrair diferentes características da imagem.
- **Controle do *stride* (passo)**: o *stride* define em quantos pixels o filtro se move entre as operações. Um *stride* pequeno (*stride* 1) faz o filtro mover-se pixel a pixel, enquanto um *stride* maior (*stride* 2) causa o movimento em saltos maiores. Isso impacta diretamente o tamanho do mapa de características gerado: quanto maior o *stride*, menor será esse mapa, já que o filtro é aplicado a um número menor de posições.

- **Dimensionalidade do mapa de características**: após a operação de convolução, o mapa de características gerado, normalmente, terá dimensões menores que a imagem original. Isso acontece porque o filtro só pode ser aplicado em um número limitado de posições. O tamanho do mapa de características depende do tamanho da imagem, do filtro e do *stride*.

EU INDICO

Se você deseja entender ainda mais o problema de classificação de imagens realizado pelas CNN, leia esse artigo que aborda os fundamentos do tema. Ele oferece uma introdução clara de como as CNN são aplicadas à classificação de imagens. Acesse:

ANÁLISE DE DADOS ESPACIAIS

As CNN vêm sendo bastante aplicadas na análise de dados espaciais, com impacto significativo em diversas áreas. Dentre suas aplicações, estão a detecção e a localização de objetos em imagens, a identificação de padrões em uso do solo e vegetação bem como o reconhecimento de elementos urbanos em imagens de satélite (Cabral; Berrones; Pons, 2024).

Essas técnicas têm sido muito aplicadas em setores como monitoramento ambiental, planejamento urbano, agricultura de precisão e segurança, proporcionando análises mais rápidas, precisas e eficientes. Modelos avançados — AlexNet, YOLO e outras arquiteturas de ponta — têm sido adotados para aprimorar a identificação de padrões visuais, reduzindo significativamente erros na interpretação de dados espaciais.

A importância dessas aplicações reside na capacidade de processar enormes volumes de informações geoespaciais, a fim de facilitar a tomada de decisões estratégicas, além de promover a automação de processos que, anteriormente, exigiam análises manuais detalhadas. Todo esse processo aumenta a eficiência e a precisão das operações (Cabral; Berrones; Pons, 2024).

O grande volume de dados gerados em áreas como monitoramento ambiental e planejamento urbano pode representar, no entanto, um desafio significativo que exige muito poder computacional e tempo de processamento. Embora a automação de processos seja uma vantagem, muitas análises ainda dependem de dados manuais ou da supervisão de especialistas, o que pode limitar a eficácia das soluções automatizadas bem como aumentar o custo e o tempo necessários para a análise.

Com o avanço da tecnologia, o uso de CNN na análise de dados espaciais continuará a crescer, impulsionando inovações em diversos setores, mas esses desafios precisam ser superados para garantir uma implementação mais eficiente e acessível (Cabral; Berrones; Pons, 2024).

INDICAÇÃO DE FILME

Perdido em Marte

O filme segue a história de Mark Watney, um astronauta que sobrevive sozinho em Marte após ser deixado para trás. Ele usa suas habilidades em engenharia e botânica para sobreviver enquanto a Nasa tenta resgatá-lo.

Refletindo sobre a história: embora o filme não mencione diretamente as CNN, ele ilustra como a análise de imagens geoespaciais é crucial para a exploração espacial.

PADDING

O *padding*, ou preenchimento, é uma técnica usada nas CNN para controlar o tamanho do mapa de características gerado após a operação de convolução, a fim de preservar ou ajustar a dimensionalidade da imagem durante o processamento. Ele consiste em adicionar pixels extras — geralmente, com valor zero — ao redor da borda da imagem de entrada antes de aplicar a convolução.

O objetivo principal do *padding* é preservar as informações nas bordas da imagem e garantir que a saída da convolução tenha as dimensões desejadas, evitando a perda de dados cruciais nas extremidades da imagem (Alrasheedi; Zhong; Huang, 2022).

O *padding* pode ser aplicado de duas formas principais: ***pre-padding*** e ***post-padding***. No ***pre-padding***, os valores de preenchimento, geralmente, zero, são adicionados antes da imagem, ou seja, nas bordas iniciais da sequência ou imagem, garantindo que o filtro tenha pixels suficientes nas regiões iniciais para realizar a operação de convolução corretamente. Já no **post-*padding***, os zeros são adicionados após a imagem, isto é, nas bordas finais. Ambas as abordagens têm suas vantagens, a depender do tipo de rede e da tarefa a ser realizada.

O ***pre-padding*** pode ser útil quando queremos preservar as características nas extremidades iniciais das imagens ou sequências, enquanto o ***post-padding*** é mais comum em CNN, nas quais as bordas finais não afetam tanto a capacidade do modelo de capturar as características locais, permitindo que as camadas de convolução operem mais eficientemente nas regiões centrais e finais das imagens. A escolha entre *pre-padding* e *post-padding* influencia o desempenho do modelo, dependendo da importância das diferentes regiões da entrada para a tarefa de aprendizado (Liu *et al.*, 2018).

Sem o uso de *padding*, as bordas da imagem seriam processadas de maneira inadequada, pois o filtro, ou *kernel*, não teria pixels suficientes para realizar o cálculo completo nas regiões periféricas. Essa ação poderia resultar na perda de características importantes localizadas nas extremidades da imagem, como as bordas de objetos, texturas ou padrões.

Além disso, o *padding* é importante para evitar a redução excessiva da dimensionalidade das imagens após a aplicação de múltiplas camadas de convolução. Sem o *padding*, a dimensão da imagem diminui progressivamente a cada camada, o que pode levar a uma perda substancial de informação ao longo do modelo (Alrasheedi; Zhong; Huang, 2022).

STRIDE

O *stride* é um parâmetro em CNN, responsável por definir o deslocamento do filtro, ou *kernel*, ao aplicar a operação de convolução sobre a imagem ou o mapa de características de entrada. Ele controla quantos pixels o filtro se move de cada vez durante a convolução, impactando diretamente a resolução do mapa de características gerado e a eficiência computacional da rede (Kong; Lucey, 2017).

Quando o *stride* é definido como 1, o filtro move-se um pixel por vez, o que resulta em um mapa de características mais detalhado e maior, pois o filtro cobre uma área menor de cada vez. Isso significa que a operação de convolução ocorre de forma mais precisa, por meio da captura de detalhes mais finos da imagem. Tal ação, no entanto, aumenta a quantidade de cálculos, tornando o modelo mais pesado e lento (Yepez; Ko, 2020).

Ainda segundo esses mesmos autores, quando o *stride* é definido como 2 ou maior, o filtro move-se mais rapidamente, pulando pixels entre as operações. Esse deslocamento maior gera mapas de características menores, o que pode reduzir a carga computacional do modelo e acelerar o processamento, mas ao custo de perder alguns detalhes locais da imagem.

Conforme Kong e Lucey (2017), o *stride* impacta diretamente em:

REDUÇÃO DA DIMENSIONALIDADE

Quanto maior o valor do *stride*, menor o mapa de características gerado. Isso ocorre porque o filtro cobre mais pixels de uma vez, portanto, diminui a resolução da imagem processada. Em CNN, esse cenário pode ser útil para reduzir a quantidade de dados em etapas mais profundas da rede e ajudar na eficiência tanto do treinamento quanto da velocidade de inferência.

EFICIÊNCIA COMPUTACIONAL

O uso de um *stride* maior tem a possibilidade de melhorar a eficiência computacional ao diminuir o número de operações necessárias para calcular o mapa de características. Esse cenário, no entanto, arrisca resultar em uma perda de informações finas, já que áreas menores da imagem são analisadas.

CAPACIDADE DE GENERALIZAÇÃO

O *stride* também influencia a capacidade de generalização da rede. O uso de *strides* maiores auxilia a rede a capturar padrões mais gerais e robustos, pois evita que o modelo se concentre excessivamente em detalhes específicos de regiões da imagem e, assim, reduz o risco de *overfitting*.

Além de suas implicações na dimensionalidade e eficiência, o *striding* também pode ser visto como uma ferramenta que força o compartilhamento de parâmetros entre diferentes regiões da entrada. Isso ocorre porque o filtro, ao ser aplicado em diferentes locais com o mesmo valor de *stride*, reutiliza os mesmos parâmetros em várias regiões da imagem. Esse compartilhamento ajuda a reduzir o espaço de parâmetros e torna o modelo mais eficiente, além de melhorar sua capacidade de generalização (Kong; Lucey, 2017).

POOLING

O ***pooling*** é um componente essencial das CNN, por ser utilizado para reduzir a dimensionalidade das representações sem perder informações cruciais. Tal habilidade melhora a eficiência computacional do modelo e a capacidade de generalização, consequentemente, torna a rede menos sensível a variações na posição dos objetos na imagem (Nirthika *et al.*, 2022).

EXPERIÊNCIA INTERATIVA

Vejamos, agora, nesse recurso, quais são as principais características do *pooling*.

Dê um passo além da leitura, escaneie o QR-Code e conecte-se ao nosso recurso interativo!

Existem diferentes tipos de *pooling*, cada um com características e vantagens específicas, adaptadas a diferentes necessidades das CNN. Guimarães *et al.* (2025) afirmam haver dois tipos mais comuns: o ***max pooling*** e o ***average pooling***, cada um com benefícios únicos, dependendo da aplicação.

O ***max pooling*** é o mais comum. Ele funciona ao selecionar o maior valor em uma região da matriz, o que ajuda a preservar as características mais importantes da imagem, como bordas e contornos, ao mesmo tempo que elimina ruídos desnecessários. Esse tipo é amplamente utilizado em **reconhecimento facial** e **carros autônomos.**

Por sua vez, o ***average pooling*** calcula a média dos valores em uma região da matriz, suavizando a imagem e mantendo mais informações, o que é útil em tarefas que envolvem padrões mais difusos, como **análise de texturas** e **diagnóstico médico**.

Ambos os tipos de *pooling* têm suas vantagens, sendo o max ideal para destacar elementos mais significativos, e o *average*, mais adequado em preservar uma visão geral e mais suave da imagem, a depender da aplicação desejada (Guimarães et al., 2025).

PENSANDO JUNTOS

Por que o *pooling* pode ser a chave para transformar sistemas de reconhecimento de imagem? O *pooling* garante que variações na posição ou no tamanho de um rosto não comprometam a precisão do modelo. Além disso, ao reduzir a dimensionalidade, possibilita economizar poder computacional, ao permitir mais rapidez e eficiência às redes neurais. Tal característica abre portas para aplicações em tempo real, como reconhecimento facial em dispositivos móveis ou sistemas de segurança.

NÃO LINEARIDADE EM CAMADAS CONVOLUCIONAIS

Originalmente, as redes neurais eram compostas somente por camadas lineares, o que limitava a capacidade delas de aprender representações complexas. Isso porque, mesmo com várias camadas, a rede ainda seria equivalente a uma única camada, devido à natureza linear das operações.

A solução para esse problema surgiu com a introdução de funções de ativação não lineares, as quais possibilitaram as redes neurais capturarem relações mais complexas e modelar dependências não lineares nos dados.

A **não linearidade** nas camadas convolucionais permite o funcionamento eficiente das CNN, sendo responsável por dar à rede a capacidade de aprender representações complexas e eficazes dos dados. Sem a introdução de não linearidades, a rede neural seria restrita a aprender apenas combinações lineares das entradas, o que limitaria drasticamente a capacidade dessa rede de captar padrões mais sofisticados e variáveis presentes nas informações, especialmente em tarefas complexas, como o reconhecimento de imagens ou a tradução de textos.

Em uma CNN, as camadas convolucionais realizam a extração de características mediante aplicação de filtros para detectar padrões básicos, por exemplo, bordas, texturas e cores. Para a rede conseguir capturar características mais abstratas e complexas, como formas e objetos completos, é necessário introduzir a não linearidade logo após essas camadas convolucionais. Isso é feito, principalmente, mediante **funções de ativação** não lineares: **ReLU (Rectified Linear Unit)**, **sigmoid** ou **tanh** (Mauad; Guilhermino Neto, 2023).

Sem a introdução de não linearidades, a rede neural seria restrita a aprender apenas combinações lineares das entradas

O ReLU transforma qualquer valor negativo da camada convolucional em zero e mantém os valores positivos, assim, torna a rede mais eficiente e ajuda a evitar um problema chamado desvanecimento do gradiente, que pode ocorrer em redes profundas durante o treinamento. Ao manter valores positivos e limitar os negativos, o ReLU também propaga o gradiente para camadas mais profundas, permitindo a rede aprender de maneira mais eficaz e rápida. Existem outras funções de ativação, como a sigmoid e tanh que, apesar de serem menos comuns em CNN modernas, ainda são usadas em tarefas específicas. A sigmoid mapeia os valores de entrada para um intervalo entre 0 e 1, enquanto a tanh faz o mesmo, mas mapeia os valores para um intervalo entre -1 e 1 (Mauad; Guilhermino Neto, 2023).

Essa introdução de não linearidade é o que torna as CNN tão poderosas. Ela faz as redes neurais capturarem e aprenderem representações hierárquicas dos dados. Em outras palavras, as CNN podem aprender primeiro características simples, como bordas e texturas nas primeiras camadas, depois, combinar essas características em formas e objetos em camadas mais profundas para, finalmente, identificar padrões ainda mais complexos em camadas mais avançadas. Essa capacidade de aprender representações em diferentes níveis de abstração é crucial às tarefas desafiadoras, como classificação de imagens, reconhecimento de objetos em vídeos, segmentação semântica e até mesmo em modelos de linguagem natural (Mauad; Guilhermino Neto, 2023).

A Figura 2 ilustra um exemplo de classificação de imagem no contexto da análise de expressões faciais. Nesse processo, a rede neural convolucional (CNN) é utilizada para identificar e classificar diferentes emoções expressas no rosto, como felicidade, tristeza, raiva ou surpresa. A imagem de entrada passa por várias camadas da rede, começando com a extração de características, seguida pela redução de dimensionalidade com *pooling* e, por fim, a classificação final realizada pelas camadas totalmente conectadas. O objetivo é treinar o modelo para reconhecer padrões faciais específicos, permitindo que ele identifique com precisão as emoções em novas imagens. A precisão do modelo depende da qualidade e variedade dos dados de treinamento, além da eficácia dos filtros aplicados nas camadas convolucionais.

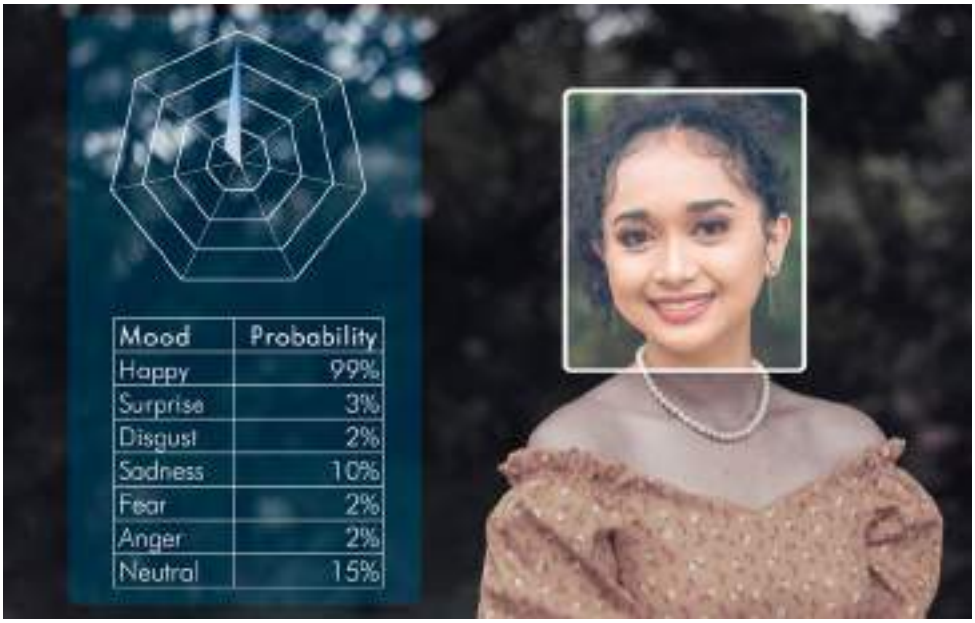

Figura 2 – Exemplo de classificação de imagem na análise de expressões faciais

Descrição da Imagem: interface de um programa de reconhecimento facial mostrando uma jovem sorridente com cabelo cacheado amarrado, brincos em formato de agulha e uma blusa que deixa os ombros à mostra. A expressão facial dela transmite felicidade. A tecnologia de reconhecimento facial está sendo aplicada à imagem, analisando as expressões e avaliando as emoções com base no sorriso e em outros sinais faciais. O sistema de IA detecta esses detalhes para entender o estado emocional da pessoa. Ao lado esquerdo da imagem, há um painel digital azul translúcido, com uma tabela e um gráfico em forma de teia de aranha. A tabela mostra diferentes estados de humor e suas probabilidades, escritos em inglês. Acima da tabela está o gráfico com linhas brancas, relacionando visualmente os diferentes níveis dos estados de humor indicados. Fim da descrição.

ARQUITETURAS MODERNAS

As **arquiteturas modernas** de CNN e suas **otimizações de convolução** são essenciais para o avanço das tecnologias de aprendizado profundo. Essas inovações visam melhorar a eficiência computacional, reduzir o tempo de treinamento e aumentar a capacidade de generalização das redes (Mateo, 2024).

A seguir, destacamos, segundo esse mesmo autor, algumas das principais arquiteturas e otimizações que têm sido aplicadas ao longo do tempo.

RESNET (*RESIDUAL NETWORKS*)

Permitem que o modelo aprenda a diferença entre a entrada e a saída, ajudando na aprendizagem de representações mais complexas, sem a necessidade de redes extremamente profundas e sem o problema de degradação do desempenho.

INCEPTION (GOOGLENET)

Utiliza múltiplos filtros convolucionais de vários tamanhos em paralelo, combinando os resultados para capturar diferentes características da imagem. Essa abordagem, chamada de *inception module*, aumenta a eficiência computacional e de memória, mantendo a capacidade da rede de aprender representações complexas sem sobrecarregar o sistema.

EFFICIENTNET

Uma das arquiteturas mais eficientes em termos de desempenho e custo computacional. Ela utiliza uma abordagem de escalabilidade que ajusta simultaneamente a profundidade, a largura e a resolução da rede, otimizando a utilização de recursos e mantendo uma alta precisão. Esse tipo de arquitetura é ideal para aplicações em dispositivos móveis e sistemas com recursos limitados.

MOBILENET

Projetada especificamente para ser eficiente em dispositivos móveis e ambientes com restrição de recursos. Utilizando convoluções separáveis em profundidade (*depthwise separable convolutions*), o MobileNet consegue realizar a convolução de maneira mais eficiente, assim, reduz significativamente o número de parâmetros e a carga computacional.

No treinamento de redes neurais, os otimizadores são essenciais para ajustar os pesos do modelo, ao minimizarem a função de perda e melhorarem o desempenho. Dentre os otimizadores mais utilizados estão o **Stochastic Gradient Descent (SGD)**, o **Adam** e o **AdamW**, cada um com características distintas (Mateo, 2024):

- **SGD**: um dos otimizadores mais antigos e amplamente usados. Ele atualiza os pesos com base no gradiente da função de perda em um pequeno lote de dados. Embora eficiente em termos de memória, pode ser lento para convergir, especialmente em modelos complexos.
- **Adam**: proposto por Kingma e Ba em 2015, combina as vantagens do SGD com momentos de primeira e segunda ordem, adaptando as taxas de aprendizado para cada parâmetro. O Adam oferece rápida convergência, além de ser eficaz para redes profundas.
- **AdamW**: introduzido por Loshchilov e Hutter em 2019, é uma modificação do Adam que desacopla a regularização por decaimento de peso do processo de atualização dos parâmetros. Essa característica resolve limitações do Adam, como a acumulação excessiva de pesos, reduzindo o risco de *overfitting*.

Diante da evolução contínua das arquiteturas das CNN e dos avanços nos métodos de otimização, a área de aprendizado profundo continua a expandir suas fronteiras, propiciando aplicações cada vez mais sofisticadas e eficientes. O desenvolvimento de modelos mais leves e precisos, como o EfficientNet e o MobileNet, aliado ao uso de utilizadores avançados, tais como o AdamW, demonstra o compromisso da comunidade científica e da indústria em aprimorar a eficiência computacional e a acessibilidade da IA.

Essas inovações viabilizam seu uso em diferentes contextos, desde dispositivos móveis até sistemas de grande escala. Assim, consolidam o impacto do aprendizado profundo em diversas áreas do conhecimento.

EM FOCO

Confira a aula referente a este tema. **Recursos de mídia disponíveis no conteúdo digital do ambiente virtual de aprendizagem.**

NOVOS DESAFIOS

As Redes Neurais Convolucionais (CNN) representam um avanço significativo na inteligência artificial (IA), especialmente para a análise e interpretação de imagens. No mercado de trabalho, essa tecnologia destaca-se em diversas áreas — saúde, segurança, indústria e entretenimento — impulsionando tanto a automação quanto a eficiência em tarefas complexas.

A teoria das CNN baseia-se no conceito de convolução, que possibilita a extração de características relevantes em imagens. Esse processo, o qual envolve filtros para identificar padrões, por exemplo, bordas, texturas e formas, fundamenta como as CNN não só reconhecem, mas interpretam dados visuais. Na prática, esse conhecimento teórico é aplicado para criar modelos treinados com grandes bases de dados, tornando a tecnologia capaz de tomar decisões autônomas e precisas.

No **campo da saúde**, por exemplo, algoritmos baseados em CNN são utilizados para detectar anomalias em exames de imagem, como tomografias e radiografias, a fim de auxiliar médicos no diagnóstico precoce de doenças.

Na segurança, sistemas de reconhecimento facial e monitoramento automatizado utilizam CNN para identificar, com alta precisão, pessoas e atividades suspeitas.

No setor industrial, a visão computacional impulsionada por CNN otimiza processos produtivos, permitindo inspeção automática de qualidade em linhas de montagem e o controle de máquinas por meio da **interpretação de imagens**. No varejo, essas redes são aplicadas para personalizar recomendações de produtos, melhorar a experiência do cliente e até mesmo gerenciar estoques com reconhecimento visual de mercadorias.

Além dessas aplicações, o mercado de tecnologia está em constante evolução, por meio da criação de oportunidades para profissionais que dominam CNN e IA. Empresas buscam especialistas capazes de desenvolver e implementar essas soluções, garantindo um futuro promissor a quem se especializa na área. Dessa forma, a teoria das CNN conecta-se diretamente à prática, pois os conceitos matemáticos e computacionais que fundamentam essas redes são essenciais para criar sistemas inteligentes impactantes em diversos setores e transformadores em como interagimos com a tecnologia.

VAMOS PRATICAR

1. A convolução surgiu como uma solução para a necessidade de melhorar a eficiência e a capacidade das redes neurais em processar imagens e dados espaciais de forma mais eficiente. Antes do desenvolvimento das Redes Neurais Convolucionais (CNN), redes tradicionais enfrentavam dificuldades ao lidar com imagens, porque essas possuem uma grande quantidade de dados e exigem um processamento intensivo. A convolução foi introduzida como uma maneira de reduzir a complexidade computacional e permitir que as redes fossem mais eficientes (Massucatto, 2018).

   Com base nessa afirmação, qual alternativa, a seguir, descreve corretamente o conceito de convolução e sua aplicação em CNN?

   a) A convolução em redes neurais é utilizada para gerar uma nova versão da imagem original, alterando suas dimensões visando adequar-se ao modelo de entrada da rede.
   b) A convolução é um processo que permite a extração de características de imagens, como bordas e formas, por meio de filtros que passam sobre a imagem original.
   c) A convolução em redes neurais é utilizada apenas para transformar imagens coloridas em tons de cinza, para facilitar o processamento.
   d) A convolução é um processo utilizado para classificar imagens em categorias específicas, sem a necessidade de aprendizado durante o treinamento.
   e) A convolução é uma técnica usada exclusivamente para aumentar a resolução de imagens antes de seu processamento por uma rede neural.

2. As arquiteturas modernas de redes neurais, como ResNet, Inception, EfficientNet e MobileNet, desempenham um papel fundamental no avanço das técnicas de aprendizado profundo. Cada uma dessas arquiteturas foi projetada com características específicas para melhorar a eficiência computacional, a escalabilidade e a capacidade de aprendizado das redes neurais. Essas inovações não apenas aprimoram a capacidade das redes neurais de lidar com tarefas complexas, mas também tornam possível a aplicação dessas tecnologias em dispositivos com recursos limitados, como smartphones e sistemas embarcados (Mateo, 2024).

   Com base no texto sobre as arquiteturas modernas de redes neurais, veja as afirmativas, a seguir:

   I - A ResNet permite que o modelo aprenda a diferença entre a entrada e a saída, ajudando na aprendizagem de representações mais complexas sem a necessidade de redes extremamente profundas, para evitar o problema de degradação de desempenho.
   II - A Inception utiliza múltiplos filtros convolucionais de diferentes tamanhos em paralelo, combinando os resultados para capturar diferentes características da imagem e aumentar a eficiência computacional e de memória.

III - A EfficientNet utiliza uma abordagem de escalabilidade que ajusta simultaneamente a profundidade, a largura e a resolução da rede, otimizando a utilização de recursos e mantendo alta precisão.

IV - A MobileNet foi projetado especificamente para dispositivos móveis, utilizando convoluções separáveis em profundidade para reduzir a carga computacional e melhorar a eficiência no uso de recursos limitados.

É correto o que se afirma em:

a) I, apenas.
b) II e IV, apenas.
c) III e IV, apenas.
d) I, II e III, apenas.
e) I, II, III e IV.

3. **As Redes Neurais Convolucionais (CNN) são amplamente utilizadas para o processamento de imagens devido à sua capacidade de extrair características relevantes em diferentes níveis de abstração. Inicialmente, as camadas convolucionais detectam padrões simples, como bordas e texturas, mas para a rede aprender representações mais complexas, é fundamental introduzir a não linearidade. Essa introdução é feita por funções de ativação (Mauad; Guilhermino Neto, 2023).**

Com base nas informações apresentadas, avalie as asserções, a seguir, e a relação proposta entre elas:

I - As funções de ativação não lineares, como ReLU, sigmoid e tanh, são essenciais para que a CNN capture características abstratas e complexas, permitindo a aprendizagem de padrões mais sofisticados.

PORQUE

II - O ReLU, ao transformar valores negativos em zero e manter os positivos, evita o problema do desvanecimento do gradiente, portanto, facilita a boa propagação do gradiente em redes profundas.

A respeito dessas asserções, assinale a alternativa correta:

a) As asserções I e II são verdadeiras, e a II é uma justificativa correta da I.
b) As asserções I e II são verdadeiras, mas a II não é uma justificativa correta da I.
c) A asserção I é uma proposição verdadeira, e a II é uma proposição falsa.
d) A asserção I é uma proposição falsa, e a II é uma proposição verdadeira.
e) As asserções I e II são falsas.

REFERÊNCIAS

ALRASHEEDI, F.; ZHONG, X.; HUANG, P.-C. *Padding module*: learning the *padding* in deep neural networks. **IEEE Access**, v. 4, p. 7348-7357, 2022.

CABRAL, M. T. M.; BERRONES, R. G. C.; PONS, M. D. A. Modelo de identificación espacial de patrones de referencia empleando Redes Neuronales Convolucionales (CNN) y entrenamiento por lotes. **Revista de Investigación Multidisiplinaria Iberoamericana**, año 2, n. 4, p. 1-20, 2024.

DATA SCIENCE ACADEMY. As principais arquiteturas de redes neurais. *In:* DATA Science Academy. **Deep Learning Book**. *[S. l.]:* Data Science Academy, 2025. Disponível em: https://www.deeplearningbook.com.br/as-10-principais-arquiteturas-de-redes-neurais/. Acesso em: 21 ago. 2025.

GUIMARÃES, A. J. S. *et al.* Ação de redes neurais convolucionais na classificação de imagens: abordagens e resultados. **Revista Contemporânea**, v. 5, n. 1, p. 1-19, 2025.

KONG, C.; LUCEY, S. Take it in your stride: do we need striding in CNN?. **arXiv preprint arXiv:1712.02502**, 2017. Disponível em: https://arxiv.org/abs/1712.02502. Acesso em: 21 ago. 2025.

LIU, G. *et al.* Partial convolution based padding. **arXiv preprint arXiv:1811.11718**, 2018. Disponível em: https://arxiv.org/abs/1811.11718. Acesso em: 21 ago. 2025.

MARCHIORI, C. E. A. **Aplicação de uma rede neural de convolução para posicionamento de seccionadora em linha de produção**. 2023. 69 f. Trabalho de Conclusão (Curso de Graduação em Engenharia de Controle e Automação) – Centro Tecnológico, de Ciências Exatas e Educação, Universidade Federal de Santa Catarina, Blumenau, 2023.

MASSUCATTO, J. D. P. **Aplicação de conceitos de redes neurais convolucionais na classificação de imagens de folhas**. 2018. 70 f. Trabalho de Conclusão de Curso (Curso de Engenharia de Computação) – Departamento Acadêmico de Informática, Universidade Tecnológica Federal do Paraná, Pato Branco, 2018.

MATEO, L. H. **Aplicação de redes neurais convolucionais para classificação de doenças em plantações de soja**. 2024. 75 f. Trabalho de Conclusão de Curso (MBA em Inteligência Artificial e Big Data) – Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo, São Carlos, 2024.

MAUAD, H. F.; GUILHERMINO NETO, G. **Deep learning para inspeção visual em peças fundidas**. 2023. 35 f. Trabalho de Conclusão de Curso (Especialização em Engenharia de Produção) – Pós-Graduação em Engenharia de Produção com Ênfase em Tecnologias de Decisão, Instituto Federal do Espírito Santo, Cariacica, 2023.

NIRTHIKA, R. *et al. Pooling* in convolutional neural networks for medical image analysis: a survey and an empirical study. **Neural Computing and Applications**, v. 34, n. 7, p. 5321-5347, 2022.

YEPEZ, J.; KO, S.-B. *Stride* 2 1-D, 2-D, and 3-D winograd for convolutional neural networks. **IEEE Transactions on Very Large Scale Integration (VLSI) Systems**, v. 28, n. 4, p. 853-863, 2020.

CONFIRA SUAS RESPOSTAS

1. Alternativa B.

   A convolução é usada para extrair características, como bordas e formas, por meio de filtros que percorrem a imagem.
   A alternativa A está incorreta, pois a convolução não pretende alterar as dimensões da imagem, mas sim extrair características.
   A alternativa C está incorreta, pois a convolução não transforma imagens coloridas em tons de cinza, mas sim extrai padrões das imagens.
   A alternativa D está incorreta, pois a convolução não classifica imagens, apenas extrai características. A classificação ocorre após a extração.
   A alternativa E está incorreta, pois a convolução não aumenta a resolução das imagens, mas pode reduzir sua resolução para extrair características.

2. Alternativa E.

   A afirmativa I está correta, pois a ResNet é projetada para permitir que a rede aprenda a diferença entre a entrada e a saída, evitando problemas de degradação de desempenho com redes muito profundas.
   A afirmativa II está correta, pois a Inception utiliza múltiplos filtros convolucionais de tamanhos diferentes, o que permite capturar diversas características da imagem, mantendo eficiência em termos de computação e memória.
   A afirmativa III está correta, pois a EfficientNet ajusta simultaneamente a profundidade, a largura e a resolução da rede, otimizando recursos e garantindo alta precisão, sendo uma das arquiteturas mais eficientes em termos de custo computacional.
   A afirmativa IV está correta, pois a MobileNet é otimizada para dispositivos móveis e utiliza convoluções separáveis em profundidade, a fim de reduzir a carga computacional, tornando-a adequada para ambientes com recursos limitados.

3. Alternativa A.

   A asserção I é verdadeira, pois as funções de ativação não lineares são essenciais para a CNN aprender padrões mais abstratos e complexos, indo além da simples detecção de bordas e texturas. Sem a não linearidade, a rede estaria limitada a operações lineares, restringindo sua capacidade de capturar relações mais sofisticadas nos dados.
   A asserção II é verdadeira, pois o ReLU desempenha um papel fundamental na propagação eficiente do gradiente, evitando o problema do desvanecimento, que ocorre quando valores muito pequenos fazem a rede parar de aprender. Ao manter valores positivos e zerar os negativos, a informação flui de maneira mais eficaz durante o treinamento.
   Dessa forma, a asserção II justifica corretamente a I, pois o uso de funções de ativação como ReLU contribui diretamente para a CNN aprender padrões mais complexos, sem sofrer com problemas de treinamento.

MEU ESPAÇO

TEMA DE APRENDIZAGEM 3

NORMALIZAÇÃO E REGULARIZAÇÃO EM CNN

MINHAS METAS

- Entender como a Batch Normalization funciona e estabiliza os dados.
- Explorar os benefícios da Batch Normalization: estabilidade e aceleração.
- Analisar o impacto da Batch Normalization na regularização e generalização.
- Estudar o papel do Dropout na prevenção de *overfitting* e robustez.
- Investigar como o Dropout afeta a ativação dos neurônios.
- Comparar a Batch Normalization e o Dropout quanto ao uso.
- Avaliar o impacto dessas técnicas no desempenho em diferentes cenários.

INICIE SUA JORNADA

Imagine que você está aprendendo um novo jogo. No começo, é difícil entender as regras e suas jogadas parecem meio aleatórias, mas conforme pratica, percebe padrões e melhora suas escolhas. Agora, imagine se, em vez de aprender a estratégia do jogo, você decorasse cada jogada exata que já viu. Isso poderia funcionar por um tempo, mas quando surgisse um novo desafio, ficaria perdido. Esse é um problema comum para quem está desenvolvendo modelos de **inteligência artificial** (IA): como garantir que eles realmente aprendam, em vez de apenas decorar os exemplos que viram?

No aprendizado de uma nova habilidade, seja um esporte, seja um idioma ou uma tecnologia, existem técnicas que ajudam a tornar a experiência mais eficiente. Em modelos de IA, também há estratégias que tornam o aprendizado mais equilibrado: algumas delas ajudam a evitar que o modelo fique "viciado" nos exemplos observados, assim, ele adapta-se melhor a novas situações; outras ajudam a organizar o aprendizado, evitando que oscilações aleatórias prejudiquem o resultado. Essas iniciativas são essenciais para quem quer desenvolver soluções inteligentes e eficientes.

Uma boa maneira de entender esse cenário é testando na prática. Ao treinar um modelo, você pode tentar rodá-lo de diferentes formas: uma vez sem nenhuma dessas estratégias, outra vez, aplicando técnicas que equilibram e estabilizam o aprendizado. O que você perceberá? Sem organização, o modelo pode se perder e aprender de forma desordenada. Sem controle, ele arrisca tornar-se "viciado" nos exemplos de treino, então, falhará quando for colocado diante de algo novo. Já com as estratégias certas, ele aprenderá de um jeito mais confiável e adaptável.

No caminho do desenvolvimento profissional, aprender a aprender é uma habilidade essencial. Da mesma forma que você precisa de boas estratégias para estudar e crescer na sua carreira, um modelo de IA também precisa ser treinado da maneira certa. O que podemos levar dessa analogia para a nossa própria jornada? Como aplicar essas ideias para melhorar não só o aprendizado das máquinas, mas também o nosso próprio aprendizado ao longo da vida?

PLAY NO CONHECIMENTO

Você sabia que a normalização e a regularização são fundamentais para tornar redes neurais mais eficientes e precisas? Nesse podcast, exploramos como essas técnicas ajudam desde o reconhecimento de imagens até os motores de voz, por exemplo, o DeepSpeech, da Mozilla. Descubra como a IA está evoluindo para criar soluções mais robustas, mais preparadas para o mercado de trabalho. **Recursos de mídia disponíveis no conteúdo digital do ambiente virtual de aprendizagem.**

VAMOS RECORDAR?

Ao estudar para uma prova ou aprender uma nova habilidade, é essencial equilibrar memorização e compreensão. Decorar respostas sem entender pode gerar dificuldades quando a questão aparece de forma diferente. Algo semelhante ocorre nas CNN. No início do treinamento, uma CNN pode apenas "decorar" os exemplos vistos, com bom funcionamento em testes internos, mas com falhas diante de imagens novas. Para evitar tal problema e garantir um aprendizado eficaz, aplicam-se técnicas de regularização. Elas fazem a rede equilibrar precisão e adaptação, reduzindo o peso de detalhes específicos que causam erros, assim, melhora-se a capacidade de generalização. Veja esse site, nele, você encontra um exemplo detalhado de como a padronização e a normalização dos dados melhoram o desempenho dos modelos de aprendizado de máquina.

DESENVOLVA SEU POTENCIAL

INTRODUÇÃO ÀS TÉCNICAS DE NORMALIZAÇÃO E REGULARIZAÇÃO

A **normalização** e a **regularização** são duas técnicas essenciais no treinamento de redes neurais e em modelos de aprendizado de máquina em geral, com o objetivo de melhorar o desempenho do modelo e assegurar que ele seja mais eficaz, mais robusto ao lidar com diferentes tipos de dados (Mendonça, 2008).

A **normalização** é um processo que ajusta os dados para todas as variáveis ou características terem uma escala similar.

Imagine que você tem um conjunto de dados com várias medições: a altura das pessoas em centímetros, a idade em anos, e a renda em milhares de reais. Esses dados possuem escalas muito diferentes, por exemplo, a altura pode variar de 150 a 200, enquanto a renda, de 1.000 a 10.000). Isso pode fazer com que a rede neural tenha dificuldades de entender as relações entre esses dados, pois variáveis com valores mais altos influenciam mais o modelo, prejudicando o aprendizado.

A **normalização** resolve esse problema ajustando os dados para uma escala comum, geralmente, fazendo com que todos os valores tenham uma média igual a zero e um desvio padrão de 1. Tal processo facilita o treinamento porque a rede neural pode aprender de forma mais equilibrada, sem ser influenciada por variáveis com escalas muito diferentes (Mendonça, 2008).

A **regularização**, por sua vez, é uma técnica que ajuda a evitar o ***overfitting***, ou sobreajuste. O *overfitting* acontece quando um modelo aprende tanto os detalhes dos dados de treinamento que ele se torna muito específico àquele conjunto e perde a capacidade de generalizar para novos dados. Isso significa que o modelo pode ser muito bom ao fazer previsões com os dados de treinamento, mas não funciona bem com dados novos ou diferentes.

A **regularização** ajuda a evitar esse problema de "memorização" dos dados. Ela faz isso mediante aplicação de uma penalidade ao modelo, restringindo a complexidade dos parâmetros ou coeficientes por ele aprendidos. Com isso, o modelo é incentivado a aprender padrões mais simples e gerais, possíveis de serem aplicados em diferentes situações, em vez de decorar informações irrelevantes (Phaisangittisagul, 2016).

Tanto a normalização quanto à regularização são essenciais para assegurar que o modelo de aprendizado de máquina seja eficaz. A normalização melhora o processo de aprendizado, tornando-o mais rápido e equilibrado, enquanto a regularização assegura que o modelo não se ajuste demais aos dados de treinamento, mantendo a capacidade dele de generalizar para novas situações.

Para os profissionais da área, essas técnicas são ferramentas cruciais que evitam problemas comuns no treinamento de redes neurais e garantem a precisão e a confiabilidade dos modelos ao fazer previsões em dados do mundo real.

Para os leigos, é importante entender que essas técnicas tornam os modelos mais "inteligentes", permitindo-os aprender de maneira mais eficiente e eficaz, sem se "enganar" ao se ajustarem aos exemplos que já conhece (Mendonça, 2008).

INDICAÇÃO DE LIVRO

Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow

Esse livro de Aurélien Géron é um guia prático e completo ao desenvolvimento de modelos de *machine learning e deep learning* com Python. O livro explora detalhadamente o uso de CNN, destacando técnicas essenciais, como a regularização (incluindo Dropout e penalidades L1/L2) e a normalização, especialmente com Batch Normalization. Essas abordagens são fundamentais para melhorar a generalização dos modelos.

Essas técnicas são ferramentas cruciais que evitam problemas comuns no treinamento de redes neurais

BATCH NORMALIZATION

Para entender a importância e o funcionamento do Batch Normalization, é fundamental explorar o conceito, a implementação prática e o impacto que essa técnica gera tanto no desenvolvimento de modelos quanto na sociedade.

Conceito e funcionamento

Batch Normalization é uma técnica utilizada em redes neurais profundas com o objetivo de tornar o treinamento mais rápido, estável e eficaz. À medida que as redes se tornam mais complexas e profundas, com diversas camadas e milhões de parâmetros, torna-se mais difícil garantir que o aprendizado ocorra de forma eficiente. Um dos desafios enfrentados nesse cenário é a instabilidade no fluxo de informações ao longo das camadas, especialmente quando os dados passam por várias transformações sucessivas (Bjorck *et al.*, 2018).

Essa técnica atua diretamente nas ativações intermediárias da rede, ou seja, nos valores calculados pelas camadas antes da aplicação das funções de ativação, como ReLU, sigmoid ou tanh). O Batch Normalization normaliza essas ativações dentro de cada *mini-batch* de treinamento, para terem média próxima de zero e desvio padrão próximo de 1. Esse processo ajuda a manter os dados em uma faixa consistente, evitando que valores muito altos ou muito baixos prejudiquem o aprendizado (Ioffe; Szegedy, 2015).

Além dessa normalização estatística, a técnica incorpora dois parâmetros treináveis: um de escala (γ) e um de deslocamento (β), que permitem à rede aprender a melhor forma de ajustar esses valores, caso a normalização "pura" não seja ideal para certas camadas ou representações (Ioffe; Szegedy, 2015). Por meio da fórmula, podemos calcular a transformação com parâmetros treináveis:

$$y_i = \gamma x_i + \beta$$

Depois que os dados são normalizados — com média zero e desvio padrão 1 — aplica-se essa transformação linear usando dois parâmetros aprendidos durante o treinamento:

- x_i : é a ativação normalizada.
- γ (gamma): controla a escala da saída normalizada.
- β (beta): controla o deslocamento da saída.

O principal problema que o Batch Normalization resolve é o chamado deslocamento de covariância interna (*internal covariate shift*), que acontece quando pequenas mudanças nos pesos de uma camada alteram significativamente a distribuição dos dados de entrada da próxima camada. Isso dificulta o treinamento, pois a rede precisa constantemente se readaptar a novas distribuições internas (Ioffe; Szegedy, 2015).

Ao manter a distribuição das ativações mais constante ao longo do tempo, o Batch Normalization reduz esse deslocamento interno, então, possibilita que a rede aprenda de maneira mais fluida. Como resultado, é possível utilizar taxas de aprendizado maiores, acelerar o processo de convergência, reduzir a dependência da escolha inicial dos pesos e até mitigar o risco de *overfitting*, funcionando como uma forma indireta de regularização (Bjorck *et al.*, 2018).

Implementação e impacto

Na prática, a implementação do Batch Normalization é simples e amplamente adotada nas principais bibliotecas de *machine learning*, como Keras, TensorFlow e PyTorch.

Em Keras, por exemplo, basta adicionar a camada BatchNormalization() após uma camada densa (ou convolucional) e antes da aplicação da função de ativação.

Em PyTorch, a camada equivalente é BatchNorm1d() (para dados unidimensionais) ou BatchNorm2d() (para imagens). Essas camadas são ajustadas automaticamente durante o treinamento, aprendendo os parâmetros necessários à normalização dos dados e, ao mesmo tempo, à preservação ou até mesmo à melhoria da capacidade de representação da rede (Vasilev *et al.*, 2019).

O impacto dessa técnica no treinamento de redes neurais é profundo e multifacetado. Ao reduzir o problema do *internal covariate shift*, o Batch Normalization acelera a convergência, o que significa que modelos aprendem mais rapidamente com menos épocas de treinamento. Isso economiza tempo e recursos computacionais, um ponto especialmente importante em projetos com muita demanda de dados e processamento, por exemplo, em visão computacional e IA em tempo real (Vasilev *et al.*, 2019).

Além disso, o Batch Normalization atua como uma forma de regularização leve, ajudando a combater o *overfitting*, mesmo na ausência de outras técnicas, tais como o Dropout. Ao manter as ativações em uma faixa estatisticamente estável, ele também torna o modelo mais robusto a mudanças nos hiperparâmetros, dentre eles, taxa de aprendizado ou inicialização de pesos. Durante a fase de inferência, ou seja, quando o modelo já está treinado e, assim, é utilizado para fazer previsões, a normalização é realizada com base em estatísticas acumuladas durante o treinamento, como médias e variâncias globais, e não nos dados do *batch* atual. Esse cenário garante tanto a consistência quanto a previsibilidade nos resultados, algo essencial para aplicações em ambientes reais (Vasilev *et al.*, 2019).

EU INDICO

Se você deseja entender melhor o funcionamento da camada Batch Normalization em redes neurais, a documentação oficial do TensorFlow é um ótimo recurso. Ela detalha os parâmetros e as funcionalidades bem como traz exemplos práticos de uso da camada BatchNormalization na biblioteca Keras, mostrando como essa técnica melhora a estabilidade e o desempenho do treinamento.

Mais do que uma melhoria técnica, o uso de Batch Normalization reflete um avanço no desenvolvimento de soluções de inteligência artificial que são cada vez mais estáveis, rápidas e eficazes. Isso tem implicações diretas na sociedade, pois modelos de IA mais robustos e confiáveis estão na base de aplicações importantes em diversas áreas. Na saúde, por exemplo, modelos treinados com essa

técnica podem melhorar o desempenho de sistemas de diagnóstico por imagem, contribuindo para a detecção precoce de doenças, como o câncer. No setor de transportes, especialmente em veículos autônomos, a estabilidade dos modelos é essencial para respostas rápidas e seguras em tempo real.

Em ambientes educacionais, a IA pode adaptar, com mais precisão, conteúdos ao perfil de cada estudante. No setor econômico, empresas conseguem usar redes neurais mais eficazes para prever demandas, otimizar estoques e tomar decisões estratégicas com base em grandes volumes de dados. Dessa forma, o Batch Normalization, embora seja uma técnica interna ao funcionamento das redes neurais, exerce influência direta na eficiência de modelos que impactam a vida cotidiana de milhões de pessoas (Ansolin, 2019).

DROPOUT

Compreender o papel do Dropout no treinamento de redes neurais envolve analisar como essa técnica atua na prevenção do *overfitting*, de que forma é aplicada e quais benefícios ela traz para a construção de modelos mais generalizáveis e eficientes.

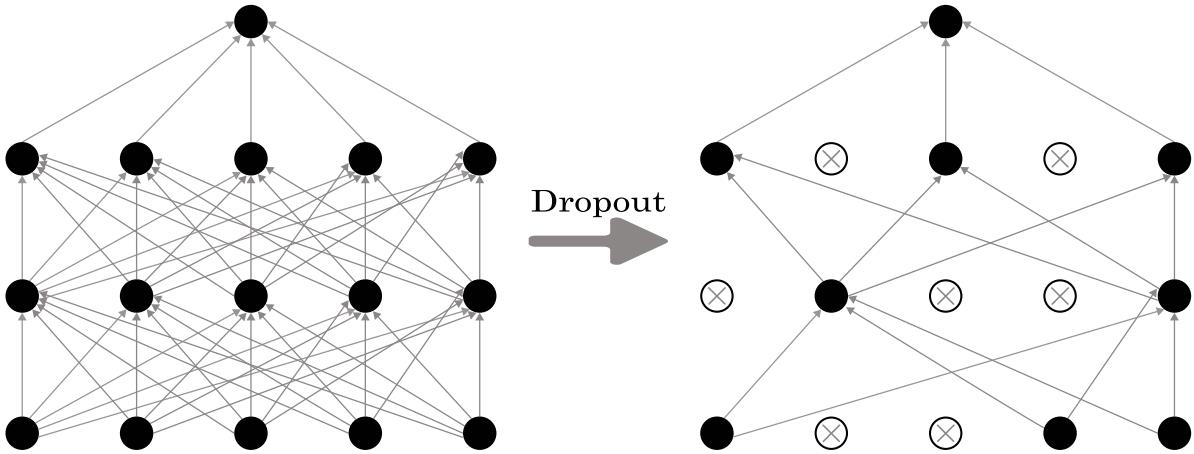

Conceito e funcionamento

Dropout é uma técnica de regularização amplamente utilizada no treinamento de redes neurais, com o principal objetivo de reduzir o *overfitting*, uma situação na qual o modelo se ajusta tão bem aos dados de treinamento que perde a capacidade de generalizar a novos dados.

A essência do Dropout é simples, mas poderosa: durante o treinamento, uma fração dos neurônios de determinadas camadas é desativada aleatoriamente a cada iteração. Esses neurônios "desligados" deixam de participar tanto no cálculo das saídas quanto na atualização dos pesos (Baldi; Sadowski, 2013). Essa exclusão temporária força a rede a não depender excessivamente de caminhos ou neurônios específicos, incentivando o aprendizado de representações mais generalizadas e distribuídas.

De forma prática, o Dropout faz com que o modelo atue como um *ensemble* de várias redes menores, cada uma com uma configuração levemente diferente. Isso contribui diretamente para a robustez do modelo e melhora sua capacidade de adaptação a dados inéditos (Srivastava *et al.*, 2014).

Tecnicamente, a desativação dos neurônios é realizada por meio de uma máscara binária gerada aleatoriamente, aplicada às saídas da camada. Para manter o equilíbrio nas ativações, os neurônios restantes têm seus valores ajustados proporcionalmente, garantindo consistência na propagação da informação. Já durante a fase de inferência, quando o modelo está em uso real, todos os neurônios permanecem ativos, e os pesos são automaticamente escalados para compensar os ajustes feitos durante o treinamento. Ao combater o *overfitting* de maneira direta, o Dropout melhora significativamente a capacidade das redes neurais de generalizar e adaptar-se a diferentes contextos e aplicações do mundo real (Srivastava *et al.*, 2014).

Implementação e impacto

A aplicação do Dropout é direta nas principais bibliotecas de *machine learning*. Em Keras, por exemplo, basta incluir a camada Dropout(rate), onde *rate* indica a fração de neurônios que serão desativados, geralmente, entre 0.2 e 0.5. Em PyTorch, a função nn.Dropout(p) cumpre o mesmo papel.

Normalmente, essa técnica é aplicada após camadas densas (*fully connected*), mas também pode ser utilizada em redes convolucionais, com cuidado, para não comprometer informações espaciais importantes (Jabir; Falih, 2021).

EU INDICO

Se você quer entender o funcionamento da camada Dropout em redes neurais, a documentação oficial do TensorFlow é um excelente ponto de partida. Ela explica como essa técnica atua na regularização dos modelos e fornece exemplos práticos de aplicação com a API do Keras. Acesse:

O impacto do Dropout no desempenho dos modelos é considerável. Ele melhora a capacidade da rede de lidar com dados desconhecidos e reduz a diferença de desempenho entre o treinamento e o teste, o que é essencial em aplicações reais. Essa técnica tem sido especialmente útil em tarefas como classificação de imagens, reconhecimento de voz, processamento de linguagem natural e outros domínios onde a quantidade de dados é grande, mas ainda exista risco de superajuste (Jabir; Falih, 2021).

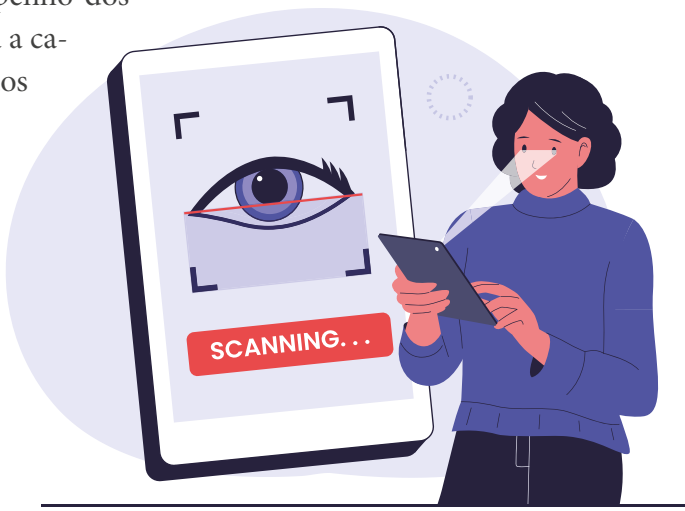

Além dos ganhos técnicos, o uso do Dropout também contribui para tornar os modelos mais confiáveis e adaptáveis, favorecendo a aplicação em cenários do mundo real. Em sistemas de recomendação, por exemplo, modelos mais generalizáveis oferecem sugestões mais precisas. Em diagnósticos médicos baseados em IA, a redução do *overfitting* significa maior segurança na análise de novos exames. Em áreas de segurança e finanças, modelos robustos ajudam a prevenir erros críticos.

OTIMIZANDO REDES NEURAIS: QUANDO USAR BATCH NORMALIZATION OU DROPOUT?

Batch Normalization e Dropout são duas técnicas amplamente utilizadas no treinamento de redes neurais profundas, cada uma com funções e efeitos específicos sobre o desempenho e a generalização dos modelos. Enquanto o Batch Normalization (BN) atua principalmente na normalização das ativações internas da rede, estabilizando o processo de aprendizado, o Dropout tem como principal objetivo reduzir o *overfitting* por meio da regularização (Vasilev *et al.*, 2019).

O Batch Normalization funciona normalizando a saída de cada camada com base na média e desvio padrão do minibatch atual. Essa técnica, introduzida por Ioffe e Szegedy (2015), reduz o chamado *internal covariate shift* — as mudanças nas distribuições internas das ativações — o que permite o uso de taxas de aprendizado maiores e acelera a convergência do treinamento. Por isso, o BN é particularmente indicado em redes profundas, convolucionais e em situações nas quais a estabilidade do treinamento é essencial.

Já o Dropout, proposto por Srivastava *et al.* (2014), atua desligando aleatoriamente uma fração dos neurônios durante cada iteração do treinamento. Essa exclusão temporária força a rede a não depender excessivamente de caminhos específicos, promovendo o aprendizado de representações mais robustas e generalizáveis. Seu uso é especialmente recomendado em redes densas e contextos em que há risco elevado de *overfitting*, como em conjuntos de dados pequenos ou altamente ruidosos.

Uma dúvida comum é se essas técnicas podem ser usadas juntas, e a resposta é sim, mas com ressalvas. Embora não sejam mutuamente exclusivas, seu uso simultâneo exige atenção. Aplicar Dropout logo após o BN pode prejudicar a estabilidade das ativações normalizadas, já que a aleatoriedade introduzida pelo primeiro interfere nas estatísticas do segundo. Em muitos casos, apenas o BN já oferece um efeito regularizador suficiente, tornando o Dropout desnecessário, principalmente em arquiteturas modernas como ResNet, Inception ou Transformers. Ainda assim, quando bem dosados, os efeitos das duas técnicas são complementares: o BN oferece estabilidade e rapidez no treinamento, enquanto o Dropout contribui com a generalização (Li *et al.*, 2019).

Durante a fase de inferência, o comportamento das duas técnicas também difere. O Batch Normalization utiliza as médias e variâncias acumuladas durante o treinamento para manter a previsibilidade, enquanto o Dropout é desativado, com os pesos ajustados proporcionalmente para compensar os neurônios desligados durante a aprendizagem (Li *et al.*, 2019).

A escolha entre Batch Normalization e Dropout, ou o uso combinado, depende do tipo de rede, da tarefa a ser resolvida, do volume de dados e da necessidade de regularização. O conhecimento dessas técnicas permite não somente melhorar o desempenho técnico dos modelos, mas também criar soluções mais eficientes e confiáveis, com impacto direto em aplicações do mundo real, como saúde, transporte, finanças e educação.

A forma resumida com as principais características do Batch Normalization e do Dropout pode ser visualizada, a seguir:

ASPECTO	BATCH NORMALIZATION	DROPOUT
Objetivo	Estabilizar e acelerar o treinamento.	Reduzir overfitting e melhorar generalização.
Quando usar	Treinamento e inferência (com estatísticas acumuladas).	Apenas no treinamento.
Vantagens	Permite maior taxa de aprendizado; acelera convergência.	Força aprendizado redundante; combate dependência excessiva.
Desvantagens	Instabilidade com *batches* pequenos.	Pode exigir mais épocas de treino.
Funcionamento	Normaliza ativações com média e desvio padrão do minibatch.	Desativa aleatoriamente neurônios durante o treinamento.

Quadro 1 – Principais características do Batch Normalization e do Dropout / Fonte: a autora.

PENSANDO JUNTOS

Como garantir que um modelo de IA aprenda equilibradamente e não se confunda com os próprios erros? É aí que entram técnicas como o Batch Normalization e o Dropout. Enquanto o primeiro estabiliza e acelera o aprendizado, mantendo os dados bem distribuídos entre as camadas, o segundo impede que o modelo se torne dependente demais de certas conexões. Juntas, essas técnicas fazem a rede neural aprender de forma mais eficiente, generalize melhor e torne-se mais confiável no uso prático, seja em diagnósticos médicos, seja em tradução automática ou em reconhecimento facial no celular.

APLICAÇÕES PRÁTICAS

Batch Normalization e Dropout são duas técnicas amplamente utilizadas em redes neurais profundas, e a aplicação varia conforme a arquitetura e os objetivos do modelo. Em arquiteturas populares, Li *et al.* (2019) afirmam que essas técnicas são adotadas de maneiras específicas, refletindo suas características estruturais e necessidades particulares.

- Na ResNet (Residual Network), por exemplo, o foco está no uso intensivo do Batch Normalization. Cada bloco residual inclui camadas convolucionais seguidas de BN antes da ativação ReLU. Isso é fundamental para permitir o treinamento estável de redes extremamente profundas, com 50, 101 ou mais camadas. Já o uso do Dropout é raro nessa arquitetura, pois o próprio BN já colabora para uma regularização eficaz.
- Na VGG, uma arquitetura mais simples e sequencial, o Dropout é bastante presente, especialmente nas camadas totalmente conectadas (*fully connected*), com taxas de até 0,5. Em versões mais recentes, como a VGG16-BN, o Batch Normalization foi adicionado para melhorar a estabilidade do treinamento. Aqui, o uso do Dropout é essencial para conter o *overfitting*, devido à densidade e ao grande número de parâmetros da rede.

- A Inception (GoogLeNet) combina ambas as técnicas: o Batch Normalization é utilizado em diversas camadas convolucionais, enquanto o Dropout é aplicado antes da camada final de classificação. Como essa arquitetura é composta por módulos paralelos (os Inception *modules*), ela demanda tanto estabilidade quanto uma forma eficaz de regularização, justificando o uso combinado das técnicas.
- Nas arquiteturas otimizadas para dispositivos móveis, como a MobileNet, o Batch Normalization é amplamente utilizado após cada convolução separável em profundidade. Isso melhora a eficiência do treinamento e garante desempenho adequado com menos recursos computacionais. O Dropout, nesse caso, costuma ser evitado, para preservar a leveza do modelo.
- A DenseNet também é fortemente dependente do Batch Normalization, que é aplicado antes de cada camada convolucional, seguindo o padrão de pré-ativação. O Dropout é raramente usado, porque a própria estrutura densamente conectada, com o BN, favorece uma boa propagação de gradientes e estabilidade no treinamento.
- Por fim, em arquiteturas voltadas para processamento de linguagem natural, como os Transformers, o Batch Normalization é substituído por Layer Normalization, que se adapta melhor a dados sequenciais. O Dropout, no entanto, continua muito utilizado, especialmente após camadas de atenção e *feedforward*, atuando como principal regularizador em modelos grandes, como o BERT e o GPT.

O uso de Batch Normalization e Dropout não é universal nem aleatório: ele é cuidadosamente ajustado conforme a estrutura e a finalidade de cada arquitetura. Essa combinação estratégica é um dos fatores que permite o sucesso de redes neurais modernas em tarefas complexas, desde o reconhecimento de imagens até a geração de linguagem natural.

Vale destacar que, diferentemente do Batch Normalization — o qual normaliza as ativações com base no *minibatch* — o Layer Normalization atua normalizando cada instância individualmente ao longo das suas dimensões, sendo mais adequado para arquiteturas como Transformers, onde o tamanho do *batch* pode variar ou ser igual a 1.

EM FOCO

Confira a aula referente a este tema. **Recursos de mídia disponíveis no conteúdo digital do ambiente virtual de aprendizagem**.

NOVOS DESAFIOS

No ambiente profissional, a capacidade de transformar conhecimento teórico em soluções eficientes é um diferencial. Para aqueles que desejam atuar na área de IA e aprendizado de máquina, entender como tornar modelos mais estáveis e adaptáveis é essencial. A normalização e a regularização, exploradas durante o aprendizado, são ferramentas valiosas para enfrentar desafios reais no mercado de trabalho.

Nos setores de saúde, finanças e tecnologia, empresas dependem de modelos de IA para tomar decisões importantes, no entanto, se esses modelos não forem treinados corretamente, podem apresentar falhas graves, como diagnosticar erroneamente uma doença ou prever imprecisamente riscos financeiros. O mercado exige profissionais que saibam equilibrar a capacidade de aprendizado de um modelo sem comprometer a confiabilidade dele.

A prática dessas técnicas também impacta diretamente a eficiência operacional. Um modelo bem ajustado economiza tempo e recursos computacionais, algo essencial em empresas que lidam com grandes volumes de dados. Isso significa que o conhecimento de normalização e regularização não é apenas uma questão acadêmica, mas uma habilidade prática valorizada pelas empresas.

Olhar para o futuro do mercado também é fundamental. O crescimento do uso de IA exige profissionais que saibam treinar modelos, mas também compreendam como evitar armadilhas comuns e melhorem continuamente os processos. A pergunta que fica é: como você pode aplicar esse conhecimento para resolver problemas reais e destacar-se em sua carreira?

1. Em treinamentos de redes neurais, é comum modelos muito complexos aprenderem padrões tão específicos dos dados de entrada que se tornam pouco eficazes em situações novas. Para lidar com esse problema, diversas técnicas têm sido desenvolvidas para tornar os modelos mais robustos e capazes de generalizar. Uma dessas estratégias envolve a desativação temporária de certas partes da rede durante o aprendizado, incentivando o modelo a não depender excessivamente de nenhum neurônio isolado (Baldi; Sadowski, 2013).

   Com base nesse contexto, assinale a alternativa correta:

   a) A técnica citada consiste em desativar permanentemente parte dos neurônios, reduzindo o tamanho da rede e economizando memória computacional.
   b) Essa técnica é aplicada apenas durante a fase de testes, para avaliar o comportamento da rede em condições limitadas.
   c) A estratégia mencionada contribui para a redução do sobreajuste, incentivando o modelo a aprender de forma mais distribuída e menos dependente de conexões específicas.
   d) A desativação dos neurônios durante o treinamento tem como principal objetivo acelerar o processamento pela redução do número de cálculos.
   e) O objetivo da técnica é substituir neurônios defeituosos automaticamente, garantindo maior tolerância a falhas de hardware.

2. O Batch Normalization (BN) é uma técnica amplamente utilizada em redes neurais profundas não apenas para acelerar o treinamento, mas também como uma forma de regularização leve. Ele atua estabilizando as ativações das camadas intermediárias, o que contribui para um treinamento mais robusto e previsível. Durante a inferência, o comportamento do BN muda ligeiramente em relação ao treinamento, utilizando estatísticas globais em vez de dados do lote atual (Vasilev *et al.,* 2019).

   Com base nessas informações, analise as afirmativas, a seguir:

   I - O Batch Normalization só é eficaz quando usado com o Dropout, pois, sozinho, não consegue contribuir para a generalização do modelo.
   II - Durante a fase de inferência, o Batch Normalization continua utilizando os dados do *batch* atual para normalizar as ativações, o que garante uma adaptação contínua do modelo aos novos dados.
   III - O uso do Batch Normalization contribui para a estabilidade do modelo em relação à taxa de aprendizado e à inicialização dos pesos, tornando o treinamento mais confiável.
   IV - O Batch Normalization ajuda a reduzir o *overfitting*, mesmo na ausência de técnicas como Dropout, funcionando como uma forma de regularização leve.

É correto o que se afirma em:

a) I, apenas.
b) II e IV, apenas.
c) III e IV, apenas.
d) I, II e III, apenas.
e) I, II, III e IV.

3. No setor da saúde, o uso de redes neurais profundas tem se mostrado promissor em aplicações como análise de exames de imagem. A construção desses modelos, no entanto, exige não somente uma base de dados adequada, mas também o emprego de técnicas que favoreçam sua capacidade de generalização. Essa característica é especialmente importante em contextos clínicos, nos quais erros de predição podem ter implicações sérias (Ansolin, 2019).

Com base nas informações apresentadas, avalie as asserções, a seguir, e a relação proposta entre elas:

I - O uso de técnicas de regularização, como o Dropout, ajuda os modelos de *deep learning* a manterem uma boa capacidade de generalização, reduzindo o risco de sobreajuste aos dados de treinamento.

PORQUE

II - Em aplicações clínicas, como o diagnóstico por imagem, a capacidade do modelo de generalizar para novos exames é essencial, a fim de garantir que ele funcione bem com pacientes diferentes dos usados no treinamento.

A respeito dessas asserções, assinale a alternativa correta:

a) As asserções I e II são verdadeiras, e a II é uma justificativa correta da I.
b) As asserções I e II são verdadeiras, mas a II não é uma justificativa correta da I.
c) A asserção I é uma proposição verdadeira, e a II é uma proposição falsa.
d) A asserção I é uma proposição falsa, e a II é uma proposição verdadeira.
e) As asserções I e II são falsas.

REFERÊNCIAS

ANSOLIN, L. L. **Sistema computacional para detecção automática de doenças na produção de uva utilizando redes neurais convolucionais**. 2019. 44 f. Trabalho de Conclusão de Curso (Bacharelado em Engenharia de Computação) – Universidade Estadual do Rio Grande do Sul, Guaíba, 2019.

BALDI, P.; SADOWSKI, P. J. Understanding dropout. *In:* NEURIPS – ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS, 26., Lake Tahoe. 2013. **Proceedings** [...]. Lake Tahoe: NeurIPS, 2013.

BJORCK, N. *et al.* Understanding batch normalization. *In:* NEURIPS – ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS, 32., 2018, Montreal. **Proceedings** [...]. Montreal: NeurIPS, 2018.

IOFFE, S.; SZEGEDY, C. Batch normalization: Accelerating deep network training by reducing internal covariate shift. *In:* INTERNATIONAL CONFERENCE ON MACHINE LEARNING, 32., 2015, Lille. **Proceedings** [...]. Lille: PMLR, 2015. p. 448-456.

JABIR, B.; FALIH, N. Dropout, a basic and effective regularization method for a deep learning model: A case study. **Indonesian Journal of Electrical Engineering and Computer Science**, v. 24, n. 2, p. 1009-1016, 2021.

LI, X. *et al.* Understanding the disharmony between dropout and batch normalization by variance shift. *In:* CVPR – CONFERENCE ON COMPUTER VISION AND PATTERN RECOGNITION, 2019. Long Beach. **Proceedings** [...]. Long Beach: IEEE, CVF, 2019. p. 2682-2690.

MENDONÇA, M. M. **Comparação entre métodos de normalização de iluminação utilizados para melhorar a taxa do reconhecimento facial**. 2008. 125 f. Dissertação (Mestrado em Engenharia Elétrica) – Escola de Engenharia de São Carlos, Departamento de Engenharia Elétrica, Universidade de São Paulo, São Carlos, 2008.

PHAISANGITTISAGUL, E. An analysis of the regularization between L2 and dropout in single hidden layer neural network. *In:* ISMS – INTERNATIONAL CONFERENCE ON INTELLIGENT SYSTEMS, MODELLING AND SIMULATION. 7., 2016, Bangkok. **Proceedings** [...]. Bangkok: IEEE, 2016. p. 174-179.

SRIVASTAVA, N. *et al.* Dropout: a simple way to prevent neural networks from overfitting. **The Journal of Machine Learning Research**, v. 15, n. 1, p. 1929-1958, 2014.

VASILEV, I. et al. **Python deep learning**: exploring deep learning techniques and neural network architectures with Pytorch, Keras, and TensorFlow. 2nd. ed. Birmingham: Packt Publishing, 2019.

CONFIRA SUAS RESPOSTAS

1. Alternativa C.

   Essa alternativa descreve corretamente o objetivo do Dropout: reduzir o *overfitting* ao incentivar o aprendizado mais distribuído.
   A alternativa A está incorreta, pois o Dropout não desativa neurônios permanentemente, apenas os desliga temporariamente durante o treinamento.
   A alternativa B está incorreta, pois o Dropout é aplicado apenas na fase de treinamento, e não durante os testes.
   A alternativa D está incorreta, pois o objetivo principal do Dropout não é acelerar o processamento, mas sim melhorar a generalização da rede.
   A alternativa E está incorreta, pois o Dropout não trata de falhas de hardware, e sim de regularização durante o treinamento da rede neural.

2. Alternativa C.

   A afirmativa I está incorreta, pois o texto afirma que o Batch Normalization atua como uma forma de regularização leve, sendo eficaz mesmo na ausência de Dropout. Portanto, dizer que ele só é eficaz com Dropout está incorreto, por si só o Batch Normalization já contribui para a generalização do modelo.
   A afirmativa II está incorreta, pois, durante a fase de inferência, não são utilizados os dados do *batch* atual para normalização. O texto é claro ao dizer que o BN usa estatísticas acumuladas (médias e variâncias globais) durante o treinamento, garantindo consistência nos resultados em produção.
   A afirmativa III está correta, pois, segundo o texto, o Batch Normalization ajuda a estabilizar o treinamento, tornando o modelo mais robusto a variações na taxa de aprendizado e na inicialização dos pesos. Isso torna o processo de aprendizado mais confiável e menos sensível a ajustes finos.
   A afirmativa IV está correta, pois o texto afirma que o BN ajuda a reduzir o *overfitting*, funcionando como uma forma de regularização leve. Essa contribuição ocorre mesmo sem outras técnicas, como o Dropout, o que reforça sua utilidade na construção de modelos generalizáveis.

3. Alternativa A.

A asserção I está correta, pois o Dropout é uma técnica de regularização que desativa aleatoriamente uma fração dos neurônios durante o treinamento, consequentemente, força a rede a não depender excessivamente de conexões específicas. Isso ajuda a evitar o *overfitting* e melhora a generalização do modelo, ou seja, sua capacidade de performar bem em dados novos e não vistos anteriormente.
A asserção II também está correta, pois, em contextos médicos, como no diagnóstico por imagem — mamografias, tomografias, ressonâncias — é essencial que o modelo funcione bem com diferentes pacientes e exames, o que exige boa generalização.
A II justifica a I: mostra a importância prática do Dropout em cenários clínicos: o uso dessa técnica favorece a robustez e confiabilidade do modelo em aplicações reais, onde os dados de entrada variam bastante.

MEU ESPAÇO

Unicesumar

unidade 3

TEMA DE APRENDIZAGEM 4

LENET E AS PRIMEIRAS CNN

MINHAS METAS

- Compreender a motivação histórica para o desenvolvimento da LeNet.
- Descrever detalhadamente a arquitetura LeNet-5.
- Apresentar a LeNet como pioneira das CNN.
- Analisar os principais desafios técnicos enfrentados no desenvolvimento da LeNet.
- Identificar as principais inovações introduzidas pela LeNet.
- Comparar a LeNet com arquiteturas modernas de CNN.
- Refletir sobre a contribuição da LeNet para o avanço da *deep learning*.

INICIE SUA JORNADA

Hoje em dia, é comum vermos celulares que desbloqueiam a tela pela identificação do rosto do usuário, carros que "enxergam" o caminho e até sistemas que reconhecem placas ou documentos automaticamente. Mas como as máquinas aprenderam a fazer isso? Como se iniciou essa ideia de ensinar computadores a identificar imagens? Entender esse ponto de partida ajuda a perceber o quanto a tecnologia evoluiu e como essa evolução conecta-se com as profissões do presente e do futuro.

Lá pelos anos 1990, quando a internet ainda engatinhava, um pesquisador chamado Yann LeCun criou um modelo chamado LeNet. Esse modelo foi usado para algo simples, mas muito importante na época: ler números escritos à mão, como os que aparecem em cheques. Pode parecer básico hoje, mas foi um dos primeiros passos para fazer as máquinas reconhecerem imagens. Para quem está estudando ou entrando no mundo da tecnologia, saber de onde veio essa ideia ajuda a entender melhor como as soluções atuais foram construídas.

Mesmo sem se aprofundar nos detalhes, é possível experimentar como esse tipo de sistema funciona. Existem sites e ferramentas onde é possível verificar, visualmente, como uma imagem é analisada gradualmente até ser identificada. Essa vivência prática, mesmo simples, já traz uma noção de como as máquinas aprendem com exemplos, e nos ajuda a conectar o aprendizado com situações reais. Conhecer essa história nos faz pensar em como as grandes mudanças tecnológicas começaram com ideias simples e muita persistência. Naquela época, os recursos eram poucos, e nem todo mundo acreditava dariam certo. Hoje, temos muito mais ferramentas, acesso à informação e possibilidades. Entender como tudo começou inspira a criar, inovar e usar a tecnologia para resolver problemas reais. Esse é um dos principais papéis de quem está se formando nessa área.

PLAY NO CONHECIMENTO

Você sabia que uma tecnologia criada há mais de 30 anos está ajudando agricultores na Nigéria a salvar plantações de inhame por meio da IA? Nesse podcast, conheça como a LeNet-5 — uma das primeiras redes de reconhecimento de imagem — foi adaptada para transformar a agricultura e a vida de comunidades rurais. Dê o play e venha descobrir como o passado está ajudando a construir o futuro. **Recursos de mídia disponíveis no conteúdo digital do ambiente virtual de aprendizagem.**

VAMOS RECORDAR?

Imagine que você tem uma grande quantidade de números escritos à mão em pedaços de papel, e precisa organizá-los rapidamente. Em vez de escrever cada número manualmente em um computador, usa a LeNet-5, uma "ferramenta inteligente" que ajuda o computador a reconhecer esses números automaticamente. Assim como você que, ao olhar para um número escrito à mão, o identifica rapidamente (ex.: "3" ou "9"), a LeNet-5 também consegue fazer isso. Ela "olha" para a imagem do número e, por meio de camadas de filtros, encontra detalhes, como formas e linhas, que o fazem se destacar. À medida que a LeNet-5 passa por essas camadas, ela fica mais precisa em reconhecer os numerais, mesmo que a escrita não seja perfeita ou o número esteja um pouco distorcido. Esse processo foi um dos primeiros sucessos das CNN, e a LeNet-5 foi pioneira nisso. Acesse:

DESENVOLVA SEU POTENCIAL

FUNDAMENTOS HISTÓRICOS E USO INICIAL DA LENET

Nos anos 1980 e 1990, a inteligência artificial (IA) passava por um período de muitos avanços teóricos, mas com sérias limitações práticas. A principal barreira era o hardware: os computadores da época tinham baixa capacidade de processamento e pouca memória, dificultando o treinamento de modelos complexos, como redes neurais profundas. Além disso, o entusiasmo com as redes neurais vinha diminuindo em um período conhecido como o **inverno da IA**, no qual tanto o interesse acadêmico quanto os investimentos no setor foram reduzidos drasticamente (Goodfellow; Bengio; Courville, 2016).

Foi nesse cenário desafiador que Yann LeCun, cientista da computação francês, desempenhou um papel crucial. Trabalhando com redes neurais no final dos anos 1980, ele desenvolveu, em 1989, a LeNet-5, uma das primeiras arquiteturas de redes neurais convolucionais (CNN) (LeCun *et al.*, 1989).

VOCÊ SABE RESPONDER?

Mas, afinal, por que a LeNet-5 surgiu?

A resposta está em um problema bastante concreto da época: o reconhecimento automático de dígitos manuscritos em cheques bancários. A automação desse processo era urgente, pois os métodos manuais eram lentos, caros e propensos a erros. Esse cientista e sua equipe buscaram uma solução prática, e assim nasceu a LeNet-5.

LeNet refere-se, no entanto, a uma família de redes neurais desenvolvida por Yann LeCun. As versões iniciais, como a LeNet-1 e LeNet-2, foram criadas no final dos anos 1980 e início dos anos 1990. Essas primeiras versões tinham um foco mais exploratório no uso de CNN para tarefas simples de reconhecimento de padrões, mas a LeNet-5 representou um avanço ao adicionar mais camadas e um foco específico no reconhecimento de dígitos manuscritos (LeCun *et al.*, 1989).

EU INDICO

Se você deseja entender melhor a evolução da arquitetura LeNet e como ela influenciou o desenvolvimento das CNN, leia o artigo da Wikipedia sobre a **LeNet**. Ele oferece uma visão detalhada da história, da estrutura e do impacto dessa arquitetura, desde suas primeiras versões até as contribuições que ela fez aos campos da visão computacional e do aprendizado de máquina. Acesse:

Apesar das limitações tecnológicas, a LeNet-5 mostrou que redes neurais poderiam funcionar muito bem em tarefas de reconhecimento visual. Para seu treinamento, foi utilizado o *dataset* MNIST, uma base de dados com milhares de imagens de dígitos manuscritos, padronizadas para facilitar o aprendizado da rede. Essa base até hoje é amplamente usada como referência em testes de classificação de imagens (LeCun *et al.*, 1989).

a LeNet-5 mostrou que redes neurais poderiam funcionar muito bem em tarefas de reconhecimento visual

A criação de um sistema automático como a LeNet-5 representou um avanço comercial. Ela reduziu custos operacionais, aumentou a velocidade do processamento e elevou a precisão na leitura de dados. Mais do que isso, pavimentou o caminho para aplicações futuras da visão computacional, que hoje se estendem à medicina, à segurança, ao varejo e muito mais.

O reconhecimento do trabalho de LeCun cresceu nos anos 2000, quando os avanços em hardware, especialmente o uso de GPU, e a disponibilidade de grandes volumes de dados possibilitaram treinar, com muito mais eficiência, redes neurais ainda mais profundas.

A ARQUITETURA DA LENET-5

A arquitetura de uma rede neural, por exemplo, a LeNet-5, pode ser entendida como o **"esqueleto"** de um sistema de aprendizado que ajuda um computador a realizar tarefas específicas, entre elas, reconhecer imagens.

Assim como o corpo humano possui diferentes partes que desempenham funções essenciais, a arquitetura de uma rede neural é composta por várias **"camadas"**, e cada uma delas tem uma tarefa única para ajudar o computador a entender e processar as informações.

A arquitetura da LeNet-5 é composta por **sete camadas**, cada uma com uma função específica, organizadas para extrair informações progressivamente e classificar imagens de maneira eficiente (Pan; Luo; Zhou, 2022). A seguir, exploraremos cada uma dessas camadas.

PRIMEIRA CAMADA CONVOLUCIONAL (C1)

É responsável por identificar características iniciais da imagem, como bordas e texturas. Imagine que você tem uma imagem de um número manuscrito, por exemplo, "7". A C1 procurará por padrões simples, como linhas horizontais e verticais, que formam esse número. A camada aplica seis filtros, ou *kernels*, que são pequenos pedaços da imagem (ex.: 5x5 pixels). Cada filtro "escaneia" a imagem em busca de padrões específicos. O resultado de cada escaneamento cria um "mapa de características", uma versão simplificada da imagem, destacando certos detalhes, como bordas e contornos.

PRIMEIRA CAMADA DE SUBAMOSTRAGEM (S2)

Após a C1, temos uma camada de subamostragem, também chamada de *pooling*. Ela possibilita reduzir a resolução dos mapas de características, ou seja, diminui a quantidade de informações para facilitar o processamento e tornar o modelo mais eficiente. A camada S2 faz isso ao tomar pequenos grupos de pixels do mapa de características e tirar a média ou o valor máximo dentro desse grupo, dependendo do tipo de *pooling*. Por exemplo, ela pode tomar 2x2 pixels e calcular a média, assim, cria uma versão mais compacta e menos detalhada dos dados, mantendo as informações essenciais.

SEGUNDA CAMADA CONVOLUCIONAL (C3)

Agora, a rede começa a procurar padrões mais complexos nas imagens. A segunda camada convolucional tem a função de identificar formas ou objetos mais definidos, como curvas ou padrões combinados. A C3 aplica 16 filtros sobre os mapas de características que passaram pela S2. Isso ajuda a rede a entender padrões mais elaborados, por exemplo, a combinação de bordas ou partes específicas que formam letras e números. Cada filtro é como uma "lupa" que observa partes mais complexas da imagem.

SEGUNDA CAMADA DE SUBAMOSTRAGEM (S4)

Assim como a primeira camada de subamostragem (S2), a segunda camada de *pooling* (S4) tem o objetivo de reduzir ainda mais a quantidade de dados, porém, ela mantém as informações mais significativas para garantir que o modelo continue aprendendo e funcionando. A S4 segue o mesmo processo de redução de resolução, ao aplicar uma operação de média ou valor máximo em grupos de pixels. Com isso, a rede consegue diminuir a complexidade dos dados sem perder informações importantes.

CAMADA TOTALMENTE CONECTADA (C5)

Após extrair e reduzir as informações das imagens, a camada C5 começa a "entender" os padrões de forma mais abstrata. Ela é chamada de camada totalmente conectada porque todos os neurônios dela estão conectados a todos os neurônios da camada anterior. A C5 possui 120 neurônios, responsáveis por combinar as informações extraídas pelas camadas anteriores, como bordas, texturas e formas, e transformar tudo isso em uma representação mais complexa. Agora, a rede começa a aprender como as partes da imagem se encaixam para formar um todo. Por exemplo, reconhecer que as bordas formam o número "7".

CAMADA DE SAÍDA (F6)

A camada F6 é uma continuação da camada C5, mas com menos neurônios (84 neurônios, no caso). Ela faz a classificação final, agrupando as informações processadas nas camadas anteriores e "decidindo" qual é a categoria ou classe da imagem. O trabalho da camada F6 é fazer a associação final entre a imagem e suas possíveis categorias. Por exemplo, ela pode determinar se a imagem é do número "7" ou "4", dependendo das características extraídas ao longo da rede.

CAMADA *SOFTMAX*

Finalmente, a camada *softmax* pega o resultado da camada de saída (F6) e transforma esse resultado em uma probabilidade, ou seja, ela mostra a chance de a imagem pertencer a cada uma das categorias possíveis. Se a rede estiver tentando identificar números de 0 a 9, a camada Softmax gera 10 valores, um para cada número. Esses valores indicam a probabilidade de a imagem representar "0", "1", "2", e assim por diante. O número com a maior probabilidade será a escolha final da rede, isto é, a classificação da imagem.

A arquitetura da LeNet-5 é uma abordagem inovadora e eficiente, que permite a classificação precisa de imagens mesmo em ambientes com recursos limitados. Ao combinar camadas convolucionais, de ***pooling* e totalmente conectadas**, a LeNet-5 foi projetada para extrair características progressivamente, desde os padrões mais simples até as representações mais complexas, culminando na classificação final.

Sua estrutura robusta e bem definida não só estabeleceu um marco importante no campo das redes neurais, como também influenciou o desenvolvimento de tecnologias modernas de visão computacional, sendo um precursor fundamental para muitas das redes mais avançadas que utilizamos hoje.

EU INDICO

Para entender melhor o funcionamento da arquitetura *LeNet-5*, o artigo *LeNet-5: A Classic CNN Architecture*, no Data Science Central, é uma excelente fonte de aprendizado. Ele oferece uma explicação detalhada sobre a estrutura e o impacto dessa arquitetura no reconhecimento de padrões, além de discutir a implementação prática dela. Acesse:

REVOLUÇÃO NA VISÃO COMPUTACIONAL: CARACTERÍSTICAS INOVADORAS DA LENET-5

A LeNet-5 trouxe várias inovações que tiveram forte impacto no campo da visão computacional e do aprendizado de máquina. Algumas dessas inovações são especialmente importantes, pois permitiram que redes neurais fossem mais eficazes em tarefas de reconhecimento de imagens e usadas em uma variedade de aplicações (LeCun; Bengio, 1995). Vamos explorar essas inovações e sua importância?

USO DE CONVOLUÇÕES COM PESOS COMPARTILHADOS

A convolução é um processo em que um filtro, ou *kernel*, passa por uma imagem para detectar padrões, como bordas ou texturas. O conceito de pesos compartilhados significa que o mesmo filtro é usado em diferentes partes da imagem, ajudando a reduzir a quantidade de cálculos e parâmetros que a rede precisa aprender. Essa ação tornou as redes neurais mais eficientes e menos propensas a erros de *overfitting* (quando o modelo se ajusta demais aos dados de treinamento).

EXTRAÇÃO AUTOMÁTICA DE CARACTERÍSTICAS

A LeNet-5 foi uma das primeiras a demonstrar que redes neurais podem extrair características automaticamente de uma imagem, sem a necessidade de intervenção humana. Isso significa que a rede pode aprender a identificar características importantes, como bordas, formas e texturas, a partir dos dados de entrada diretamente.

REDUÇÃO DE DIMENSIONALIDADE COM *POOLING*

O *pooling* é uma técnica usada para reduzir a resolução das imagens de forma controlada, mantendo as informações mais importantes. Essa ação torna o modelo mais rápido e menos exigente em termos de computação, além de evitar o *overfitting*.

ARQUITETURA SIMPLES, PORÉM EFICAZ PARA PROBLEMAS VISUAIS

A arquitetura da LeNet-5 foi projetada para ser relativamente simples, mas muito eficaz. Sua combinação de camadas convolucionais e de *pooling*, seguidas por camadas totalmente conectadas, proporcionou uma abordagem poderosa para problemas de reconhecimento de imagem.

A LeNet-5 é como um sistema inteligente que aprende a identificar objetos em imagens, processando apenas as informações mais importantes para tornar o reconhecimento rápido e eficiente. Inspirada no funcionamento do cérebro humano, essa CNN analisa as imagens em etapas, começando por detalhes simples — linhas, bordas e texturas — e, aos poucos, constrói uma compreensão mais complexa do que está sendo visto (LeCun; Bengio, 1995).

PENSANDO JUNTOS

Como ensinar uma máquina tal qual a LeNet-5 a enxergar imagens e reconhecer o que vê, assim como fazemos naturalmente? Pense na LeNet-5 enquanto um sistema de câmeras de segurança inteligente. Quando uma imagem chega, ela começa observando detalhes simples, como linhas e formas. A cada camada, foca nos elementos mais importantes, a exemplo de quem olha uma cena e vai direto ao que importa. A LeNet-5 extrai os aspectos essenciais e reduz o volume de dados, mantendo só o necessário. No final, aprende a reconhecer padrões, por exemplo, rostos e objetos, com rapidez e precisão. Assim como nossos olhos e cérebro trabalham juntos, essa arquitetura entende imagens eficientemente. Ela é a base das tecnologias de leitura automática, filtros de redes sociais e carros autônomos.

DESAFIOS TÉCNICOS E CIENTÍFICOS NA CRIAÇÃO DA LENET-5

Durante o desenvolvimento da LeNet-5, Yann LeCun e sua equipe enfrentaram uma série de desafios técnicos e teóricos. Um dos maiores obstáculos foi a falta de poder computacional, pois, na década de 1990, os computadores não tinham o poder de processamento necessário para treinar redes neurais profundas. As GPU, atualmente essenciais ao treinamento eficiente de redes neurais, ainda não estavam disponíveis, e o processo de treinamento era extremamente lento e limitado pela capacidade dos processadores da época (LeCun *et al.*, 1998).

Outro desafio importante foi o problema do ***overfitting***, ou seja, quando um modelo se ajusta excessivamente aos dados de treinamento e não generaliza bem para novos dados. Visando evitar esse problema, LeCun e sua equipe precisaram de técnicas de regularização e de uma arquitetura que conseguisse

extrair características robustas sem se tornar excessivamente complexa. O treinamento de redes neurais na época era uma tarefa difícil e demorada, o que limitava os testes e ajustes da arquitetura.

Além desses desafios, a falta de *datasets* (conjunto de dados) padronizados também foi um problema. Enquanto hoje temos grandes bases de dados como o MNIST, amplamente usadas para treinamento de redes neurais, na época, o acesso a *datasets* de imagens rotuladas era limitado. Foi necessário criar e estruturar os dados manualmente, o que consumia tempo e recursos.

Ademais, havia um ceticismo significativo na comunidade científica em relação ao uso de redes neurais profundas. Durante o chamado "inverno da IA", a pesquisa em redes neurais estava em declínio, devido ao fracasso das primeiras tentativas de redes muito profundas e ao desprezo por modelos que não mostravam resultados concretos. Muitos viam as redes neurais como uma abordagem falha para problemas de aprendizado de máquina, e a LeNet-5 desafiou essa visão, provando que as redes convolucionais poderiam, de fato, ser aplicadas com sucesso.

DO PASSADO AO FUTURO: COMO A LENET-5 MOLDOU AS REDES NEURAIS DE HOJE

A LeNet-5 marcou um ponto de inflexão no campo da visão computacional, representando o primeiro uso prático bem-sucedido de Redes Neurais Convolucionais (CNN). Sua aplicação comercial introdutória — o reconhecimento de dígitos manuscritos em cheques bancários nos Estados Unidos — foi revolucionária, solucionando um problema real que, até então, era processado manualmente.

O uso de CNN para automação dessa tarefa aumentou a velocidade e a precisão, além de reduzir custos operacionais consideráveis (LeCun *et al.*, 1998).

> Esse avanço abriu portas para a evolução das redes neurais e influenciou o desenvolvimento de arquiteturas modernas de aprendizado profundo. Arquiteturas como AlexNet, VGG e ResNet, que se tornaram referências na visão computacional, têm raízes no trabalho inicial da LeNet-5. Embora essas redes sejam mais profundas e complexas, seus princípios fundamentais — o uso de camadas convolucionais para extração de características e camadas totalmente conectadas para classificação — foram fortemente inspirados na LeNet-5 (Goodfellow; Bengio; Courville, 2016).

Em comparação com as arquiteturas mais modernas, como AlexNet e VGG, a LeNet-5 destaca-se por sua simplicidade. Ela possui uma profundidade menor e menos camadas, refletindo as limitações do hardware da época. Enquanto a LeNet-5, contudo, utiliza funções de ativação — a **sigmoide** ou **tanh** — redes modernas, como AlexNet, passaram a adotar funções ReLU (Rectified Linear Unit), que ajudam a acelerar o treinamento. Técnicas mais avançadas, tais quais Dropout, Batch Normalization e otimização com GPU, são, agora, comuns em modelos contemporâneos, resultando em redes mais profundas e robustas.

Mesmo com essas diferenças, a LeNet-5 foi fundamental para o desenvolvimento das arquiteturas modernas, e seu impacto continua a ser sentido como a base que impulsionou avanços significativos na evolução das redes convolucionais. Sua simplicidade, combinada com sua eficácia, estabeleceu o padrão para redes convolucionais modernas, permitindo avanços significativos em diversas áreas, entre elas, reconhecimento de objetos, diagnóstico médico e até mesmo veículos autônomos (Goodfellow; Bengio; Courville, 2016).

EM FOCO

Confira a aula referente a este tema. **Recursos de mídia disponíveis no conteúdo digital do ambiente virtual de aprendizagem.**

NOVOS DESAFIOS

A teoria por trás da LeNet-5 serve como alicerce para a criação de sistemas autônomos capazes de realizar tarefas complexas. Na prática, esses conceitos transformam-se em soluções reais com impacto significativo em diversos setores. A LeNet-5 é usada para classificar imagens e identificar padrões em grandes volumes de dados, facilitando a tomada de decisões em tempo real. Essa característica conecta-se diretamente ao mercado de trabalho, onde a aplicação de IA em tarefas cotidianas está crescendo rapidamente, por exemplo, no diagnóstico médico, no reconhecimento de voz e na análise de grandes bases de dados.

Na saúde, a LeNet-5 tem muito potencial ao ser aplicada na análise de imagens médicas, como radiografias e tomografias. Ela pode detectar sinais precoces de doenças — câncer de pulmão, fraturas ósseas e até doenças oculares — proporcionando diagnósticos mais rápidos e precisos.

Na educação, essa arquitetura pode ser usada para personalizar a experiência de aprendizado, por meio da adaptação do conteúdo às necessidades de cada aluno. Plataformas inteligentes podem analisar o desempenho dos estudantes em tempo real, ajustando exercícios e oferecendo *feedback* instantâneo.

Em **segurança pública**, a LeNet-5 pode ser empregada no reconhecimento de padrões em vídeos de câmeras de vigilância, mediante identificação de comportamentos suspeitos, ou no rastreamento de objetos, ou pessoas, em tempo real.

No **setor cinematográfico e de jogos**, ela pode ser utilizada para automação da classificação de cenas, reconhecimento de objetos e até mesmo melhoria dos efeitos visuais. Tais ações aceleram a produção bem como otimizam a experiência do usuário final.

No **setor de transporte**, especialmente em sistemas de monitoramento de tráfego, a LeNet-5 ajuda a identificar padrões de tráfego, prever congestionamentos e analisar incidentes, proporcionando uma gestão mais eficiente das vias públicas.

Em **ciência ambiental**, ela pode ser aplicada no monitoramento de desmatamento e mudanças climáticas, por meio da análise de imagens de satélite, o que permite uma resposta mais rápida às questões ambientais.

Esses exemplos mostram como gerar soluções inovadoras que atendem às necessidades reais em diversas áreas.

No **ambiente profissional**, o conhecimento profundo dessas tecnologias e a habilidade de aplicá-las para resolver problemas específicos são cruciais ao sucesso. À medida que o mercado de trabalho continua a se transformar com o avanço da IA, os profissionais que dominam essas ferramentas, como a LeNet-5, estarão mais preparados para enfrentar os desafios e aproveitar as oportunidades que surgem em saúde, educação, agronegócio, segurança pública ou em qualquer outro setor.

VAMOS PRATICAR

1. Durante os primeiros anos do desenvolvimento de redes neurais, criar modelos que pudessem lidar com dados visuais eficientemente ainda era um desafio. A introdução da LeNet-5 marcou um avanço importante, ao apresentar uma arquitetura capaz de extrair automaticamente características relevantes de imagens e realizar classificações de maneira eficiente. Essa rede pioneira mostrou que era possível treinar máquinas para interpretar, com alta precisão, padrões complexos, inaugurando práticas e conceitos que seriam a base das CNN modernas (LeCun *et al.*, 1989).

   Com base no texto, qual alternativa descreve corretamente o motivo do surgimento da LeNet-5?

   a) Melhorar a velocidade de processamento de imagens em jogos de videogame.
   b) Estudar, como ferramenta acadêmica, as redes neurais profundas, sem aplicações práticas no início.
   c) Resolver o problema prático de reconhecer dígitos manuscritos em cheques bancários, automatizando um processo manual e ineficiente.
   d) Substituir sistemas de segurança baseados em reconhecimento facial.
   e) Apenas classificar imagens médicas em diagnósticos hospitalares.

2. A LeNet-5 funciona como um sistema inteligente que aprende a identificar objetos em imagens, focando apenas nas informações mais relevantes para tornar o processo de reconhecimento mais rápido e eficiente. Com inspiração no funcionamento do cérebro humano, essa CNN examina as imagens em diferentes etapas, mediante análise de linhas e bordas, e, gradualmente, constrói uma percepção mais detalhada e complexa do conteúdo visual (LeCun; Bengio, 1995).

   Com base no texto, qual alternativa descreve corretamente o funcionamento da LeNet-5?

   a) Analisa as imagens de forma direta, sem a necessidade de decompor as informações em etapas.
   b) Processa as imagens em etapas, começando por características simples, como linhas e bordas, e evoluindo para uma compreensão mais complexa.
   c) Utiliza uma abordagem simples, processando todos os detalhes de uma imagem simultaneamente, sem a necessidade de separar por partes.
   d) Apenas reconhece padrões de alta complexidade, e não lida com detalhes simples de imagens.
   e) Apenas trabalha apenas com imagens em preto e branco, sem considerar texturas ou outros detalhes.

3. A LeNet-5 é um tipo de rede neural que possui sete camadas, cada uma com uma tarefa específica. Essas camadas trabalham juntas para analisar as imagens gradualmente, começando com a identificação de características simples e, aos poucos, capturando detalhes mais complexos, até finalmente classificar a imagem de maneira eficiente. Em outras palavras, a LeNet-5 ajuda o computador a entender uma imagem, por exemplo, reconhecer um número ou um objeto, por meio de um processo passo a passo (Pan; Luo; Zhou, 2022).

   Com base no texto, analise as afirmativas, a seguir:

   I - A primeira camada de convolução aplica filtros na imagem de entrada para identificar padrões simples, como bordas e texturas, criando mapas de características que capturam as informações iniciais da imagem.
   II - A primeira camada de subamostragem utiliza a operação de *pooling* para reduzir a resolução dos mapas de características, mantendo as informações essenciais e diminuindo a complexidade computacional da rede.
   III - A segunda camada de convolução aplica filtros sobre os mapas de características gerados pela primeira camada de subamostragem para identificar padrões mais complexos, como combinações de bordas e formas, permitindo um entendimento mais profundo da imagem.
   IV - A camada de saída é responsável pela classificação final da imagem, combinando as informações extraídas nas camadas anteriores e atribuindo a imagem a uma categoria específica, como um número ou objeto.

   É correto o que se afirma em:

   a) I, apenas.
   b) II e IV, apenas.
   c) III e IV, apenas.
   d) I, II e III, apenas.
   e) I, II, III e IV.

REFERÊNCIAS

GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. Regularization for deep learning. *In:* GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. **Deep learning**. Cambridge: The MIT Press, 2016. p. 216-261.

LECUN, Y. *et al.* Backpropagation applied to handwritten zip code recognition. **Neural Computation**, v. 1, n. 4, p. 541-551, 1989.

LECUN, Y.; BENGIO, Y. Convolutional networks for images, speech, and time series. **The Handbook of Brain Theory and Neural Networks**, v. 3361, n. 10, p. 1-14, 1995.

LECUN, Y. *et al.* Gradient-based learning applied to document recognition. **Proceedings of the IEEE**, v. 86, n. 11, p. 2278-2324, 1998.

PAN, X.; LUO, Z.; ZHOU, L. Comprehensive survey of state-of-the-art convolutional neural network architectures and their applications in image classification. **Innovations in Applied Engineering and Technology**, v. 1, n. 1, p. 1-16, 2022.

CONFIRA SUAS RESPOSTAS

1. Alternativa C.

   A LeNet-5 foi criada para resolver um problema prático e urgente da época: automatizar o reconhecimento de dígitos manuscritos em cheques bancários.
   A alternativa A está incorreta, pois a LeNet-5 não foi criada para jogos de videogame. O foco dela era o reconhecimento de números manuscritos, não o processamento de imagens para entretenimento.
   A alternativa B está incorreta, pois apesar de ter surgido no meio acadêmico, a LeNet-5 tinha uma aplicação prática desde o início: resolver o problema da automação bancária, e não era apenas um projeto para estudos teóricos. O processo manual era lento, caro e sujeito a erros, LeCun e sua equipe desenvolveram a rede justamente para atender a essa necessidade do setor bancário.
   A alternativa D está incorreta, pois a LeNet-5 não foi projetada para sistemas de reconhecimento facial. O problema específico que ela visava resolver era o reconhecimento de números, não rostos.
   A alternativa E está incorreta, pois a LeNet-5 não foi feita para a área médica. Ela foi desenvolvida para classificar dígitos manuscritos em cheques, no contexto bancário.

2. Alternativa B.

   A alternativa descreve exatamente o funcionamento da LeNet-5. A rede processa as imagens em etapas, começando com características simples, como linhas e bordas, gradualmente construindo uma compreensão mais complexa da imagem. Esse processo de decomposição em etapas é fundamental para entender como a LeNet-5 funciona.
   A alternativa A está incorreta, pois, ao contrário do que é sugerido, a LeNet-5 não analisa as imagens diretamente e sem decomposição. A rede decompõe a análise em etapas para melhorar a precisão do reconhecimento, começando por aspectos simples e, gradualmente, aprofundando-se.
   A alternativa C está incorreta, pois a LeNet-5 não processa todos os detalhes simultaneamente. Ela adota uma abordagem em que começa com características simples, como linhas e bordas, e não processa a imagem de uma vez. O processo é gradual, construindo uma compreensão mais complexa à medida que avança.
   A alternativa D está incorreta, pois afirma que a LeNet-5 não lida com os detalhes simples da imagem. Na verdade, ela começa justamente com a análise dos detalhes simples, como bordas e texturas, antes de construir uma percepção mais complexa dos objetos.
   A alternativa E está incorreta, pois embora a LeNet-5 tenha sido originalmente projetada para trabalhar com imagens em preto e branco (como os dígitos manuscritos), ela não ignora texturas ou outros detalhes nas imagens. A rede pode ser usada para analisar diferentes tipos de informações visuais, não se limitando apenas à simplicidade de imagens monocromáticas.

3. Alternativa E.

Todas as afirmativas estão corretas. Cada uma descreve corretamente o funcionamento das camadas em uma rede neural convolucional, desde a primeira camada de convolução até a camada de saída.

A afirmativa I está correta, pois a primeira camada de convolução é, de fato, responsável por aplicar filtros (*kernels*) à imagem de entrada para detectar padrões simples, como bordas e texturas. Isso resulta em mapas de características, que são versões simplificadas da imagem, com destaque a detalhes importantes.

A afirmativa II está correta, pois a primeira camada de subamostragem, ou *pooling*, realiza a redução da resolução dos mapas de características gerados pela camada convolucional anterior. Isso ajuda a reduzir a complexidade computacional e a prevenir o *overfitting*, mantendo as informações essenciais.

A afirmativa III está correta, pois a segunda camada de convolução aplica filtros nos mapas de características da camada anterior (primeira camada de subamostragem). Esses filtros ajudam a identificar padrões mais complexos, como combinações de bordas ou formas, e fazem a rede aprender características mais abstratas.

A afirmativa IV está correta, pois a camada de saída tem como função a classificação final da imagem. Ela combina as informações extraídas pelas camadas anteriores e decide a categoria à qual a imagem pertence, por exemplo, reconhecer números ou objetos.

MEU ESPAÇO

TEMA DE APRENDIZAGEM 5

ALEXNET E A REVOLUÇÃO NO RECONHECIMENTO DE IMAGEM

MINHAS METAS

- Compreender a criação da AlexNet e o contexto histórico do ImageNet 2012.
- Analisar como a AlexNet utiliza os GPU em redes neurais profundas.
- Estudar a arquitetura da AlexNet e suas inovações.
- Investigar como a AlexNet impactou a visão computacional.
- Avaliar os ganhos em precisão e eficiência trazidos pela AlexNet.
- Explorar a influência da AlexNet em arquiteturas posteriores.
- Discutir como a AlexNet transformou a pesquisa e a indústria.

INICIE SUA JORNADA

Imagine que você tem um celular bem simples: ele só faz ligações e manda SMS. Um dia, surge um smartphone que acessa a internet, tira fotos incríveis e roda jogos pesados. Isso muda completamente como você usa o aparelho. Algo parecido aconteceu com a AlexNet no mundo da IA: ela foi como o **"primeiro smartphone"** das máquinas, que abriu novas possibilidades para elas entenderem imagens, sons e dados de forma muito mais inteligente.

Mas por que isso deve importar para você, que está estudando ou começando na área? Porque entender essas viradas ajuda a enxergar onde estão as oportunidades.

Antes da AlexNet, as máquinas tinham dificuldades para identificar o que havia em uma imagem. Era como se estivessem tentando ver com os olhos embaçados. A AlexNet clareou essa visão, mostrou que, com a estrutura certa e a força de um bom "motor", **como os processadores gráficos**, os computadores podiam aprender a reconhecer rostos, objetos e lugares com muito mais precisão. Esse avanço permitiu, por exemplo, existirem, hoje, filtros de Instagram que reconhecem seu rosto, ou aplicativos que traduzem placas por meio da câmera.

Pense em quando você começou a usar um celular mais moderno: tudo ficou mais rápido, mais interativo e cheio de possibilidades. Foi isso que a AlexNet trouxe para a área da visão computacional. Depois dela, surgiram versões ainda melhores, como os "**smartphones de última geração**" das redes neurais, cada um aprendendo com os acertos e erros do anterior. Quando você começa a programar, trabalhar com imagens ou criar projetos, está usando ideias que começaram lá atrás, com esse grande passo.

Da mesma forma que hoje ninguém quer voltar a usar um celular antigo, a AlexNet fez o mundo da tecnologia nunca mais ser o mesmo. Entender essa mudança ajuda a perceber como as inovações nascem e podem transformar sua carreira, estudante.

A grande lição é: não basta usar a tecnologia, é importante entender de onde ela vem e como você pode fazer parte do que vem depois. Tudo começa por uma boa pergunta: qual será a próxima grande virada e como você pode participar dela?

PLAY NO CONHECIMENTO

Você sabia que a IA pode auxiliar no diagnóstico de doenças cerebrais? Nesse podcast, exploraremos como a AlexNet, uma das redes neurais mais poderosas, está sendo utilizada para detectar patologias cerebrais, com precisão impressionante. Acompanhe essa revolução tecnológica no campo da saúde, e entenda como a IA está transformando a medicina. **Recursos de mídia disponíveis no conteúdo digital do ambiente virtual de aprendizagem.**

VAMOS RECORDAR?

Imagine que você está olhando para uma imagem e, sem pensar muito, reconhece um gato, uma bicicleta ou uma praia. Para um computador, isso era um desafio até pouco tempo, mas tudo mudou com a chegada da AlexNet, uma rede neural criada por pesquisadores em 2012, que revolucionou o campo da IA. A importância da AlexNet foi tremenda: ao vencer a competição ImageNet em 2012, por meio de uma precisão muito maior do que qualquer outro modelo da época, ela provou que redes neurais profundas podiam superar métodos tradicionais em tarefas de visão computacional. Esse feito marcou o início da era do *deep learning* moderno e inspirou avanços em áreas de reconhecimento facial, carros autônomos, assistentes virtuais e muito mais. Para recordar melhor como tudo começou, assista ao vídeo que mostra a maneira pela qual a AlexNet mudou o treinamento de máquinas para elas enxergarem o mundo. Acesse:

Da mesma forma que hoje ninguém quer voltar a usar um celular antigo, a AlexNet fez o mundo da tecnologia nunca mais ser o mesmo

DESENVOLVA SEU POTENCIAL

O SURGIMENTO DA ALEXNET

Já se perguntou como carros autônomos conseguem identificar pedestres, semáforos e obstáculos em tempo real? Eles tomam decisões em frações de segundo, baseando-se em imagens captadas por câmeras, tudo graças a avanços impressionantes em IA e visão computacional.

Nada disso seria possível sem dois marcos fundamentais: um banco de dados inovador e uma rede neural que mudou para sempre como máquinas interpretam imagens. Estamos falando do ImageNet, um vasto repositório visual com mais de 14 milhões de imagens anotadas manualmente, organizadas em mais de 20 mil categorias. Criado para estimular a pesquisa em reconhecimento de objetos, o ImageNet trouxe algo que antes não existia: escala e diversidade suficientes para redes neurais profundas poderem realmente aprender (Sun *et al.,* 2019).

Em 2010, o projeto lançou o ImageNet Large Scale Visual Recognition Challenge (ILSVRC), uma competição anual que desafiava pesquisadores a criar algoritmos capazes de reconhecer objetos em mais de mil categorias, com base em milhões de imagens rotuladas.

Foi na edição de 2012 que tudo mudou. Uma rede chamada AlexNet, desenvolvida por Alex Krizhevsky, Ilya Sutskever e Geoffrey Hinton, superou todas as expectativas. Até então, redes neurais profundas eram vistas com ceticismo, devido à dificuldade de treinamento em larga escala, aos altos custos computacionais e à falta de grandes conjuntos de dados, mas a AlexNet mudou esse jogo (Sun *et al.,* 2019).

Ainda segundo esses autores, dentre as inovações técnicas dessa rede neural estavam:

- Uso da função de ativação ReLU, o que acelerou o treinamento.
- Camadas convolucionais profundas, capazes de extrair padrões visuais complexos.
- Técnicas como Dropout e Data Augmentation, que aumentaram a capacidade de generalização.
- Treinamento com GPU, o que viabilizou a aplicação prática em grande escala.

O impacto foi imediato: a AlexNet reduziu o erro top-5 de 26% para 15,3%, um salto impressionante. A diferença entre ela e o segundo colocado foi tão grande que chamou a atenção da comunidade científica e da indústria.

Depois disso, as Redes Neurais Convolucionais (CNN), antes pouco exploradas, se tornaram o novo padrão em visão computacional. Grandes empresas começaram a aplicar essas técnicas em produtos como carros autônomos, sistemas de segurança, diagnóstico médico e muito mais.

A vitória da AlexNet, em 2012, não foi apenas um feito técnico, mas o início de uma nova era na IA, impulsionada por grandes dados, computação de alto desempenho e redes neurais profundas (Sun *et al.*, 2019).

VOCÊ SABE RESPONDER?

Se as CNN já existiam antes da AlexNet, por que só a partir de 2012 elas passaram a dominar a visão computacional?

Embora os conceitos básicos das CNN fossem conhecidos, a AlexNet mostrou, na prática, que era possível treinar redes profundas com eficácia em amplos conjuntos de dados, graças à combinação de grande volume de dados (ImageNet), avanços computacionais (GPU) e novas técnicas de regularização e ativação.

A AlexNet demonstrou um ganho real e mensurável de desempenho, o que motivou a comunidade a abandonar métodos tradicionais e investir em *deep learning*.

EU INDICO

Você já parou para pensar como a IA pode transformar a maneira como vemos o mundo ao nosso redor? No vídeo, você entenderá como o Google Photos usa redes neurais e aprendizado de máquina para identificar rostos, objetos e até mesmo locais em suas fotos, tudo isso sem precisar de legendas. Acesse:

Revolução do treinamento com os GPU

O surgimento das redes neurais profundas revolucionou a IA, mas também trouxe muitos desafios. Treinar esses modelos exige milhões, às vezes, bilhões, de operações matemáticas. No início, esse processo era feito principalmente com CPU — os processadores tradicionais de computadores — o que levava muito tempo e limitava o tamanho dos modelos.

A mudança aconteceu com o uso pioneiro das GPU, as unidades de processamento gráfico. Diferentemente das CPU, boas para tarefas sequenciais, as GPU conseguem realizar milhares de cálculos ao mesmo tempo. Essa capacidade de processamento paralelo torna-as ideais para o treinamento de redes neurais, onde operações matemáticas são repetidas em grandes volumes de dados (You; Gitman; Ginsburg, 2017).

Com a introdução das GPU nesse processo, foi possível aumentar drasticamente o volume de dados analisados por vez, o chamado *batch size*. Em vez de treinar a rede com pequenas quantidades de imagens, começou-se a utilizar até 32 mil imagens por etapa de treinamento. Esse salto só foi possível pela combinação de múltiplas GPU de alto desempenho operando de forma coordenada. Esse avanço

reduziu drasticamente o tempo de treinamento. Modelos que antes levavam dias ou até semanas para serem treinados passaram a ser concluídos em menos de uma hora, sem perda de qualidade. Tal mudança também abriu as portas para a criação de arquiteturas maiores e mais profundas, capazes de lidar com tarefas cada vez mais complexas, como tradução automática, reconhecimento facial, diagnósticos médicos por imagem, entre outros (You; Gitman; Ginsburg, 2017).

Além disso, o uso eficiente das GPU estimulou o desenvolvimento de novos métodos de otimização e sincronização de dados entre dispositivos, permitindo que o treinamento em larga escala fosse feito de forma estável e eficiente. Hoje, praticamente todas as grandes inovações em IA dependem dessa base construída com o uso estratégico das GPU.

O avanço não parou por aí. Surgiram também as TPU (Tensor Processing Units), chips projetados especificamente para acelerar operações de aprendizado de máquina, como cálculos com tensores, comuns em redes neurais. As TPU oferecem maior desempenho e eficiência energética do que as GPU em tarefas específicas de IA, sendo amplamente usadas em *data centers* para treinamento e execução de modelos.

Além das TPU, a indústria também adotou os ASIC (Application-Specific Integrated Circuits), chips desenvolvidos para realizar tarefas específicas de forma extremamente eficiente, como o processamento de dados para IA, sendo mais rápidos e econômicos em termos de energia em comparação com outras soluções.

Por sua vez, os FPGA (Field-Programmable Gate Arrays), chips programáveis que podem ser configurados para executar diferentes operações, oferecem uma flexibilidade única nos ajustes, os quais são voltados a necessidades específicas em tempo real, por exemplo, nas aplicações em veículos autônomos (Jouppi *et al.*, 2017).

Estrutura da AlexNet

A AlexNet apresenta uma arquitetura simples quando comparado aos modelos mais modernos de *deep learning*, pois apresenta uma estrutura composta por oito camadas: cinco camadas convolucionais e três camadas totalmente conectadas. Embora sua arquitetura não seja tão complexa quanto a de redes mais recentes, como as que utilizam dezenas ou até centenas de camadas, a AlexNet foi uma

revolução na época de seu lançamento, principalmente pelo uso de inovações técnicas que transformaram o campo da visão computacional (Krizhevsky; Sutskever; Hinton, 2012).

Cada uma dessas camadas tem um papel fundamental no processamento e aprendizado da rede. **Analisaremos cada uma delas**, conforme os conceitos de Ghazal *et al.* (2023) e Krizhevsky, Sutskever e Hinton (2012):

PRIMEIRA CAMADA CONVOLUCIONAL (CONV1)

A primeira camada convolucional da AlexNet aplica 96 filtros de tamanho 11x11 com um passo (*stride*) de 4 pixels. Essa camada é responsável por identificar características iniciais da imagem, como bordas e texturas. Ela "escaneia" a imagem com os filtros, criando mapas de características que ajudam a destacar detalhes importantes, por exemplo, contornos e formas gerais.

SEGUNDA CAMADA CONVOLUCIONAL (CONV2)

Recebe a saída da primeira camada e aplica 256 filtros de 5x5. Ela amplia a detecção de características mais complexas, como formas e padrões mais elaborados. Além disso, essa camada aplica uma operação de normalização de resposta local (LRN), que ajuda a rede a se ajustar a variações locais nas imagens, melhorando tanto a generalização quanto a estabilidade do modelo.

TERCEIRA CAMADA CONVOLUCIONAL (CONV3)

Essa camada usa 384 filtros de 3x3. Não há operações de *pooling* ou normalização nela, o que a permite capturar informações mais detalhadas sobre os objetos e suas interações em diferentes regiões da imagem. Essa camada também é importante para a rede aprender a identificar padrões mais complexos e refinados.

QUARTA CAMADA CONVOLUCIONAL (CONV4)

A quarta camada, assim como a terceira, usa 384 filtros de 3x3. Ela continua o processo de extração de características, buscando identificar padrões ainda mais detalhados e sutis relevantes para a tarefa de classificação. Ao não aplicar *pooling* ou normalização, essa camada mantém uma riqueza maior de informações na representação da imagem.

QUINTA CAMADA CONVOLUCIONAL (CONV5)

Essa camada aplica 256 filtros de 3x3, funcionando de maneira semelhante à quarta camada. Ela também é responsável por refinar as representações das imagens, por meio da captura de padrões ainda mais profundos e complexos que auxiliarão a rede a fazer distinções precisas entre as classes.

PRIMEIRA CAMADA TOTALMENTE CONECTADA (FC6)

Após as camadas convolucionais, a AlexNet tem três camadas totalmente conectadas, também chamadas de *fully connected layers*. A primeira camada (FC6) possui 4.096 neurônios, sendo responsável por consolidar todas as características extraídas pelas camadas anteriores. Aqui, a rede começa a aprender relações mais complexas entre as características da imagem, portanto, ajuda a rede a decidir qual é o objeto ou a classe presente na imagem.

SEGUNDA CAMADA TOTALMENTE CONECTADA (FC7)

Essa camada também possui 4.096 neurônios. Ela continua o processo de integração das informações extraídas, trabalhando para fazer uma distinção mais precisa entre as classes possíveis. O objetivo é continuar refinar a tomada de decisão antes da camada final de saída.

CAMADA DE SAÍDA (*SOFTMAX*)

A camada final da AlexNet é uma camada *softmax* que gera a probabilidade para cada uma das mil classes possíveis. Ela transforma os valores calculados pelas camadas totalmente conectadas em probabilidades, permitindo que a rede faça a previsão sobre a classe provável para a imagem. O *softmax* é uma função de ativação que auxilia a rede a classificar a entrada em uma das várias categorias possíveis, com base nas probabilidades calculadas.

Cada uma dessas camadas trabalha integradamente para extrair características da imagem, aprender a representá-las e, finalmente, classificar a imagem em uma das possíveis categorias. Essa ação possibilita que a AlexNet seja uma das primeiras redes profundas a alcançar avanços em tarefas de reconhecimento de imagens em larga escala (Krizhevsky; Sutskever; Hinton, 2012).

EU INDICO

O artigo *AlexNet para Classificação de Imagens* oferece uma introdução prática à implementação dessa arquitetura em tarefas de classificação de imagens, utilizando o conjunto de dados Dogs vs. Cats, do Kaggle. É demonstrado como preparar os dados, aplicar técnicas de Data Augmentation com ImageDataGenerator e construir a arquitetura AlexNet utilizando o *framework* Keras. Acesse:

Inovações arquitetônicas da AlexNet

Adicionalmente, entre as inovações implementadas pela AlexNet, destaca-se o uso das **funções de ativação ReLU (Rectified Linear Unit)**. Essa função representou um avanço em relação às ativações tradicionais, por exemplo, a sigmoide, por permitir que a rede aprenda de maneira mais eficiente, acelere o processo de treinamento e contribua com a mitigação do problema conhecido como *vanishing gradientes*, ou "desaparecimento de gradientes".

A ReLU tornou-se popular por sua simplicidade e eficiência: ela propicia a passagem linear de valores positivos e zera os negativos, portanto, favorece uma convergência mais rápida e viabiliza o uso de redes mais profundas (Krizhevsky; Sutskever; Hinton, 2012).

Outra inovação importante foi a **Normalização de Resposta Local (LRN)**, um mecanismo que melhora a estabilidade do treinamento ao lidar com variações nas características locais das imagens. Inspirada no funcionamento do sistema visual humano em relação ao contraste, a LRN auxilia na generalização do modelo, tornando-o mais robusto frente às diferenças sutis nos dados de entrada.

Também merece destaque o uso do *Pooling* Máximo Sobreposto (Overlapping Max Pooling), técnica que visa reduzir a dimensionalidade das imagens sem perder informações importantes. Diferentemente do *pooling* tradicional, o método utilizado na AlexNet realiza a operação com janelas sobrepostas, o que preserva mais detalhes relevantes da imagem e, ao mesmo tempo, reduz a complexidade computacional.

Além disso, o Dropout foi incorporado ao AlexNet como uma estratégia eficaz de regularização para combater o *overfitting*. Durante o treinamento, uma fração dos neurônios é desativada aleatoriamente, impedindo que a rede se torne

excessivamente dependente de conexões específicas. Esse processo promove a diversidade nos caminhos de aprendizado e força o modelo a desenvolver representações mais generalizadas, menos suscetíveis ao ruído presente nos dados de treino (Srivastava *et al.*, 2014).

Com todas essas inovações desde a estrutura em camadas profundas até o uso combinado de ReLU, LRN, Dropout e o *pooling* sobreposto, a AlexNet consolidou as redes neurais profundas enquanto ferramentas viáveis e altamente eficazes para tarefas complexas de reconhecimento de imagens. O legado dela permanece como um marco na história do *deep learning*, influenciando diretamente o desenvolvimento de arquiteturas mais avançadas e os rumos da pesquisa em AI nas décadas seguintes (Srivastava *et al.*, 2014).

De maneira análoga, imagine que você está tentando ensinar um grupo de pessoas a reconhecer frutas somente com base em fotos. A função ReLU é como uma regra simples que diz: "só preste atenção nos sinais fortes e ignore os fracos", regra essa a qual ajuda o sistema a aprender mais rápido. Já o Dropout funciona como se, durante o treino, você solicitasse para algumas pessoas da equipe se calarem por um momento. Assim, as outras aprendem a trabalhar melhor sozinhas, e o grupo não depende demais de alguém.

Essas inovações técnicas ReLU e Dropout tornaram-se padrões na construção de modelos de *deep learning*, sendo amplamente adotadas nas arquiteturas posteriores por sua eficácia comprovada tanto em desempenho quanto em estabilidade durante o treinamento.

EU INDICO

Você sabia que o código-fonte original da AlexNet foi liberado como código aberto? Essa decisão não só democratizou o acesso ao modelo, mas também impulsionou a pesquisa e o desenvolvimento em IA. Ao tornar-se código aberto, a AlexNet possibilitou que desenvolvedores, pesquisadores e empresas pudessem adaptar, modificar e aplicar a arquitetura em diversas áreas, como reconhecimento de imagem, vídeo e até mesmo assistentes virtuais. Acesse:

O legado da AlexNet e suas derivações

O sucesso da AlexNet representou um ponto de inflexão no desenvolvimento de redes neurais profundas e motivou uma série de inovações nas arquiteturas que surgiram nos anos seguintes. Modelos como VGG, GoogLeNet e ResNet deram continuidade aos avanços propostos pela AlexNet, ao mesmo tempo que introduziram novas estratégias para aumentar a precisão, a profundidade e a eficiência computacional dos modelos (Krizhevsky; Sutskever; Hinton, 2012).

A arquitetura VGG destacou-se por sua simplicidade e profundidade. Seu projeto comprovou que redes profundas compostas por camadas convolucionais homogêneas com filtros pequenos (3x3) podiam superar arquiteturas anteriores, como a AlexNet, a qual utilizava filtros maiores (11x11). A VGG16 e a VGG19, com 16 e 19 camadas respectivamente, demonstraram que o uso repetido de filtros pequenos permitia a extração de características mais detalhadas e complexas, mantendo uma estrutura arquitetônica regular bem como eficiente. Essa simplicidade estruturada contribuiu para sua ampla adoção e influência em arquiteturas posteriores (Simonyan; Zisserman, 2015).

A GoogLeNet inovou com o conceito do *inception module*, que propiciou o uso simultâneo de filtros de diferentes tamanhos — 1x1, 3x3, 5x5 — em uma mesma camada, promovendo a captura de múltiplos níveis de abstração. A utilização de convoluções 1x1 também reduziu drasticamente o número de parâmetros, assim, tornou o modelo mais leve e eficiente não somente em termos de memória, mas de processamento. O equilíbrio entre profundidade e eficiência consolidou a GoogLeNet como uma das arquiteturas mais inovadoras de sua época (Zhong; Jin; Xie, 2015).

Já a ResNet introduziu os **blocos residuais**, permitindo a construção de redes extremamente profundas, sem sofrer com o problema do desvanecimento do gradiente. Em vez de aprender uma transformação direta da entrada, os blocos residuais aprendem apenas as diferenças (resíduos), o que facilita o fluxo de gradientes durante o treinamento. Com essa abordagem, foi possível desenvolver redes como a ResNet-152, com 152 camadas, mantendo alto desempenho e estabilidade. A ResNet superou modelos anteriores em diversas competições, como o ImageNet, e tornou-se referência em projetos de visão computacional (HE *et al.*, 2016).

Essas arquiteturas, derivadas e inspiradas pela AlexNet, foram fundamentais para levar o campo do *deep learning* a um novo patamar, por meio de redes cada vez mais profundas, precisas e capazes de lidar eficazmente com tarefas de reconhecimento de imagens em larga escala.

O impacto da AlexNet foi tão expressivo que contribuiu decisivamente para consolidar o *deep learning* como a principal abordagem em IA. Antes de 2012, havia ceticismo quanto à viabilidade das redes neurais profundas, principalmente devido às limitações computacionais e à escassez de dados rotulados. O desempenho extraordinário do AlexNet no ImageNet, impulsionado pelo uso de GPU para treinamento, mostrou que tais redes poderiam ser treinadas eficientemente em grandes volumes de dados, com resultados superiores aos métodos tradicionais (Krizhevsky; Sutskever; Hinton, 2012).

Esse marco levou gigantes da tecnologia — Google, Facebook e Microsoft — a investirem fortemente em *deep learning* e aplicarem os avanços dessa abordagem em produtos como assistentes virtuais, mecanismos de busca, reconhecimento facial e outras soluções inteligentes.

A AlexNet não somente redefiniu a trajetória da pesquisa acadêmica, mas também transformou o setor industrial, consolidando o *deep learning* como a base tecnológica da IA moderna (Petrovic, 2025, on-line).

EM FOCO

Confira a aula referente a este tema. **Recursos de mídia disponíveis no conteúdo digital do ambiente virtual de aprendizagem.**

NOVOS DESAFIOS

Aprender sobre a AlexNet não é somente entender uma arquitetura de rede neural, é compreender um ponto de virada que possibilitou muitos dos avanços tecnológicos os quais usamos hoje. A teoria por trás da AlexNet, incluindo redes profundas, uso de GPU e aprendizado supervisionado, reflete-se diretamente em diversas aplicações profissionais e soluções do mundo real.

No campo da segurança, por exemplo, sistemas que desbloqueiam celulares pela identificação do rosto do usuário, monitoram entradas de prédios ou identificam pessoas em aeroportos usam princípios que começaram a se tornar viáveis com a AlexNet. Ela mostrou ser possível treinar modelos para reconhecer, com alta precisão, rostos, mesmo com milhares de imagens, o que, até então, era um desafio.

Da mesma forma, na indústria automobilística, os carros autônomos precisam interpretar imagens das ruas em tempo real para identificar pedestres, sinais de trânsito e outros veículos. A capacidade desses carros de **"ver" e "entender"** essas imagens começa com o tipo de processamento que a AlexNet ajudou a popularizar.

O impacto da AlexNet também é evidente no comércio eletrônico. Em plataformas de vendas, modelos de visão computacional treinados com arquiteturas semelhantes a ela analisam fotos para sugerir produtos semelhantes, melhorar buscas por imagem e até mesmo identificar automaticamente o conteúdo das fotos postadas pelos usuários. A recomendação visual em sites como Amazon ou Instagram não seria tão precisa sem as técnicas que a AlexNet ajudou a consolidar.

No campo da agricultura, essa arquitetura e suas derivadas transformaram a maneira como os agricultores utilizam tecnologia. Com o uso de drones e sensores, redes neurais são aplicadas na análise de imagens de plantações bem como na identificação de pragas, doenças ou problemas no solo.

Na área da saúde, a AlexNet também está presente. Redes neurais são usadas para analisar exames de imagem, por exemplo, raio-x ou tomografias, e auxiliar no diagnóstico precoce de doenças, como câncer. O que antes dependia somente da interpretação humana, agora, é reforçado por AI treinada a detectar padrões invisíveis a olho nu, melhorando a precisão e a velocidade dos diagnósticos médicos.

Esses **exemplos** evidenciam como os conceitos aqui aprendidos de redes neurais, processamento de dados e GPU se transformam em soluções reais, impactando diretamente profissões, empresas e a sociedade. Ao aplicar esses conhecimentos, você não só adquire **habilidades técnicas**, mas também se prepara para liderar inovações que moldam o futuro.

Pergunte-se: como você pode usar esse aprendizado para resolver problemas reais e destacar-se em um mundo em constante evolução? O futuro está em suas mãos, e quem souber aplicar teoria e prática estará à frente.

VAMOS PRATICAR

1. Durante a evolução das arquiteturas de CNN, diferentes estratégias foram incorporadas para aumentar a capacidade de extração de características sem comprometer o desempenho computacional. A GoogLeNet, por exemplo, trouxe contribuições relevantes nesse sentido (Zhong; Jin; Xie, 2015).

   Qual das alternativas descreve corretamente uma inovação introduzida pela arquitetura GoogLeNet?

   a) A adoção exclusiva de filtros 5x5 para reduzir a complexidade da rede.
   b) A eliminação das camadas convolucionais em favor de camadas totalmente conectadas.
   c) O uso de filtros de tamanhos variados em uma mesma camada, permitindo a captura de diferentes níveis de abstração.
   d) A substituição dos módulos de convolução por redes recorrentes para melhorar o desempenho em tarefas sequenciais.
   e) A remoção de todas as camadas de *pooling* para aumentar a resolução das imagens.

2. No desenvolvimento de redes neurais profundas, técnicas de regularização desempenham um papel crucial na melhoria da capacidade de generalização dos modelos. Uma dessas técnicas é o Dropout, que foi incorporado à AlexNet para mitigar alguns problemas (Srivastava *et al.*, 2014).

   Com base nessa informação, assinale a alternativa correta:

   a) O Dropout aumenta a dependência da rede em conexões específicas, melhorando a precisão do modelo.
   b) Durante o treinamento, o Dropout desativa permanentemente neurônios específicos para simplificar a arquitetura da rede.
   c) O Dropout é aplicado apenas durante a fase de teste, para avaliar a robustez do modelo.
   d) O Dropout promove a diversidade nos caminhos de aprendizado, forçando o modelo a desenvolver representações mais generalizadas.
   e) O uso do Dropout na AlexNet foi responsável por reduzir a profundidade da rede, facilitando seu treinamento.

3. A partir dos avanços introduzidos pela AlexNet, surgiram novos modelos de CNN, como a VGG, a GoogLeNet e a ResNet. Cada um desses modelos contribuiu significativamente para o aumento da precisão e da eficiência computacional, além de permitir arquiteturas mais profundas e estáveis no campo do *deep learning* (Krizhevsky; Sutskever; Hinton, 2012).

   Com base na evolução das CNN após a AlexNet, analise as afirmativas, a seguir, sobre os avanços trazidos pelos modelos VGG, GoogLeNet e ResNet:

   I - A VGG introduziu arquiteturas mais profundas e uniformes, utilizando pequenas janelas de convolução para aumentar a precisão dos modelos.
   II - A GoogLeNet inovou ao usar blocos *inception*, que combinam múltiplas convoluções em paralelo para melhorar a eficiência computacional.
   III - A ResNet resolveu o problema do desvanecimento do gradiente por meio da introdução dos blocos residuais, assim, propiciou redes extremamente profundas e estáveis.
   IV - Todos esses modelos foram desenvolvidos antes da AlexNet e serviram como base para o desenvolvimento dela.

   É correto o que se afirma em:

   a) I, apenas.
   b) II e IV, apenas.
   c) III e IV, apenas.
   d) I, II e III, apenas.
   e) I, II, III e IV.

REFERÊNCIAS

GHAZAL, T. M. *et al.* Early detection of autism in children using transfer learning. **Intelligent Automation & Soft Computing**, v. 36, n. 1, p. 11-22, 2023.

HE, K. *et al.* Deep residual learning for image recognition. *In:* CVPR – CONFERENCE ON COMPUTER VISION AND PATTERN RECOGNITION, 28., 2016. **Proceedings** [...]. Las Vegas: CVPR, 2016. p. 770-778.

JOUPPI, N. P. *et al.* In-datacenter performance analysis of a tensor processing unit. *In:* ANNUAL INTERNATIONAL SYMPOSIUM ON COMPUTER ARCHITECTURE, 44., 2017, Toronto. **Proceedings** [...]. New York: Association for Computing Machinery, 2017. p. 1-12.

KRIZHEVSKY, A.; SUTSKEVER, I.; HINTON, G. E. ImageNet classification with deep convolutional neural networks. *In:* NEURIPS – ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS, 25., Lake Tahoe, 2012. **Proceedings** [...]. Lake Tahoe: NeurIPS, 2012. p. 1097-1105. Disponível em: https://papers.nips.cc/paper/2012/hash/c399862d3b9d6b76c8436e924a68c45b-Abstract.html. Acesso em: 27 ago. 2025.

PETROVIC, D. AlexNet: the deep learning breakthrough that reshaped Google's AI strategy. **Dejan AI**, 21 mar. 2025. Disponível em: https://dejan.ai/blog/alexnet-the-deep-learning-breakthrough--that-reshaped-googles-ai-strategy/?utm_source=chatgpt.com. Acesso em: 27 ago. 2025.

SIMONYAN, K.; ZISSERMAN, A. Very deep convolutional networks for large-scale image recognition. **arXiv preprint arXiv:1409.1556**, v. 6, p. 1-14, 2015. Disponível em: https://arxiv.org/pdf/1409.1556. Acesso em: 27 ago. 2025.

SRIVASTAVA, N. *et al.* Dropout: a simple way to prevent neural networks from overfitting. **The Journal of Machine Learning Research**, v. 15, n. 1, p. 1929-1958, 2014.

SUN, P. *et al.* Optimizing network performance for distributed DNN training on GPU clusters: ImageNet/AlexNet training in 1.5 minutes. **arXiv preprint arXiv:1902.06855**, v. 1, p. 1-13, 2019. Disponível em: https://arxiv.org/abs/1902.06855. Acesso em: 27 ago. 2025.

YOU, Y.; GITMAN, I.; GINSBURG, B. Scaling SGD batch size to 32k for ImageNet training. **arXiv preprint arXiv:1708.03888**, v. 6, n. 12, p. 1-13, 2017. Disponível em: https://arxiv.org/pdf/1708.03888v1. Acesso em: 27 ago. 2025.

ZHONG, Z.; JIN, L.; XIE, Z. High performance offline handwritten chinese character recognition using GoogleNet and directional feature maps. *In:* ICDAR – INTERNATIONAL CONFERENCE ON DOCUMENT ANALYSIS AND RECOGNITION, 13., 2015, Tunis. **Proceedings** [...]. Tunis: IEEE, 2015. p. 846-850.

CONFIRA SUAS RESPOSTAS

1. Alternativa C.

   A GoogLeNet introduziu o *inception module*, que combinava simultaneamente filtros 1x1, 3x3 e 5x5 em uma mesma camada, possibilitando a extração de múltiplos níveis de características. Além disso, o uso de convoluções 1x1 ajudava a reduzir o número de parâmetros, melhorando a eficiência do modelo.
   A alternativa A está incorreta, pois a GoogLeNet não utilizou apenas filtros 5x5, ela combinava múltiplos tamanhos.
   A alternativa B está incorreta, pois as camadas convolucionais foram mantidas como essenciais na arquitetura.
   A alternativa D está incorreta, pois redes recorrentes não fazem parte da estrutura da GoogLeNet.
   A alternativa E está incorreta, pois o *pooling* ainda é utilizado, ao ajudar a reduzir a dimensionalidade e o custo computacional.

2. Alternativa D.

   O Dropout é uma técnica de regularização que, durante o treinamento, desativa aleatoriamente uma fração dos neurônios da rede neural. Essa abordagem impede a rede de se tornar excessivamente dependente de conexões específicas, promovendo a diversidade nos caminhos de aprendizado. Como resultado, o modelo desenvolve representações mais generalizadas, torna-se menos suscetível ao ruído presente nos dados de treino e reduzi o risco de *overfitting*.
   A alternativa A está incorreta, pois contraria o objetivo do Dropout, que é justamente reduzir a dependência em conexões específicas.
   A alternativa B está incorreta, pois o Dropout, desativa neurônios de forma temporária e aleatória durante o treinamento, não permanentemente.
   A alternativa C está incorreta, pois o Dropout é aplicado durante o treinamento, não na fase de teste.
   A alternativa E está incorreta, pois o Dropout não altera a profundidade da rede, ele atua como uma técnica de regularização, sem modificar a arquitetura estrutural.

3. Alternativa D.

   A afirmativa I está correta, pois a VGG apostou em arquiteturas mais profundas usando pequenas janelas (3x3) de convolução, o que ajudou a aumentar a precisão dos modelos.
   A afirmativa II está correta, pois a GoogLeNet introduziu os blocos *inception*, os quais combinam várias operações convolucionais paralelas, aumentando a eficiência computacional, mas sem aumentar demais o custo.
   A afirmativa III está correta, pois a ResNet resolveu o problema do desvanecimento do gradiente com blocos residuais, possibilitando o treino de redes muito profundas e estáveis.
   A afirmativa IV está incorreta, pois esses modelos foram desenvolvidos após a AlexNet. Ela, por sua vez, é um marco inicial que abriu caminho para eles.

MEU ESPAÇO

Unicesumar

unidade 4

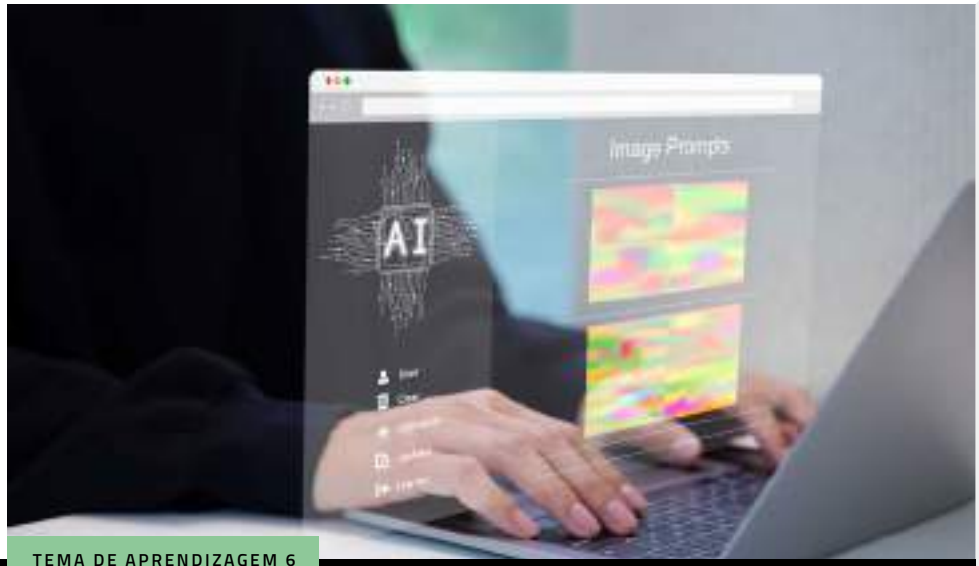

TEMA DE APRENDIZAGEM 6

VGG E A ESTRUTURA DE CAMADAS PROFUNDAS

MINHAS METAS

- Entender a arquitetura básica da VGG.
- Analisar o uso de convoluções 3x3 em camadas profundas.
- Identificar a simplicidade estrutural da VGG.
- Avaliar a profundidade como fator de melhoria no desempenho.
- Comparar a VGG com arquiteturas anteriores.
- Discutir os avanços trazidos pela VGG para redes profundas.
- Explorar aplicações práticas da VGG em reconhecimento de imagens.

INICIE SUA JORNADA

Já parou para pensar como os aplicativos de celular conseguem identificar objetos, reconhecer rostos ou até ajudar médicos a descobrir doenças por meio de exames de imagem? No passado, isso era muito difícil, porque os programas que analisam imagens eram bem simples e não conseguiam perceber muitos detalhes. A dúvida que surgiu foi: será que, deixando esses programas mais "profundos", com várias etapas de análise, eles poderiam funcionar melhor?

Em 2014, um grupo de pesquisadores criou a VGG, um modelo de rede neural que provou exatamente isso: quanto mais **"camadas"** a rede tiver, mais detalhes ela consegue perceber em uma imagem. É como se, em vez de olhar rapidamente para uma foto, o programa passasse a analisá-la com muito mais atenção, camada por camada. Essa ideia mudou completamente o jeito como hoje usamos a IA, e ajuda desde carros que dirigem sozinhos até sistemas que detectam doenças em exames médicos.

Hoje, qualquer estudante pode testar esse tipo de rede neural usando ferramentas gratuitas e fáceis de acessar na internet. Existem sites e programas onde é possível treinar uma rede inspirada na VGG para, por exemplo, reconhecer diferentes tipos de frutas ou animais. Essas experiências mostram, na prática, como funciona a ideia das "camadas profundas", e ajudam a entender por que esse conceito é tão importante no mundo da tecnologia.

O sucesso da VGG ensina uma lição importante: muitas vezes, para resolver problemas difíceis, precisamos ir mais fundo, analisando cada detalhe, sem pressa. Isso vale não só para as máquinas, mas também para nós, como profissionais em formação. Além disso, **nos faz pensar**: até que ponto queremos as máquinas com o poder de ver e entender o mundo como nós? Quem será responsável por garantir que essa tecnologia seja usada de forma ética e segura?

PLAY NO CONHECIMENTO

Quer saber como a IA está ajudando médicos a identificar a Covid-19 só com uma radiografia do pulmão? Nesse podcast, explicaremos, de forma simples, como um modelo chamado VGG, um tipo de "superdetector de imagens", foi adaptado para auxiliar no diagnóstico da pandemia com precisão de mais de 96%. Não perca essa conversa! **Recursos de mídia disponíveis no conteúdo digital do ambiente virtual de aprendizagem.**

VAMOS RECORDAR?

Imagine que você está assistindo a um filme de ação e, em uma cena, um carro autônomo consegue desviar de obstáculos na pista, tudo sem motorista. Por trás dessa tecnologia impressionante, existe um trabalho enorme de visão computacional que faz os carros "verem" o mundo ao redor, reconhecerem objetos e tomarem decisões rápidas. Um dos modelos que ajudou a dar esse salto foi a VGG, criada em 2014. Pense nela como uma lupa muito poderosa, que olha para cada parte da imagem em várias etapas, capturando detalhes com intuito de entender exatamente o que está na cena. A VGG usa várias camadas empilhadas para aprender padrões complexos. Essa forma simples, porém eficiente, fez dela uma ferramenta fundamental para muitas aplicações práticas, como carros autônomos, reconhecimento facial em smartphones, análise de imagens médicas para o diagnóstico de doenças e moderação automática de conteúdos em redes sociais. Acesse:

DESENVOLVA SEU POTENCIAL

INTRODUÇÃO À ARQUITETURA DA VGG

A VGG é uma Rede Neural Convolucional (CNN) criada em 2014, por Karen Simonyan e Andrew Zisserman. Ela ficou famosa por sua arquitetura simples, porém extremamente eficaz, para tarefas de reconhecimento e classificação de imagens.

A estrutura básica da VGG é composta por várias camadas convolucionais pequenas, sempre com filtros de tamanho 3x3, empilhadas umas sobre as outras. Esses filtros funcionam como pequenas janelas que percorrem a imagem, capturando detalhes simples, por exemplo, bordas e texturas. Ao empilhar várias dessas camadas, a rede consegue identificar padrões mais complexos, como formas e objetos inteiros (Simonyan; Zisserman, 2015).

> O diferencial da VGG está justamente nessa simplicidade estrutural: em vez de usar filtros grandes e diferentes tipos de camadas, ela adota apenas pequenas convoluções repetidas e camadas de *pooling*, que servem para reduzir o tamanho da imagem, além de preservar as informações mais importantes. Essa estratégia torna a rede mais profunda, permitindo-a aprender de forma mais detalhada e eficiente, mas, ao mesmo tempo, mantém a arquitetura organizada e padronizada, a fim de facilitar tanto a implementação quanto o treinamento (Simonyan; Zisserman, 2015).

A VGG é extremamente importante porque ela serviu de base para muitos outros modelos avançados de redes neurais que surgiram depois, além de ter sido um dos primeiros exemplos a demonstrar como o aumento da profundidade da rede poderia melhorar significativamente o desempenho em tarefas de visão computacional.

Hoje, entender como a VGG funciona é essencial para quem deseja trabalhar com IA, ciência de dados ou áreas relacionadas, pois muitos dos conceitos que ela introduziu continuam sendo usados em aplicações modernas: reconhecimento facial, veículos autônomos, diagnóstico médico com imagens, entre outras (Vinagreiro, 2022).

EU INDICO

Para aprofundar seus conhecimentos sobre a arquitetura VGG e suas camadas profundas, leia o artigo *VGG-Net Architecture Explained*, de Siddhesh Bangar, disponível no Medium. O autor explora, de forma clara e acessível, como a VGG utiliza camadas convolucionais empilhadas para extrair características complexas de imagens. Acesse:

ARQUITETURA VGG

Na arquitetura VGG, o uso de filtros pequenos, especialmente os de tamanho 3x3, é uma das principais inovações. Diferentemente de outras redes que utilizavam filtros maiores — 5x5 ou 7x7 — a VGG optou por usar várias camadas com filtros menores empilhados em sequência. Isso pode parecer estranho à primeira vista, mas essa escolha trouxe vantagens importantes: melhorou a capacidade da rede de capturar padrões complexos, usando menos parâmetros e menos sobrecarga computacional (Rodrigues Filho; Cortes, 2023).

Filtros 3x3 são como pequenas janelas que observam a imagem em pedaços muito pequenos, capturando detalhes simples, tais quais bordas ou mudanças sutis de cor e textura. Quando várias dessas camadas são combinadas, a rede consegue, gradualmente, construir uma representação muito mais complexa e precisa da imagem. Por exemplo, as primeiras camadas detectam linhas e formas básicas, enquanto as camadas seguintes combinam essas informações para reconhecer partes de objetos e, finalmente, objetos inteiros, como um rosto ou um carro (Sharma; Singh, 2024).

Esse processo é eficiente por dois motivos principais. **Primeiro**, filtros pequenos exigem menos cálculos e, consequentemente, menos recursos computacionais. **Segundo**, ao empilhar várias camadas, a rede ganha profundidade, o que aumenta a capacidade de aprendizado e de generalização dela para diferentes tipos de imagens. Assim, a VGG consegue ter um desempenho excelente, reconhecendo imagens com muita precisão, sem necessidade de uma estrutura muito complexa (Sharma; Singh, 2024).

Existem duas versões principais da arquitetura VGG: **VGG16 e VGG19**. Ambas foram desenvolvidas com a mesma estrutura básica, utilizando múltiplas camadas convolucionais pequenas (3x3) empilhadas, seguidas por camadas totalmente conectadas. A principal diferença entre elas está no número de camadas: a VGG16 possui 16, e a VGG19, como o nome sugere, 19. Essas diferenças impactam diretamente na profundidade do modelo e na sua capacidade de representar padrões mais complexos (Mascarenhas; Agarwal, 2021).

As especificidades de cada versão podem ser visualizadas claramente no quadro, a seguir:

CARACTERÍSTICAS	VGG16	VGG19
Número de camadas	16 (13 convolucionais + 3 totalmente conectadas).	19 (16 convolucionais + 3 totalmente conectadas).
Parâmetros ajustáveis	Aproximadamente 138 milhões.	Aproximadamente 144 milhões.
Filtros convolucionais	3x3 em sequência, com aumento progressivo no número de filtros.	3x3 em sequência, com aumento progressivo no número de filtros.
Camadas de pooling	5 camadas de *max pooling* 2x2.	5 camadas de *max pooling* 2x2.
Camadas totalmente conectadas	3 (4096, 4096, 1000 neurônios).	3 (4096, 4096, 1000 neurônios).
Função de ativação	ReLU após cada camada convolucional e totalmente conectada.	ReLU após cada camada convolucional e totalmente conectada.
Camada de saída	Softmax para classificação em 1000 classes.	Softmax para classificação em 1000 classes.
Desempenho	Alto desempenho em tarefas de classificação de imagens.	Desempenho ligeiramente superior devido à maior profundidade.
Uso típico	Reconhecimento de imagens, transferência de aprendizado.	Reconhecimento de imagens, transferência de aprendizado.

Quadro 1 – Especificidades das versões principais da arquitetura VGG
Fonte: adaptado de Mascarenhas e Agarwal (2021).

O funcionamento da VGG pode ser dividido em três etapas principais. Primeiro, a rede utiliza vários blocos de camadas convolucionais com filtros 3x3, cada bloco seguido por uma camada de *pooling* 2x2, que reduz a resolução espacial da imagem, por meio da simplificação da informação, sem perder características importantes. Em seguida, vêm as camadas totalmente conectadas: elas combinam e sintetizam os recursos extraídos para formar uma representação mais abstrata dos dados. Por fim, a camada de saída realiza a classificação, determinando a qual categoria a imagem pertence.

Essa estrutura modular e consistente tornou a VGG um modelo clássico, servindo de base e inspiração para muitas arquiteturas profundas que vieram depois, especialmente no campo da visão computacional e do aprendizado profundo (Mascarenhas; Agarwal, 2021).

VOCÊ SABE RESPONDER?

Por que usar várias camadas pequenas na VGG é mais eficaz do que usar poucas camadas com filtros grandes?

A resposta seria: porque o uso dessas várias camadas menores permite analisar a imagem em etapas, capturando detalhes gradualmente. Os filtros grandes podem perder informações ao tentar captar tudo de uma vez.

O aumento no número de camadas em redes como a VGG está diretamente ligado à melhora da precisão na tarefa de reconhecimento de imagens. Camadas adicionais possibilitam ao modelo extrair informações em níveis cada vez mais complexos e abstratos. Enquanto as primeiras camadas capturam detalhes simples, como bordas e texturas, as camadas mais profundas conseguem identificar padrões mais sofisticados, como formas específicas, objetos completos e até contextos visuais (Sharma; Singh, 2024).

Essa profundidade é fundamental porque imagens do mundo real são muito complexas e cheias de variações. Quanto mais camadas a rede tiver, maior é a capacidade de analisar essas variações e distinguir características sutis decisivas para uma classificação correta. Assim, a profundidade não só aumenta o poder

de aprendizado do modelo, como também melhora a capacidade dele de generalizar para imagens novas e, consequentemente, aumenta a precisão e a robustez da rede em tarefas práticas (Sharma; Singh, 2024).

COMPARAÇÃO COM ARQUITETURAS ANTERIORES

Antes da introdução da arquitetura VGG, o campo das Redes Neurais Convolucionais (CNN) já contava com modelos importantes, dentre eles, a LeNet-5 (1998) e a AlexNet (2012).

A LeNet-5, desenvolvida por Yann LeCun, foi uma das primeiras CNN a demonstrar o potencial do aprendizado profundo, sendo usada, com sucesso, para reconhecer dígitos manuscritos. Essa arquitetura, porém, era relativamente rasa, com poucas camadas convolucionais, e adequada apenas para tarefas simples (LeCun *et al.*, 1989).

Anos depois, a AlexNet — proposta por Krizhevsky, Sutskever e Hinton, em 2012 — revolucionou a área ao vencer a competição ImageNet por meio de uma precisão sem precedentes. A AlexNet introduziu técnicas importantes, tais como a ativação ReLU (Rectified Linear Unit), o uso de Dropout para reduzir *overfitting*, e o treinamento em GPU para acelerar o processamento. Além disso, possuía cinco camadas convolucionais, aspecto que, na época, já representava um avanço significativo em relação a redes anteriores.

Essa arquitetura, no entanto, ainda utilizava filtros relativamente grandes — 11x11 e 5x5 — e apresentava uma estrutura que, embora inovadora, era menos padronizada (Sun *et al.*, 2019). Foi nesse contexto que surgiu a **VGG (Visual Geometry Group) Network**. A inovação da VGG foi a introdução de um modelo padronizado, profundo e simples: em vez de utilizar filtros de tamanhos variados e grandes, como na AlexNet, utilizou exclusivamente filtros pequenos de 3x3, empilhados em várias camadas. Essa escolha permitiu que a rede alcançasse uma profundidade muito maior das versões mais famosas, VGG16 e VGG19, as quais possuem 16 e 19 camadas, respectivamente, com parâmetros ajustáveis.

Segundo Mascarenhas e Agarwal (2021), o uso desses pequenos filtros empilhados trouxe várias melhorias importantes, tais como:

REDUÇÃO DE PARÂMETROS

Filtros menores significam menos parâmetros por camada, o que permite adicionar mais camadas sem aumentar exageradamente a complexidade computacional.

APRENDIZADO PROGRESSIVO

Ao empilhar filtros 3x3, a rede constrói representações complexas a partir de detalhes simples, facilitando a identificação de padrões sutis e características hierárquicas nas imagens.

PADRONIZAÇÃO

A estrutura uniforme da VGG, composta por blocos convolucionais seguidos de *pooling*, simplificou o design e a implementação de redes profundas, além de favorecer tanto a replicação quanto a extensão por outros pesquisadores.

Outro aspecto importante da VGG foi mostrar que a profundidade é um fator essencial para melhorar a precisão em tarefas de reconhecimento de imagens. Portanto, ao comparar a VGG com as arquiteturas anteriores, percebe-se que sua principal contribuição foi demonstrar o seguinte: com uma estrutura simples e bem planejada, é possível construir redes profundas e altamente eficazes para classificação de imagens.

A VGG tornou-se uma referência clássica tanto em aplicações práticas quanto como base para pesquisas acadêmicas, influenciando diretamente o design das arquiteturas modernas em visão computacional.

Outro aspecto importante da VGG foi mostrar que a profundidade é um fator essencial para melhorar a precisão em tarefas de reconhecimento de imagens

APLICAÇÕES PRÁTICAS E IMPACTO DA VGG

A arquitetura VGG teve um impacto significativo na evolução da visão computacional e do aprendizado profundo. Ao propor o uso sistemático de pequenas camadas convolucionais empilhadas (3x3), a VGG demonstrou que redes profundas são mais eficazes na extração de características complexas de imagens, sem necessidade de filtros grandes ou estruturas excessivamente complicadas (Simonyan; Zisserman, 2014).

Esse modelo padronizado e modular tornou-se referência para inúmeras pesquisas e aplicações práticas, assim, funcionou como base ao desenvolvimento de arquiteturas ainda mais avançadas, por exemplo, ResNet e DenseNet (Simonyan; Zisserman, 2015). Além disso, a VGG facilitou a democratização do uso de redes profundas, uma vez que sua estrutura clara e organizada é relativamente simples de ser implementada e adaptada em diversos projetos.

A VGG possibilitou avanços expressivos em várias áreas da tecnologia e da ciência, com aplicações que impactam diretamente a sociedade. Dentre elas, tem-se:

Reconhecimento facial

Usa a rede neural VGG, eficiente em captar detalhes dos rostos, para identificar pessoas automaticamente em sistemas de segurança, redes sociais e autenticação biométrica (Dubey; Jain, 2020).

Veículos autônomos

Utilizam a rede VGG para analisar imagens de sensores, mediante identificação de pedestres, sinais e obstáculos, garantindo uma direção mais segura e eficiente (Dewi *et al.*, 2024).

Classificação de imagens satelitais e sensoriamento remoto

A VGG é aplicada para classificação de imagens multiespectrais, segmentação de terrenos e monitoramento ambiental. Por exemplo, na identificação de áreas desmatadas e na análise do uso da terra (Guerra, 2024).

Monitoramento ambiental e agricultura de precisão

Uso avançado do processamento de imagens capturadas por satélites e drones para acompanhar a saúde de florestas e plantações, identificar mudanças ambientais e otimizar práticas agrícolas (GARG *et al.*, 2021).

EU INDICO

Para entender, na prática, como a arquitetura VGG pode ser aplicada, leia o artigo *Utilizando a Arquitetura VGG para a Classificação de Doenças nas Plantas de Feijão*. Ele explica, passo a passo, como preparar os dados, ajustar a arquitetura e treinar o modelo, tornando o conteúdo acessível mesmo para quem está começando. Acesse:

A influência da VGG é tamanha que seus modelos pré-treinados ainda são amplamente utilizados como ponto de partida para diversas tarefas de visão computacional, a fim de reduzir o tempo e os recursos necessários para treinar redes em novos conjuntos de dados.

EM FOCO

Confira a aula referente a este tema. **Recursos de mídia disponíveis no conteúdo digital do ambiente virtual de aprendizagem.**

NOVOS DESAFIOS

No universo da IA e da visão computacional, a arquitetura VGG é um exemplo claro de como a teoria e a prática andam juntas para transformar o mercado de trabalho. Criada com intuito de melhorar a capacidade das máquinas em "entender" imagens, a VGG usa camadas profundas para capturar detalhes cada vez mais complexos em fotos, vídeos e outros tipos de dados visuais.

Aos estudantes interessados em áreas como ciência de dados, IA, automação ou saúde digital, compreender o funcionamento das camadas profundas é essencial. Essas camadas permitem que modelos como a VGG identifiquem padrões sutis que passam, muitas vezes, despercebidos aos olhos humanos, desde sinais precoces de doenças em exames médicos até a detecção de objetos e pessoas em sistemas de segurança e veículos autônomos.

A VGG já é aplicada na detecção de doenças em imagens médicas, na navegação segura de veículos autônomos, no reconhecimento facial para segurança, na moderação automática de conteúdos em redes sociais e até mesmo no monitoramento de plantações, por meio da agricultura de precisão. Para os estudantes, dominar essa tecnologia significa estar preparado a atuar em múltiplos setores, transformando conhecimento teórico em soluções práticas e inovadoras.

Além disso, ter habilidades práticas em **construir, treinar e otimizar** redes neurais profundas abre portas em empresas de tecnologia, *startups*, centros de pesquisa e em setores tradicionais que estão acelerando sua transformação digital.

O mercado valoriza profissionais capazes de aplicar conceitos como a arquitetura VGG para resolver problemas reais, otimizar processos e criar produtos inteligentes. Por isso, aprender camadas profundas vai muito além da teoria, é uma **ferramenta estratégica** para construir uma carreira estável, alinhada com as demandas tecnológicas do mundo contemporâneo.

1. A rede neural convolucional VGG, criada em 2014 por Karen Simonyan e Andrew Zisserman, é conhecida por sua arquitetura simples e eficiente, que utiliza várias camadas convolucionais pequenas de filtros. Essa técnica tem impulsionado avanços em áreas como reconhecimento facial, veículos autônomos e monitoramento ambiental, possibilitando que máquinas interpretem imagens com um nível de detalhamento antes inacessível (Simonyan; Zisserman, 2015).

   Sobre a estrutura e o funcionamento da VGG, assinale a alternativa correta:

   a) A VGG utiliza filtros grandes, de tamanho 7x7, para captar detalhes complexos nas imagens desde as primeiras camadas.
   b) A arquitetura da VGG é composta por camadas convolucionais empilhadas, todas com filtros pequenos de 3x3, que permitem identificar desde padrões simples até complexos nas imagens.
   c) A VGG não utiliza filtros convolucionais, mas sim filtros lineares para acelerar o processamento de imagens.
   d) A rede VGG foi criada para trabalhar exclusivamente com imagens em preto e branco devido à limitação dos seus filtros 3x3.
   e) A principal característica da VGG é o uso de poucas camadas convolucionais para evitar o excesso de informações e simplificar o reconhecimento de objetos.

2. As arquiteturas VGG16 e VGG19 são amplamente utilizadas em tarefas de classificação de imagens devido ao seu alto desempenho. Embora ambas tenham estruturas semelhantes, a diferença na profundidade impacta o desempenho dos modelos (Mascarenhas; Agarwal, 2021).

   Considerando essas informações, assinale a alternativa correta sobre o desempenho da VGG16 e da VGG19:

   a) A VGG16 apresenta desempenho superior à VGG19 porque possui menos camadas, o que reduz o risco de *overfitting*.
   b) A VGG19 tem desempenho ligeiramente inferior à VGG16 devido ao aumento excessivo de parâmetros.
   c) Ambas as arquiteturas têm desempenho equivalente, pois usam os mesmos filtros convolucionais 3x3.
   d) A VGG19 apresenta desempenho ligeiramente superior à VGG16 devido à sua maior profundidade, a qual permite capturar padrões mais complexos.
   e) A VGG16 não é adequada às tarefas de classificação de imagens, enquanto a VGG19 é a única versão utilizada para esse fim.

3. As arquiteturas VGG16 e VGG19 são versões da rede neural VGG, ambas com estrutura semelhante, mas com diferenças em sua profundidade. Essas variações influenciam diretamente a capacidade do modelo de capturar padrões mais complexos nas imagens (Mascarenhas; Agarwal, 2021).

   Sobre ambas as arquiteturas, analise as afirmativas, a seguir:

   I - A VGG19 utiliza filtros convolucionais maiores que a VGG16, o que explica o desempenho superior daquela em relação a essa.
   II - A principal diferença entre a VGG16 e a VGG19 está na quantidade de camadas convolucionais, o que impacta na profundidade e, potencialmente, no desempenho do modelo.
   III - A VGG16 tem mais parâmetros treináveis do que a VGG19. Essa característica torna a VGG16 mais pesada computacionalmente.
   IV - Ambas utilizam filtros 3x3 em sequência e compartilham a mesma estrutura geral, incluindo camadas de *pooling*, ativação ReLU e uma camada de saída com *softmax*.

   É correto o que se afirma em:

   a) I, apenas.
   b) II e IV, apenas.
   c) III e IV, apenas.
   d) I, II e III, apenas.
   e) I, II, III e IV.

REFERÊNCIAS

DEWI, A. L. *et al.* Two-stage object detection for autonomous vehicles with VGG-16 based faster R-CNN. **Jurnal Elektronika dan Telekomunikasi**, v. 24, n. 1, p. 25-30, 2024.

DUBEY, A. K.; JAIN, V. Automatic facial recognition using VGG16 based transfer learning model. **Journal of Information and Optimization Sciences**, v. 41, n. 7, p. 1589-1596, 2020.

GARG, S. *et al.* Towards a multimodal system for precision agriculture using IoT and machine learning. *In:* ICCCNT – INTERNATIONAL CONFERENCE ON COMPUTING COMMUNICATION AND NETWORKING TECHNOLOGIES, 12., 2021, Kharagpur. **Proceedings** [...]. Kharagpur: IEEE, 2021. p. 1-7.

GUERRA, L. R. **Classificação de uso do solo para agricultura com imagens do Sentinel-2 e CNN VGG-16**. 2024. 64 f. Trabalho de Conclusão de Curso (Graduação em Engenharia Elétrica) – Escola de Engenharia, Departamento de Engenharia Elétrica, Universidade Federal do Rio Grande do Sul, Porto Alegre, 2024.

LECUN, Y. *et al.* Backpropagation applied to handwritten zip code recognition. **Neural Computation**, v. 1, n. 4, p. 541-551, 1989.

MASCARENHAS, S.; AGARWAL, M. A comparison between VGG16, VGG19 and ResNet50 architecture frameworks for Image Classification. *In:* CENTCON – INTERNATIONAL CONFERENCE ON DISRUPTIVE TECHNOLOGIES FOR MULTI-DISCIPLINARY RESEARCH AND APPLICATIONS, 2021, Bengaluru. **Proceedings** [...]. Bengaluru: IEEE, 2021. p. 96-99.

RODRIGUES FILHO, M. L.; CORTES, O. A. C. Classificação de imagens histopatológicas usando uma VGG e mecanismo de atenção para detecção de câncer de mama. *In:* SBCAS – SIMPÓSIO BRASILEIRO DE COMPUTAÇÃO APLICADA À SAÚDE, 23., 2023, São Paulo. **Anais** [...]. São Paulo: SBC, 2023. p. 1-6.

SHARMA, R.; SINGH, A. VGG16-3PGA: a hybrid approach for plant disease detection. **Journal of Crop Health**, v. 76, n. 6, p. 1541-1552, 2024.

SIMONYAN, K.; ZISSERMAN, A. Very deep convolutional networks for large-scale image recognition. **arXiv preprint arXiv:1409.1556**, v. 6, p. 1-14, 2015. Disponível em: https://arxiv.org/pdf/1409.1556. Acesso em: 27 ago. 2025.

SUN, P. *et al.* Optimizing network performance for distributed DNN training on GPU clusters: ImageNet/AlexNet training in 1.5 minutes. **arXiv preprint arXiv:1902.06855**, v. 1, p. 1-13, 2019. Disponível em: https://arxiv.org/abs/1902.06855. Acesso em: 28 ago. 2025.

VINAGREIRO, M. A. L. **Classificação baseada em espaços de camadas convolucionais de redes CNNs densas**. 2022. 127 f. Dissertação (Mestrado em Sistemas Eletrônicos) – Escola Politécnica, Pós-Graduação em Engenharia Elétrica, Universidade de São Paulo, São Paulo, 2022. Disponível em: https://www.teses.usp.br/teses/disponiveis/3/3142/tde-04052023-091217/publico/MichelAndreLimaVinagreiroOrig2022.pdf. Acesso em: 28 ago. 2025.

CONFIRA SUAS RESPOSTAS

1. Alternativa B.

   A arquitetura da rede VGG é baseada no uso de várias camadas convolucionais pequenas, todas com filtros de tamanho 3x3. Esses pequenos filtros são aplicados em sequência (empilhados), permitindo que a rede extraia características simples, como bordas e texturas, nas primeiras camadas, e combine essas informações para reconhecer padrões mais complexos, como formas e objetos completos, nas camadas mais profundas.
   A alternativa A está incorreta, pois a VGG não utiliza filtros grandes de 7x7. Seu diferencial está justamente no uso de filtros pequenos (3x3).
   A alternativa C está incorreta, pois a VGG usa filtros convolucionais, não filtros lineares.
   A alternativa D está incorreta, pois a VGG pode trabalhar com imagens coloridas (RGB), não se limita a imagens em preto e branco.
   A alternativa E está incorreta, pois a VGG utiliza muitas camadas convolucionais para capturar detalhes progressivamente mais complexos, não poucas camadas.

2. Alternativa D.

   A VGG19 apresenta desempenho ligeiramente superior à VGG16 devido à maior profundidade, que permite capturar padrões mais complexos.
   A alternativa A está incorreta, pois embora menos camadas reduzam o *overfitting*, a VGG16 não tem desempenho superior à VGG19. A maior profundidade da VGG19 costuma ser uma vantagem.
   A alternativa B está incorreta, pois a VGG19 não tem desempenho inferior. Seu aumento de parâmetros melhora sua capacidade de aprender padrões.
   A alternativa C está incorreta, pois o uso dos mesmos filtros não garante desempenho igual. A profundidade da rede também é fundamental.
   A alternativa E está incorreta, pois a VGG16 é amplamente usada e eficaz em tarefas de classificação, não sendo correto dizer que não é adequada.

3. Alternativa B.

   A afirmativa I está incorreta, pois ambas utilizam os mesmos filtros 3x3, a diferença está no número de camadas, não no tamanho dos filtros.
   A afirmativa II está correta, pois a diferença entre VGG16 e VGG19 está na quantidade de camadas, afetando diretamente a profundidade e a capacidade de aprendizado do modelo.
   A afirmativa III está incorreta, pois a VGG19 tem mais parâmetros (144 milhões) do que a VGG16 (138 milhões), portanto, a afirmação está invertida.
   A afirmativa IV está correta, pois ambas as redes compartilham estrutura semelhante: filtros 3x3, *pooling* 2x2, função ReLU, camadas totalmente conectadas e saída com *softmax*.

MEU ESPAÇO

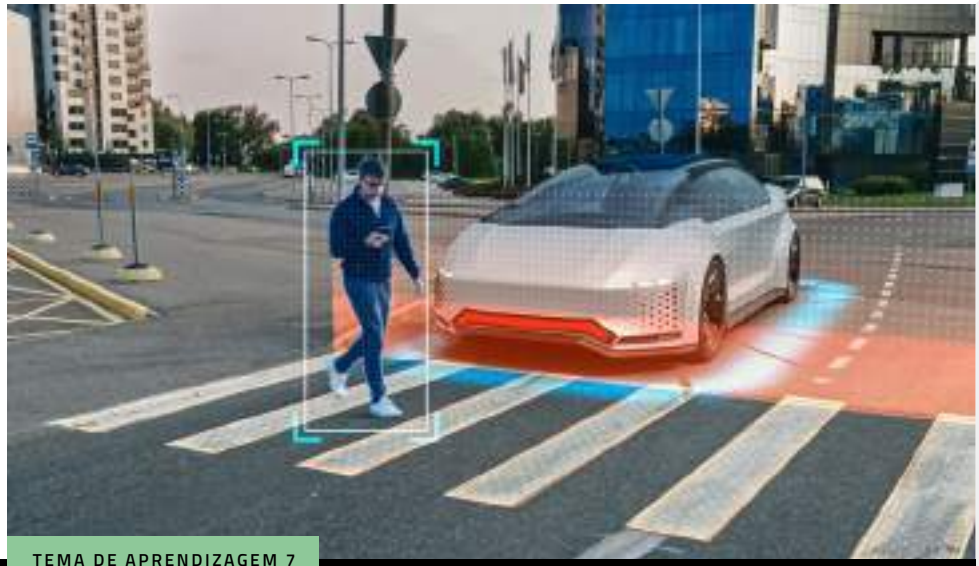

TEMA DE APRENDIZAGEM 7

RESNET E CONEXÕES RESIDUAIS

MINHAS METAS

- Entender o problema do desaparecimento de gradientes em redes profundas.
- Explicar o que são conexões residuais (*skip connections*).
- Descrever a arquitetura básica da ResNet.
- Mostrar como conexões residuais melhoram o fluxo do gradiente.
- Entender por que a ResNet permite redes muito profundas.
- Reconhecer a importância da ResNet em visão computacional.
- Aplicar conexões residuais para melhorar modelos profundos.

INICIE SUA JORNADA

No cotidiano profissional, muitas vezes, enfrentamos desafios em que informações importantes se perdem durante processos longos e complexos. Imagine ensinar uma receita detalhada, na qual várias pessoas precisam aprender e passar adiante a sequência. Se o caminho for muito longo, as instruções podem ser esquecidas ou distorcidas, prejudicando o resultado. Da mesma forma, no desenvolvimento de sistemas inteligentes, redes neurais profundas enfrentam dificuldades para **"aprender"** quando são muito extensas, pois o conhecimento talvez se perca entre as etapas.

Compreender esse desafio é essencial para quem quer atuar em áreas de tecnologia e inteligência artificial (IA). A perda de informações durante o aprendizado da rede impacta diretamente na eficiência dos sistemas criados. Reconhecer a existência de soluções que facilitam esse processo é importante ao desenvolvimento de competências técnicas atuais, porque essas permitem construir sistemas mais robustos e confiáveis.

Ao experimentar projetos e exercícios que simulam esse problema, por exemplo, criando redes neurais com diferentes estruturas, o estudante percebe, na prática, como pequenas mudanças podem melhorar muito os resultados. Essa experimentação aproxima o aprendizado do cotidiano real, mostrando que conceitos aparentemente abstratos estão ligados a desafios concretos e relevantes.

Refletir sobre essa situação incentiva o estudante a pensar criticamente os processos de desenvolvimento e as inovações tecnológicas. Essa reflexão fortalece a capacidade de **resolver problemas** complexos e adaptá-los a diferentes contextos profissionais, preparando você para contribuir efetivamente no mercado de trabalho, onde a melhoria contínua e a inovação são essenciais.

PLAY NO CONHECIMENTO

Você já imaginou como um computador ajuda médicos a identificar sinais da Doença de Alzheimer antes mesmo de os sintomas aparecerem? Nesse podcast, exploramos a arquitetura ResNet, uma tecnologia de ponta que, por meio da IA, está transformando o diagnóstico médico. Venha descobrir como essa inovação pode salvar vidas. **Recursos de mídia disponíveis no conteúdo digital do ambiente virtual de aprendizagem.**

VAMOS RECORDAR?

Suponha que você está assistindo a um filme de ação e, em uma cena, um carro autônomo precisa desviar de vários obstáculos na estrada, sem motorista. Para que isso aconteça, o sistema precisa "enxergar" o ambiente, reconhecer objetos e tomar decisões rápidas, tudo isso graças à visão computacional e às redes neurais profundas. Um avanço nessa área foi a criação das redes residuais, ou ResNet, as quais funcionam como "atalhos" na rede neural, permitindo a passagem da informação por várias camadas sem se perder ou se degradar. Antes da ResNet, redes muito profundas tinham dificuldades para aprender, porque os sinais de treino "desapareciam" ao passar por muitas camadas, um problema chamado desaparecimento de gradiente. Com as conexões residuais, esse problema foi resolvido, a partir daí foram criadas redes mais profundas e eficientes, usadas em diversas aplicações: carros autônomos, diagnósticos por imagens médicas, reconhecimento facial, assistentes virtuais e muito mais. Acesse:

DESENVOLVA SEU POTENCIAL

O DESAPARECIMENTO DE GRADIENTES EM REDES PROFUNDAS

Há alguns anos, caso você perguntasse a cientistas se computadores poderiam reconhecer rostos, traduzir idiomas, dirigir veículos ou até mesmo escrever textos, a resposta, provavelmente, seria unânime: "não com as redes neurais que temos hoje". A razão? Um problema técnico chamado "desaparecimento de gradientes" que impediu redes neurais mais profundas de aprender eficientemente (Bengio; Simard; Frasconi, 1994).

Mesmo com o domínio do **algoritmo *backpropagation***, popularizado na década de 1980, o qual permitia o ajuste dos pesos de uma rede camada por camada, a profundidade mostrava-se uma inimiga. Quanto mais camadas uma rede neural possuía, mais os sinais de erro enfraqueciam à medida que retropropagavam. Esses sinais tornavam-se tão diminutos que as primeiras camadas da rede mal conseguiam ser atualizadas (Bengio; Simard; Frasconi, 1994). Esse problema limitou drasticamente o potencial de aprendizado da IA por um longo tempo (Rumelhart; Hinton; Williams, 1986).

VOCÊ SABE RESPONDER?

Mas, afinal, o que são esses gradientes que desaparecem?

Em redes neurais, um gradiente é um valor numérico que indica o quanto o erro de uma previsão muda em relação a cada peso da rede. Em termos simples: se você imaginar o processo de aprendizado como uma trilha até o fundo de um vale, o gradiente é a inclinação dessa trilha; ele mostra para onde a rede deve "andar" para diminuir o erro. Durante o treinamento, a rede usa esses gradientes para ajustar seus pesos e melhorar a precisão. Quanto maior o gradiente, maior a correção, quanto menor, menor a mudança (Goodfellow; Bengio; Courville, 2016).

O desaparecimento de gradientes ocorre porque, durante o treinamento das redes neurais, as derivadas das funções de ativação, como a sigmoide, são multiplicadas sucessivamente em cada camada. Essas derivadas costumam ser menores que 1, então, os gradientes diminuem exponencialmente à medida que se propagam para trás, impedindo as primeiras camadas de aprenderem. Na verdade, elas praticamente "congelam". Esse fenômeno foi identificado já em 1991, por Sepp Hochreiter, e, alguns anos depois, Bengio, Simard e Frasconi (1994) demonstraram formalmente que o uso do gradiente descendente em redes profundas era ineficaz devido à perda de sinal entre as camadas.

Foi só a partir de 2006 que começaram a surgir soluções práticas para esse problema. Uma das primeiras foi o uso de pré-treinamento camada por camada com *autoencoders* ou redes de Boltzmann restritas. Com isso, cada camada era treinada de forma independente antes do ajuste global da rede, o que facilitava a propagação dos gradientes (Hinton; Osindero; Teh, 2006).

Outro avanço foi a introdução da função de ativação ReLU (Rectified Linear Unit) que, ao contrário da sigmoide, não achatava os gradientes. Essa característica manteve os valores de atualização ativos mesmo em redes profundas, possibilitando treinar modelos mais complexos eficazmente. Além disso, métodos modernos de inicialização de pesos ajudaram a manter os gradientes em uma faixa adequada durante o treinamento, para evitar tanto o desaparecimento quanto a explosão de gradientes (He *et al.*, 2016).

O surgimento das redes residuais (ResNet) revolucionou esse campo. Essas redes introduziram conexões de atalho (*skip connections*) que permitem os gradientes "saltarem" camadas e chegarem com mais intensidade às camadas iniciais. Isso tornou viável o treinamento de redes com mais de 100 camadas, algo impensável anos antes.

Graças a essas soluções, hoje, utilizamos redes neurais profundas em quase tudo: reconhecimento facial, tradução automática, diagnósticos médicos por imagem e até mesmo carros autônomos.

Tudo isso só se tornou possível, no entanto, após superarmos o desafio silencioso do desaparecimento de gradientes, um obstáculo que quase impediu o avanço da IA tal qual a conhecemos (He *et al.*, 2016).

ENTENDENDO AS CONEXÕES RESIDUAIS

Quando criamos redes neurais muito profundas com muitas camadas, às vezes, elas ficam difíceis de treinar e têm pior funcionamento, mesmo com mais camadas. Isso acontece porque, durante o treinamento, a informação que ajuda a ajustar a rede pode se perder ou ficar muito fraca ao passar por tantas camadas. Conexões residuais são uma "solução engenhosa" para resolver esse problema. Elas funcionam como "atalhos" que pulam algumas camadas, levando a informação diretamente às camadas mais adiante, sem precisar passar por tudo no meio (He *et al.*, 2016).

As conexões residuais têm importância porque, sem elas, as redes neurais profundas enfrentariam muitas dificuldades para aprender e melhorar o desempenho. Isso ocorre porque a informação, ao passar por muitas camadas, vai enfraquecendo gradualmente, portanto, dificulta-se o ajuste correto dos parâmetros da rede. Ao introduzir conexões que pulam algumas camadas, essa informação e os ajustes chegam de forma mais direta e rápida às camadas mais profundas, facilitando o treinamento. Como resultado, as redes conseguem aprender de maneira mais eficiente, podendo ser muito mais profundas do que antes, algo praticamente inviável há alguns anos, devido às limitações do treinamento tradicional (He *et al.*, 2016).

Conforme esses mesmos autores citados, as conexões residuais trazem diversos benefícios, como:

- Evitar a degradação do desempenho em redes muito profundas.
- Facilitar o fluxo dos gradientes durante o *backpropagation*, evitando que eles desapareçam ou explodam.
- Acelerar o treinamento, tornando as redes mais fáceis de otimizar.
- Permitir treinar redes com muito mais camadas, por exemplo, ResNet-152 com 152 camadas, o que, antes, era inviável.

Para aplicar conexões residuais em seus modelos de redes neurais, você pode utilizar *frameworks* populares e amplamente adotados pela comunidade de IA, como TensorFlow e PyTorch. Essas plataformas oferecem blocos residuais pré-implementados, facilitando a incorporação dessa técnica, pois não há necessidade de desenvolver tudo do zero. Além disso, elas propiciam muita flexibilidade para criar blocos residuais personalizados, adaptados às necessidades específicas do seu projeto.

Dessa forma, é possível experimentar diferentes arquiteturas, ajustar a profundidade da rede e otimizar o desempenho do modelo, de maneira prática e eficiente, aproveitando toda a robustez e os recursos dessas ferramentas modernas (Paszke *et al.*, 2019).

EU INDICO

Para aprofundar seus conhecimentos sobre a arquitetura ResNet e suas camadas residuais, leia o capítulo *Residual Networks* (ResNet) do livro on-line *Dive into Deep Learning* (D2L). O material explica, de forma clara e didática, como as conexões residuais ajudam a resolver problemas comuns no treinamento de redes muito profundas, assim, facilitam o fluxo de informação e a estabilidade durante o aprendizado. Acesse:

ARQUITETURA BÁSICA DA RESNET

A arquitetura ResNet (Residual Network) foi projetada para superar limitações enfrentadas por CNN profundas, como o desaparecimento de gradientes, que dificulta o treinamento de redes muito profundas e compromete o desempenho em tarefas de aprendizado de máquina. O diferencial da ResNet está nas conexões residuais: elas criam atalhos cuja entrada de um bloco seja somada diretamente à sua saída, facilitando o fluxo de gradientes bem como a preservação de informações importantes ao longo das camadas (Sengupta; Almasri, 2021).

A ResNet-50 — uma das variações mais utilizadas da arquitetura — possui 50 camadas de profundidade organizadas em blocos residuais empilhados eficientemente (2021). Conforme Sengupta e Almasri (2021), a estrutura básica desses blocos inclui:

CAMADAS CONVOLUCIONAIS
Responsáveis pela extração de características, aplicam filtros — tipicamente de 1x1, 3x3 e, novamente, 1x1 no bloco *bottleneck* — para aprender padrões em diferentes níveis de abstração.
BATCH NORMALIZATION
Aplica normalização das ativações para estabilizar e acelerar o treinamento.
FUNÇÃO DE ATIVAÇÃO RELU
Introduz não linearidade ao modelo, assim, possibilita a aprendizagem de funções complexas.
CONEXÃO RESIDUAL
Realiza a soma entre a entrada do bloco e a saída das camadas convolucionais, o que facilita o treinamento e reduz a perda de informação.
CAMADAS DE *POOLING*
Reduzem a dimensionalidade dos dados e ajudam a focar nas informações mais relevantes.
CAMADAS *FULLY CONNECTED*
Utilizadas ao final da arquitetura para realizar tarefas, por exemplo, classificação ou detecção.

A profundidade da ResNet-50 permite capturar padrões complexos em dados, sendo amplamente utilizada em tarefas de reconhecimento de imagens, detecção de objetos e segmentação semântica, com destaque pela sua robustez e estabilidade durante o treinamento.

O design com blocos residuais ***bottleneck*** na ResNet-50 reduz o custo computacional ao mesmo tempo que mantém a capacidade de aprendizado de redes profundas, representando um avanço significativo em comparação às arquiteturas convolucionais anteriores (Sengupta; Almasri, 2021).

EU INDICO

O artigo do *GeeksforGeeks* sobre Residual Networks (ResNet) explica, de forma clara e acessível, como as conexões residuais ajudam a treinar redes neurais profundas e, assim, evitam o problema do desaparecimento de gradientes. Acesse:

VARIAÇÕES DA ARQUITETURA RESNET

As ResNet-18 e ResNet-34 utilizam blocos residuais simples, compostos por duas camadas convolucionais seguidas de Batch Normalization e função de ativação ReLU. Essas variantes são indicadas para aplicações em que redes mais leves e rápidas são essenciais, como em dispositivos móveis e sistemas embarcados, devido ao menor custo computacional e menor demanda por memória, sem comprometer significativamente a performance em tarefas de classificação de imagens (Nagpal; Bhinge; Shitole, 2022).

Por sua vez, as ResNet-50, 101 e 152 utilizam blocos residuais do tipo *bottleneck*, compostos por três camadas convolucionais — 1x1, 3x3, 1x1 — em cada bloco. Essa estrutura reduz a dimensionalidade antes das convoluções mais pesadas e a amplia novamente depois, otimizando o uso de recursos computacionais enquanto permite o aumento da profundidade da rede. Com isso, essas variantes são indicadas para tarefas mais complexas, por exemplo, detecção de objetos, segmentação semântica e classificação em imagens de alta resolução, por meio da captura de padrões sutis e detalhados que exigem maior capacidade de abstração.

Além de possibilitar a construção de redes profundas sem degradar o desempenho, a arquitetura ResNet facilita a utilização de aprendizado transferido (*transfer learning*), pois seus pesos pré-treinados em grandes bases de dados, como o ImageNet, podem ser facilmente adaptados para diferentes aplicações práticas, economizando tempo de treinamento e aumentando a eficiência em problemas específicos.

As variantes mais profundas, como ResNet-101 e ResNet-152, embora exijam mais recursos computacionais e tempo de treinamento, apresentam alta capacidade de extração de características complexas, o que resulta em mais precisão em tarefas desafiadoras. Já variantes como ResNet-18 e ResNet-34, mesmo sendo menos profundas, proporcionam soluções rápidas e eficazes às aplicações que demandam processamento em tempo real (Nagpal; Bhinge; Shitole, 2022).

Para facilitar a compreensão, o quadro, a seguir, apresenta as principais características e diferenças entre cada variante da arquitetura ResNet:

VERSÃO RESNET	Nº DE CAMADAS	TIPO DE BLOCO	VANTAGENS
Resnet-18	18	2 camadas convolucionais	Leve, rápido e baixo custo computacional.
Resnet-34	34	2 camadas convolucionais	Mais profundo que o anterior, logo, mais eficiente.
Resnet-50	50	3 camadas convolucionais	Equilíbrio entre profundidade e eficiência.
Resnet-101	101	3 camadas convolucionais	Alta capacidade em capturar padrões complexos.
Resnet-152	152	3 camadas convolucionais	Máxima profundidade, alta precisão.

Quadro 1 – Comparação entre as versões principais da arquitetura ResNet
Fonte: adaptado de Nagpal, Bhinge e Shitole (2022).

APROFUNDANDO

Sabia que uma rede de três camadas convolucionais também é chamada de *bottleneck*? Esse bloco é muito usado em arquiteturas ResNet-50, 101 e 152, a fim de possibilitar, com eficiência, redes profundas. O nome "*bottleneck*" vem do fato de que ele reduz temporariamente a quantidade de canais, diminuindo cálculos e uso de memória, depois, expande novamente os canais e mantém a capacidade de aprendizado. O bottleneck utiliza a sequência de convoluções 1x1 para reduzir, 3x3 para processar, e 1x1 para expandir, portanto, facilita o treinamento, evita a degradação de desempenho e possibilita que a rede aprenda padrões complexos em imagens de forma rápida e estável, sendo essencial em aplicações como diagnóstico médico, reconhecimento facial e veículos autônomos (Nagpal; Bhinge; Shitole, 2022).

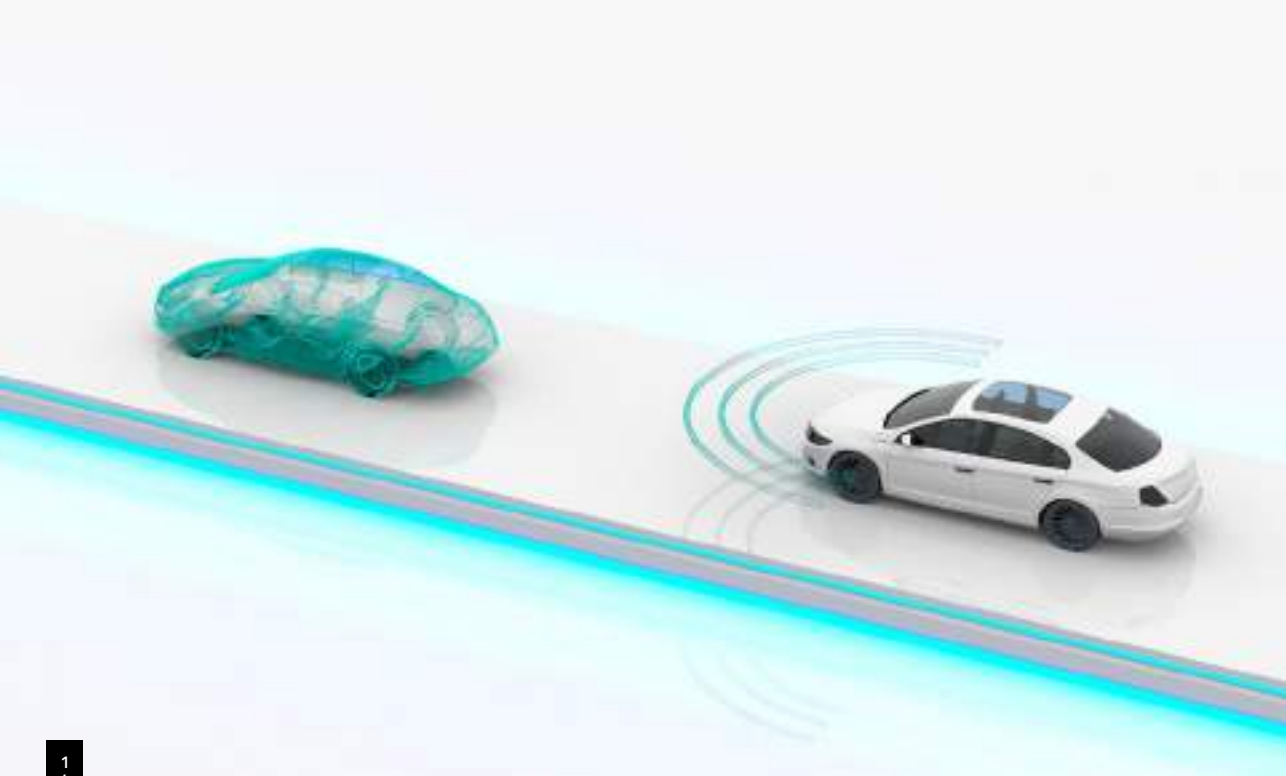

Essas variações propiciam a adaptação da ResNet a diferentes cenários de aplicação, desde dispositivos com capacidade computacional limitada até servidores com alta potência de processamento, utilizados em treinamento de grandes volumes de dados em tarefas de classificação, detecção de objetos e segmentação de imagens. Além disso, as variantes mais profundas, como ResNet-101 e ResNet-152, conseguem capturar padrões complexos em imagens, aumentando a precisão em tarefas desafiadoras, embora exijam maior capacidade computacional e maior tempo de treinamento (Zhang *et al.*, 2023).

Outro ponto relevante da ResNet é a sua escalabilidade e facilidade de integração em *pipelines* de aprendizado transferido (*transfer learning*). Devido ao seu desempenho robusto em conjuntos de dados de grande escala, como o ImageNet, os pesos pré-treinados das variantes ResNet são amplamente utilizados em aplicações práticas, permitindo reduzir o tempo de treinamento e aumentar a eficiência em problemas específicos, mesmo quando há menos dados disponíveis.

A arquitetura ResNet também inspirou variações — ResNeXt e SE-ResNet — que combinam os blocos residuais com técnicas adicionais, como atenção de canal (*squeeze-and-excitation*), ou agrupamentos de convoluções em paralelo, cujos resultados são as melhorias no desempenho sem aumento significativo do custo computacional.

Essa adaptabilidade consolida a ResNet enquanto um padrão de excelência para tarefas de visão computacional, aprendizado transferido e aplicações práticas em diversos setores, como saúde, segurança, agricultura e indústria, onde robustez, escalabilidade e precisão são requisitos essenciais (ZHANG *et al.*, 2023).

VOCÊ SABE RESPONDER?

Por que a ResNet usa conexões residuais, em vez de simplesmente empilhar muitas camadas?

A resposta seria: porque as conexões residuais evitam o desaparecimento de gradientes, a fim de facilitar o treinamento de redes muito profundas.

IMPACTO DA RESNET NA VISÃO COMPUTACIONAL E APLICAÇÕES PRÁTICAS

A introdução da arquitetura ResNet marcou um divisor de águas no campo da visão computacional. Antes da ResNet, o treinamento de redes muito profundas era limitado por problemas como o desaparecimento de gradientes, que dificultava a aprendizagem efetiva das camadas iniciais. A proposta inovadora das conexões residuais, as quais permitem a passagem direta do sinal de uma camada para outra mais adiante, revolucionou essa dinâmica (He *et al.*, 2016).

Graças a essas conexões residuais, as redes ResNet conseguem manter o fluxo de informação e gradientes durante o treinamento, possibilitando a construção de modelos com dezenas ou até centenas de camadas. Essa característica levou a avanços significativos em diversas tarefas de visão computacional, como reconhecimento de imagens, detecção de objetos, segmentação semântica e muito mais.

Na prática, as conexões residuais são amplamente incorporadas em modelos modernos, desde aplicações comerciais em reconhecimento facial, sistemas de segurança e veículos autônomos até pesquisas avançadas em diagnóstico por imagens médicas, em que tanto a precisão quanto a robustez são cruciais. Por exemplo, no reconhecimento facial, essas redes possibilitam, com muita precisão, identificar indivíduos, mesmo diante de variações de ângulo e iluminação. Em veículos autônomos, a ResNet auxilia no processamento em tempo real das imagens para detectar obstáculos e pedestres, aumentando a segurança. Na área médica, sua aplicação inclui a detecção precoce de tumores em radiografias e ressonâncias magnéticas, o que contribui com diagnósticos mais rápidos e tratamentos eficazes (He *et al.*, 2016).

Antes da ResNet, o treinamento de redes muito profundas era limitado por problemas como o desaparecimento de gradientes

EU INDICO

Quer entender como as redes neurais profundas revolucionaram a visão computacional? Confira o artigo *Deep Residual Learning for Image Recognition*, de Kaiming He e colaboradores. Essa pesquisa apresentou as famosas conexões residuais como verdadeiros "atalhos" que transformaram o treinamento de redes com centenas de camadas em algo possível e eficiente. Acesse:

Implementar conexões residuais em modelos profundos não só melhora a capacidade de aprendizado, mas também acelera a convergência, reduz o risco de *overfitting* e aumenta a estabilidade durante o treinamento. Por isso, a ResNet e suas conexões residuais tornaram-se um padrão na arquitetura de redes neurais para visão computacional e muito mais (Litjens *et al.*, 2017).

A seguir, apresentaremos um quadro comparativo entre as diferentes arquiteturas.

CARACTERÍSTICAS	RESNET	CNN	INCEPTION
Ano	2015	desde 1980	2014
Problema resolvido	Desaparecimento de gradientes.	Desaparecimento e degradação.	Eficiência computacional.
Conexões residuais	Presença de skip connections.	Ausentes	Ausentes
Facilidade de treinamento	Alta devido ao fluxo de gradiente facilitado.	Dificuldade em redes muito profundas.	Moderada
Aplicações comuns	Reconhecimento, detecção, segmentação.	Reconhecimento básico.	Reconhecimento, detecção.

Quadro 2 – Análise comparativa das arquiteturas ResNet, CNN e Inception
Fonte: adaptado de Goodfellow, Bengio e Courville (2016).

Dessa forma, a ResNet destaca-se em relação às CNNs tradicionais e à arquitetura Inception ao utilizar conexões residuais que facilitam o treinamento de redes extremamente profundas, superando problemas comuns como o desaparecimento de gradientes.

As CNN (Convolutional Neural Networks) são redes compostas por camadas convolucionais que extraem características das imagens de forma hierárquica, e são amplamente utilizadas em classificação e detecção de objetos. Já a arquitetura Inception foi desenvolvida para otimizar o uso de recursos computacionais ao empregar múltiplos filtros de diferentes tamanhos em paralelo em cada camada, propiciando a captação de características em diferentes escalas eficientemente.

Embora a Inception melhore a capacidade de extração de características, ela não elimina os desafios do treinamento em redes muito profundas. Por isso, a ResNet possibilita a criação de modelos maiores, mais estáveis e eficientes. Comom resultado, configura um avanço significativo no desenvolvimento de redes neurais profundas (Goodfellow; Bengio; Courville, 2016).

EM FOCO

Confira a aula referente a este tema. **Recursos de mídia disponíveis no conteúdo digital do ambiente virtual de aprendizagem.**

NOVOS DESAFIOS

Ao longo do processo de aprendizagem sobre redes neurais profundas e os desafios envolvidos no treinamento delas, como o problema do desaparecimento de gradientes, você, estudante, tem a oportunidade de compreender não somente conceitos teóricos, mas também a importância prática desses conhecimentos para o mercado de trabalho atual e futuro. A conexão entre teoria e prática é essencial na formação de profissionais capazes de atuar em áreas que exigem inovação e domínio de tecnologias avançadas.

No ambiente profissional, o avanço das tecnologias de IA e aprendizado de máquina está transformando os setores de saúde, finanças, indústria, agricultura e entretenimento. As redes neurais profundas são a base para muitas dessas inovações, permitindo desde diagnósticos médicos mais precisos, passando por sistemas de recomendação personalizados até veículos autônomos que prometem revolucionar o transporte. As conexões residuais, implementadas em arquiteturas como a ResNet, ajudam a superar dificuldades técnicas, a fim de garantir que esses sistemas sejam tão eficientes quanto confiáveis.

Exemplos práticos ilustram bem essa aplicação: sistemas de reconhecimento facial usados para segurança, diagnósticos por imagens médicas que identificam tumores, veículos autônomos que detectam obstáculos e tomam decisões em tempo real, assistentes virtuais compreendedores de linguagem natural, análises financeiras as quais detectam fraudes e preveem tendências, além de ferramentas de tradução automática e geração de imagens digitais. Todos esses avanços dependem do treinamento eficaz de redes profundas, viabilizado por técnicas como as conexões residuais.

O conhecimento adquirido também fomenta uma postura crítica e inovadora, necessária para acompanhar a velocidade por meio da qual a tecnologia evolui. A capacidade de experimentar, testar e adaptar soluções, baseada no entendimento sólido da teoria, diferencia o profissional no mercado competitivo.

Portanto, a união entre teoria e prática não só fortalece a base técnica dos estudantes, mas também os prepara para contribuir efetivamente com o desenvolvimento tecnológico, fomenta carreiras promissoras e traz impacto positivo à sociedade.

1. As arquiteturas ResNet-18, 34, 50, 101 e 152 fazem parte da família de redes residuais (ResNet) que utilizam conexões residuais para viabilizar o treinamento de redes profundas. Elas diferenciam-se principalmente em profundidade e utilização ou não de blocos *bottleneck* para reduzir custo computacional, mantendo a capacidade de aprendizado em redes profundas (Nagpal; Bhinge; Shitole, 2022).

   Com base nesse texto, assinale a alternativa correta:

   a) ResNet-18, ResNet-34, ResNet-50, ResNet-101 e ResNet-152 utilizam exclusivamente blocos *bottleneck* em todas as versões.
   b) ResNet-18 e ResNet-34 utilizam blocos simples (sem *bottleneck*), enquanto ResNet-50, ResNet-101 e ResNet-152 utilizam blocos *bottleneck* para maior eficiência em redes profundas.
   c) Todas as versões de ResNet utilizam a mesma quantidade de camadas, com variação apenas na taxa de aprendizado.
   d) Apenas a ResNet-50 utiliza conexões residuais, sendo as demais redes variantes de CNN tradicionais sem atalhos.
   e) ResNet-18 e ResNet-34 são mais profundas que a ResNet-152, por utilizarem mais conexões residuais.

2. As conexões residuais, como as presentes na arquitetura ResNet, têm revolucionado o campo do aprendizado profundo por permitir o treinamento eficaz de redes neurais muito profundas. Na prática, essas conexões são amplamente aplicadas em diversas áreas onde precisão e robustez são essenciais. Essa versatilidade torna as conexões residuais um componente fundamental em aplicações comerciais e de pesquisa avançada (HE *et al.*, 2016).

   Sobre as aplicações práticas das conexões residuais em modelos modernos, assinale a alternativa correta:

   a) As conexões residuais são usadas principalmente em modelos de previsão do tempo, devido à sua capacidade de processar dados meteorológicos complexos.
   b) A ResNet não é adequada para uso em imagens médicas, por não conseguir lidar com variações de iluminação e ângulo.
   c) Redes com conexões residuais são ineficazes em sistemas de segurança porque apresentam dificuldades em reconhecer imagens em tempo real.
   d) A aplicação das conexões residuais é limitada apenas a pesquisas acadêmicas, e não é utilizada em ambientes comerciais.
   e) A ResNet é amplamente empregada em reconhecimento facial, veículos autônomos e diagnóstico por imagens médicas, graças à sua precisão e robustez.

3. As arquiteturas de CNN evoluíram para resolver diferentes desafios. A ResNet, a CNN tradicional e a Inception possuem características distintas relacionadas a problemas resolvidos, estrutura, facilidade de treinamento e aplicações (Goodfellow; Bengio; Courville, 2016).

   Sobre as arquiteturas citadas, analise as afirmativas, a seguir:

   I - A ResNet foi projetada para resolver o problema do desaparecimento de gradientes por meio de conexões residuais (*skip connections*), facilitando o treinamento de redes muito profundas.
   II - As CNN tradicionais têm conexões residuais que melhoram significativamente a eficiência computacional.
   III - A arquitetura Inception foi criada em 2015 para resolver problemas de desaparecimento e degradação em redes profundas.
   IV - As CNN tradicionais são altamente eficientes no treinamento de redes muito profundas, graças à facilidade de fluxo do gradiente.

   É correto o que se afirma em:

   a) I, apenas.
   b) II e IV, apenas.
   c) III e IV, apenas.
   d) I, II e III, apenas.
   e) I, II, III e IV.

REFERÊNCIAS

BENGIO, Y.; SIMARD, P.; FRASCONI, P. Learning long-term dependencies with gradient descent is difficult. **IEEE Transactions on Neural Networks**, v. 5, n. 2, p. 157-166, 1994.

GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. **Deep learning**. Cambridge: The MIT Press, 2016.

HE, K. *et al.* Deep residual learning for image recognition. *In:* CVPR – CONFERENCE ON COMPUTER VISION AND PATTERN RECOGNITION, 28., 2016, Las Vegas. **Proceedings** [...]. Las Vegas: CVPR, 2016. p. 770-778.

HINTON, G. E.; OSINDERO, S.; TEH, Y.-W. A fast learning algorithm for deep belief nets. **Neural Computation**, v. 18, n. 7, p. 1527-1554, 2006.

LITJENS, G. *et al.* A survey on deep learning in medical image analysis. **Medical Image Analysis**, v. 42, p. 60-88, 2017.

NAGPAL, P.; BHINGE, S. A.; SHITOLE, A. A comparative analysis of ResNet architectures. *In:* SMART GENCON – INTERNATIONAL CONFERENCE ON SMART GENERATION COMPUTING, COMMUNICATION AND NETWORKING, 2022, Bangalore. **Proceedings** [...]. Bangalore: IEEE, 2022. p. 1-8.

PASZKE, A. *et al.* PyTorch: an imperative style, high-performance deep learning library. **arXiv:1912.01703**, v. 32, p. 1-12, 2019. Disponível em: https://arxiv.org/abs/1912.01703. Acesso em: 28 ago. 2025.

RUMELHART, D. E.; HINTON, G. E.; WILLIAMS, R. J. Learning representations by backpropagating errors. **Nature**, London, v. 323, n. 6088, p. 533-538, 1986.

SENGUPTA, S.; ALMASRI, A. ResNet 50. *In*: KOONCE, B. **Convolutional neural networks with swift for tensorflow**: image recognition and dataset categorization. Berkeley: Apress, 2021. p. 63-72. Disponível em: https://link.springer.com/chapter/10.1007/978-1-4842-6168-2_6. Acesso em: 28 ago. 2025.

ZHANG, R. *et al.* Research on image recognition model based on improved ResNet. **IEEE Access**, v. 11, p. 34817-34829, 2023. Disponível em: https://ieeexplore.ieee.org/abstract/document/10083966. Acesso em: 28 ago. 2025.

CONFIRA SUAS RESPOSTAS

1. Alternativa B.

   A ResNet-18 e a ResNet-34 usam blocos simples (sem *bottleneck*), enquanto ResNet-50, ResNet-101 e ResNet-152 utilizam blocos *bottleneck*, permitindo redes profundas com maior eficiência computacional.
   A alternativa A está incorreta, pois nem todas as versões utilizam blocos *bottleneck*. ResNet-18 e ResNet-34 usam blocos simples, enquanto ResNet-50 em diante utilizam *bottleneck*.
   A alternativa C está incorreta, pois as versões da ResNet diferenciam-se principalmente pela quantidade de camadas, não apenas por taxa de aprendizado.
   A alternativa D está incorreta, pois todas as versões ResNet possuem conexões residuais, não somente a ResNet-50, e todas pertencem à arquitetura ResNet, não sendo variantes de CNN tradicionais sem atalhos.
   A alternativa E está incorreta, pois a ResNet-152 é a versão mais profunda da família, com mais camadas e conexões residuais do que a ResNet-18 e a ResNet-34.

2. Alternativa E.

   A ResNet é amplamente utilizada em reconhecimento facial, veículos autônomos e diagnóstico por imagens médicas, devido à sua precisão e robustez, que facilitam o treinamento de redes profundas nessas aplicações.
   A alternativa A está incorreta, pois as conexões residuais não são usadas principalmente em previsão do tempo, mas em tarefas de visão computacional, como reconhecimento facial, veículos autônomos e imagens médicas.
   A alternativa B está incorreta, pois a ResNet é adequada para uso em imagens médicas e lida bem com variações de iluminação e ângulo, sendo utilizada na detecção precoce de doenças em exames de imagem.
   A alternativa C está incorreta, pois redes com conexões residuais são eficazes em sistemas de segurança, justamente porque conseguem reconhecer imagens em tempo real, com precisão.
   A alternativa D está incorreta, pois as conexões residuais são usadas amplamente em ambientes comerciais, e não apenas em pesquisas acadêmicas, sendo aplicadas em sistemas de segurança, celulares e veículos autônomos.

3. Alternativa A.

A afirmativa I está correta, pois a ResNet foi criada para resolver o problema do desaparecimento de gradientes, por meio de conexões residuais (*skip connections*), o que facilita o treinamento de redes muito profundas.
A afirmativa II está incorreta, pois as CNN tradicionais não possuem conexões residuais, portanto, não melhoram a eficiência computacional por esse recurso.
A afirmativa III está incorreta, pois a arquitetura Inception foi introduzida em 2014, e seu foco principal foi aumentar a eficiência computacional, não resolver diretamente o desaparecimento de gradientes.
A afirmativa IV está incorreta, pois as CNN tradicionais têm dificuldade para treinar redes muito profundas devido à dificuldade no fluxo dos gradientes.

MEU ESPAÇO

Unicesumar

unidade

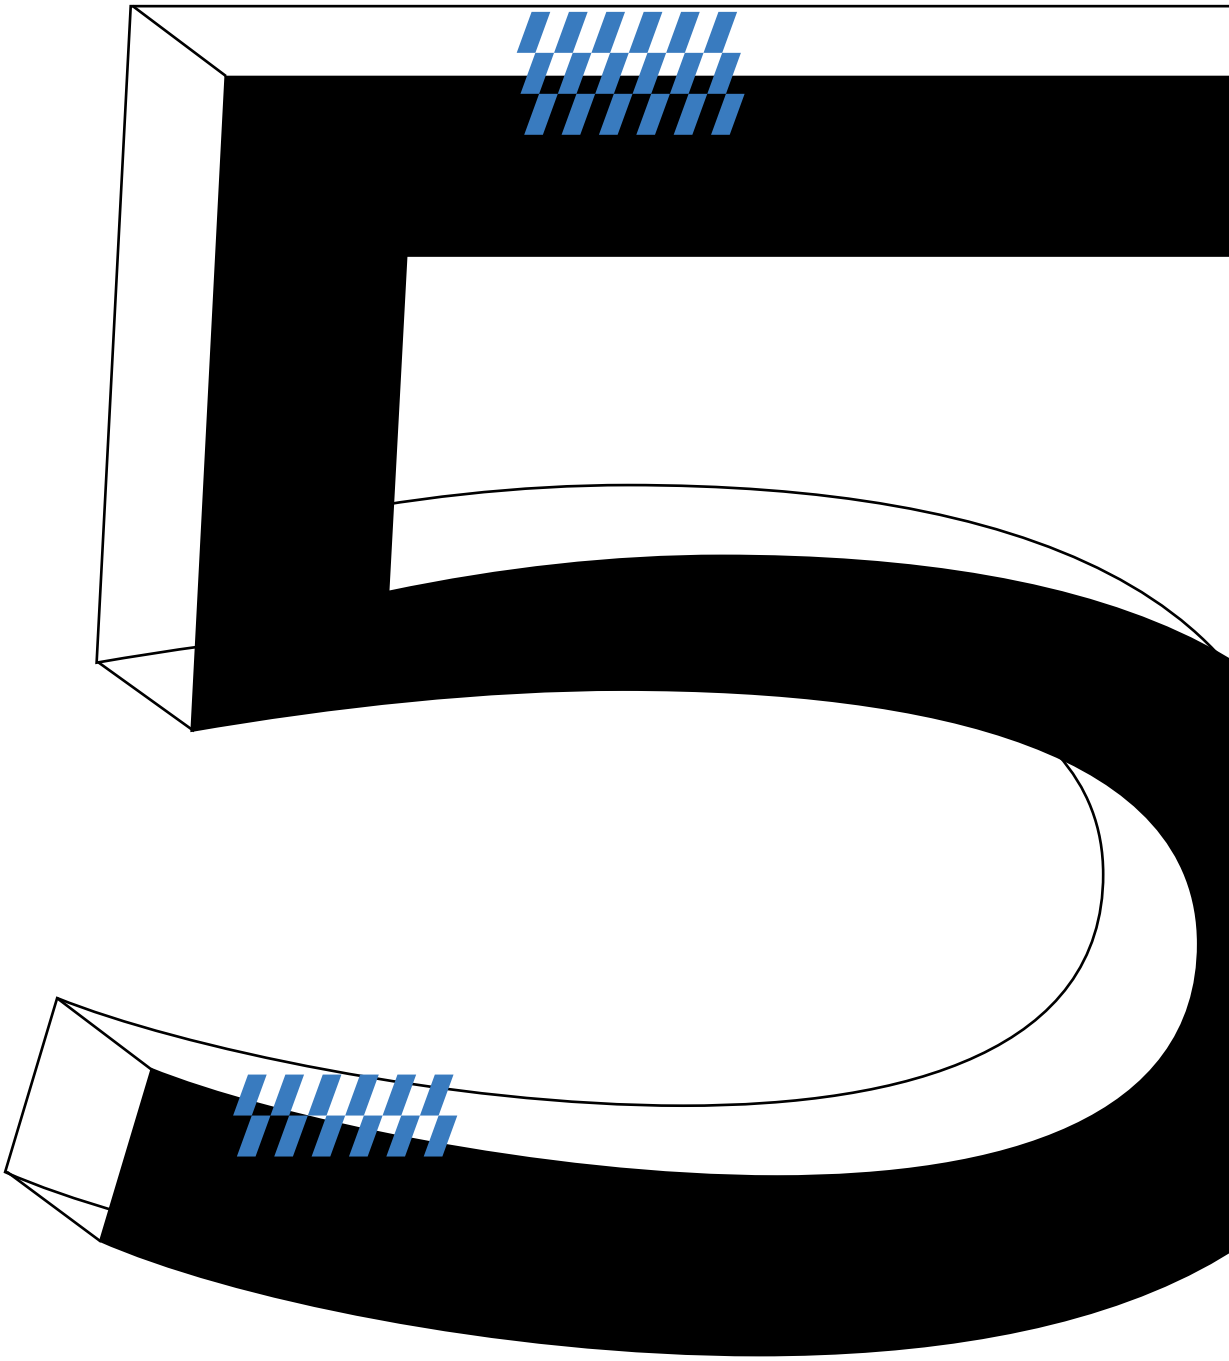

TEMA DE APRENDIZAGEM 8

DENSENET E CONECTIVIDADE OTIMIZADA

MINHAS METAS

- Explicar a estrutura básica de uma DenseNet e sua motivação.
- Descrever a conectividade densa na propagação de gradientes.
- Reutilizar características na DenseNet para um aprendizado otimizado.
- Analisar como as DenseNet utilizam menos parâmetros.
- Investigar a conectividade densa na melhora do fluxo de informação e dos gradientes.
- Comparar DenseNet e ResNet.
- Aplicar DenseNet em um caso prático.

INICIE SUA JORNADA

Imagine que você está montando um grande quebra-cabeça complexo, mas só pode olhar para a peça imediatamente anterior para encaixar a próxima. Se perder alguma peça ou esquecer algum detalhe importante, fica muito difícil completar a imagem corretamente. Isso é parecido com o que acontece em **redes neurais tradicionai**s muito profundas: à medida que a informação passa por muitas camadas, partes importantes podem se perder ou enfraquecer, dificultando o aprendizado e a capacidade da rede de tomar decisões precisas.

A DenseNet propõe uma forma diferente de conectar as camadas da rede, permitindo que cada nova camada tenha acesso a todas as informações já processadas nas camadas anteriores. É como se, ao montar o quebra-cabeça, você pudesse olhar para todas as peças colocadas para decidir qual a próxima a encaixar-se melhor. Assim, a rede reutiliza informações valiosas várias vezes, tornando o processo de aprendizado mais rápido e eficiente.

Para você, estudante e futuro profissional da área, entender essa inovação é essencial no momento de desenvolver modelos de inteligência artificial (IA) que sejam mais robustos e econômicos em termos de recursos computacionais.

Ao experimentar com a DenseNet em projetos práticos, como sistemas de reconhecimento facial, classificação de imagens médicas ou identificação de objetos em vídeos, você aprende a aplicar essa técnica concretamente. Usar todas as "peças" de informação disponíveis ajuda os modelos a tomar decisões mais confiáveis, aumentando a precisão e reduzindo erros. Essa experiência prática é fundamental para consolidar o aprendizado teórico e lhe preparar aos desafios do mercado de trabalho em tecnologia.

Refletir sobre a maneira como a conectividade densa melhora o fluxo de informações na rede nos convida a pensar, de forma mais crítica e criativa, nos desafios do aprendizado profundo. Quando entendemos que a DenseNet ajuda a manter os gradientes fortes e reutiliza eficientemente as características, percebemos como isso não só deixa o modelo mais poderoso, mas também abre portas para ideias inovadoras.

Essa reflexão é essencial para que você, como futuro profissional, se mantenha atualizado, trabalhe as **tecnologias emergentes** com confiança e faça a diferença em projetos avançados de IA.

PLAY NO CONHECIMENTO

Você já imaginou uma tecnologia que consegue identificar, com mais de 99% de acerto, sinais de autismo em crianças, transformando vidas e trazendo esperança para milhares de famílias? Nesse podcast, conheceremos o Capsule DenseNet, o superdetetive do autismo, que usa IA para ajudar no diagnóstico precoce e facilitar o acesso a tratamentos no momento certo. Não perca! **Recursos de mídia disponíveis no conteúdo digital do ambiente virtual de aprendizagem.**

VAMOS RECORDAR?

Suponha que você está usando um aplicativo de reconhecimento de plantas pelo celular. Para ele funcionar bem, o sistema precisa analisar cada detalhe da imagem, "lembrando" e reutilizando informações importantes, a fim de identificar corretamente a planta. É aí que entra uma arquitetura avançada chamada DenseNet. Ela conecta cada camada da rede a todas as anteriores, como se cada parte da análise pudesse acessar tudo que já foi visto antes, facilitando o aprendizado e melhorando a precisão do reconhecimento. Esse tipo de conexão densa faz a rede reutilizar melhor as informações e evita que dados importantes "se percam" no caminho. Vamos recordar melhor como funciona essa arquitetura revolucionária? Acesse:

DESENVOLVA SEU POTENCIAL

INTRODUÇÃO ÀS DENSENET: ESTRUTURA E PRINCÍPIOS

As DenseNet (Densely Connected Convolutional Networks, ou Redes Convolucionais Densamente Conectadas) surgiram em 2017, no trabalho de Gao Huang e colaboradores, com o objetivo de resolver desafios comuns enfrentados pelas redes neurais profundas, como desvanecimento de gradiente, redundância de parâmetros e dificuldade na reutilização eficiente de características ao longo das camadas. Esses problemas podem ser comparados a uma equipe de trabalho na qual várias pessoas realizam a mesma tarefa repetidamente, ocupando espaço e gastando recursos sem trazer informações novas (Huang *et al.*, 2017).

Para facilitar o entendimento, detalhamos, a seguir, cada um desses desafios:

DESVANECIMENTO DE GRADIENTE

Em redes profundas, ao passar por muitas camadas, os ajustes necessários para o aprendizado — os gradientes — vão ficando cada vez menores, dificultando o treinamento das camadas iniciais.

REDUNDÂNCIA DE PARÂMETROS

Grandes redes possuem muitos parâmetros (pesos) e, muitas vezes, diferentes camadas aprendem as mesmas informações sem necessidade, consequentemente, desperdiçam memória e processamento

DIFICULDADE DE REUTILIZAÇÃO DE CARACTERÍSTICAS

Em redes tradicionais, cada camada utiliza apenas as informações da anterior. Se uma camada aprende algo importante, como identificar um contorno em uma imagem, essa informação nem sempre é aproveitada eficientemente nas próximas camadas.

Para resolver esses problemas, as DenseNet implementaram um sistema de conexões diretas entre todas as camadas da rede, permitindo que cada camada receba como entrada os mapas de características de todas as camadas anteriores. Diferentemente das arquiteturas tradicionais, em que cada camada envia informações somente para a próxima, as DenseNet criam um fluxo denso e contínuo de informações e gradientes ao longo de toda a rede, a fim de garantir que características importantes aprendidas nas camadas iniciais sejam reutilizadas pelas camadas seguintes (Huang *et al.*, 2017).

Ainda segundo esses autores, na prática, isso significa que as DenseNet aproveitam melhor as informações aprendidas, reduzem significativamente o número de parâmetros necessários e facilitam o treinamento de redes profundas sem perda de desempenho. Essa estrutura não apenas melhora a eficiência computacional, mas também aumenta a capacidade de generalização do modelo, tornando as DenseNet uma escolha poderosa e eficaz em tarefas de visão computacional, como classificação e segmentação de imagens, com resultados de destaque em diversos *benchmarks*.

ZOOM NO CONHECIMENTO

A palavra *benchmark* significa "referência" ou "ponto de comparação". Em redes neurais e ciência de dados, *benchmark* refere-se a testes padronizados usados para medir e comparar o desempenho de modelos de IA em tarefas específicas, como classificação ou segmentação de imagens, de forma justa e sob as mesmas condições (Huang *et al.*, 2017).

As DenseNet aproveitam melhor as informações aprendidas, reduzem significativamente o número de parâmetros necessários e facilitam o treinamento de redes profundas

CONECTIVIDADE DENSA: O QUE É? POR QUE IMPORTA NAS REDES NEURAIS?

Nas últimas décadas, as redes neurais profundas tornaram-se a espinha dorsal de muitos avanços em IA, especialmente em áreas como visão computacional, processamento de linguagem natural e reconhecimento de voz. Conforme essas redes, no entanto, se tornaram mais profundas, ou seja, com maior número de camadas, surgiram diversos desafios relacionados ao treinamento eficiente e ao uso eficaz dos recursos computacionais. Um dos conceitos mais inovadores para superar esses desafios é a conectividade densa, que tem revolucionado como as redes neurais processam informações (Huang *et al.*, 2017).

A conectividade densa refere-se a uma arquitetura de rede na qual cada camada é diretamente conectada a todas as outras camadas anteriores na rede, formando uma malha de conexões que permite um fluxo contínuo e abrangente de informações. Diferentemente das arquiteturas tradicionais, onde cada camada recebe a saída somente da camada imediatamente anterior, nas DenseNet, cada camada recebe como entrada os mapas de características de todas as camadas anteriores e passa suas próprias características a todas as seguintes. Isso cria uma conectividade muito mais rica, além de promover a reutilização de informações ao longo de toda a rede (Huang *et al.*, 2017). Mas por que a conectividade densa é importante? Veremos as respostas a essa questão segundo Bengio, Simard e Frasconi (1994), He *et al.* (2016) e Huang *et al.* (2017):

MELHORA O FLUXO DE GRADIENTES DURANTE O TREINAMENTO

O treinamento de redes profundas envolve o ajuste de pesos por meio da retropropagação de erros (gradientes). Em redes muito profundas, os gradientes tendem a diminuir à medida que são propagados para camadas anteriores, um fenômeno conhecido como desvanecimento de gradiente, o qual dificulta o aprendizado das camadas iniciais.

REUTILIZAÇÃO EFICIENTE DE CARACTERÍSTICAS

Como cada camada tem acesso a todas as informações previamente extraídas, é possível reutilizar padrões e características importantes sem precisar reaprendê-los repetidamente. Essa ação reduz a redundância e aumenta a eficiência do modelo.

REDUÇÃO DO NÚMERO DE PARÂMETROS

A conectividade densa promove o compartilhamento de informações, o que possibilita a construção de redes mais compactas, mais leves, utilizando menos parâmetros do que arquiteturas tradicionais de profundidade semelhante. Assim, são gerados modelos menos propensos a *overfitting* e mais rápidos para treinar e executar.

MELHORIA NA CAPACIDADE DE GENERALIZAÇÃO

Ao facilitar o treinamento e evitar a redundância, as redes com conectividade densa costumam apresentar melhor capacidade de generalizar para dados não vistos, o que é crucial ao desempenho em situações do mundo real.

Esses fundamentos tornam as DenseNet uma das arquiteturas mais inovadoras e influentes no campo da IA, atualmente. Elas são amplamente utilizadas em aplicações que exigem alta precisão e eficiência, especialmente na visão computacional, abrangendo desde sistemas de reconhecimento facial até diagnósticos médicos por imagem e veículos autônomos. Além disso, a capacidade das DenseNet de reutilizar informações torna esses modelos mais ágeis e menos custosos em termos computacionais, características essenciais para aplicações em dispositivos móveis e em tempo real.

A conectividade densa, que sustenta essa estrutura, representa um avanço significativo ao superar limitações históricas das redes profundas, promovendo, assim, a reutilização eficiente de informações e mais eficiência no treinamento. Por essas razões, essa arquitetura segue sendo um pilar fundamental no avanço da IA em problemas complexos do mundo real (Huang *et al.*, 2017).

EU INDICO

O material *Redes Densamente Conectadas* (DenseNet), do livro *Dive into Deep Learning* (D2L), traz uma explicação clara e prática sobre a arquitetura DenseNet, incluindo exemplos em PyTorch. É ideal para quem quer entender a teoria e aplicá-la em projetos reais. O capítulo explica blocos densos, camadas de transição e como elas melhoram tanto a eficiência quanto o desempenho. Acesse:

ARQUITETURA DENSENET

A DenseNet é uma rede neural convolucional (CNN) que se diferencia das arquiteturas tradicionais por sua conectividade densa, onde cada camada recebe como entrada os mapas de características de todas as camadas anteriores. Essa característica faz a rede reutilizar melhor as informações, facilitar o fluxo de gradientes e reduzir a redundância de parâmetros.

Conforme Huang *et al.* (2017), para lidar com o problema das diferentes dimensões dos mapas de características ao longo da rede — problema esse causado por operações de *downsampling* — a DenseNet é organizada em blocos chamados *dense blocks* (blocos densos), separados por *transition layers* (camadas de transição).

Veremos, com mais detalhes, esses elementos, a seguir:

BLOCOS DENSOS (*DENSE BLOCKS*)

Cada bloco denso é composto por várias camadas convolucionais interligadas de forma especial. Dentro do bloco, as conexões são densas. Isso significa que a saída de cada camada não apenas passa para a próxima camada, mas também é concatenada com as saídas de todas as camadas anteriores do mesmo bloco. Essa conexão em forma de "atalho" faz as informações extraídas em diferentes níveis serem reutilizadas continuamente, o que melhora a eficiência da rede. Além disso, o tamanho dos mapas de características (largura e altura) permanece constante durante todo o bloco, facilitando essa concatenação sem necessidade de ajustes (Yu *et al.*, 2019).

CAMADAS DE TRANSIÇÃO (*TRANSITION LAYERS*)

As camadas de transição estão localizadas entre os Dense Blocks, realizando operações de redução dimensional para evitar que a rede fique muito pesada e para facilitar o processamento nas etapas seguintes. Normalmente, essas camadas consistem em uma sequência de operações: primeiro, a normalização em lote (Batch Normalization), que ajuda a acelerar o treinamento e estabilizar a rede; em seguida, a função de ativação ReLU, cuja função é introduzir não linearidade; depois, uma convolução 1x1, a qual reduz o número de canais, diminuindo a complexidade computacional; por fim, um *pooling* médio 2x2, que realiza o *downsampling*, reduzindo a dimensão espacial dos mapas de características pela metade. Dessa forma, as camadas de transição fazem o *downsampling* dos dados e diminuem tanto a resolução espacial quanto a quantidade de canais antes de a informação ser transmitida ao próximo bloco denso, mantendo o modelo eficiente e eficaz (Huang et al., 2017).

CAMADA DE ENTRADA (*INPUT LAYER*)

A camada de entrada, geralmente, consiste em uma convolução inicial que processa a imagem recebida, por meio da extração de características básicas e preparação dos mapas de características para o primeiro *dense block*. Essa etapa é essencial ao ajuste da resolução e do número de canais dos dados, facilitando o aprendizado das representações nas camadas seguintes. A convolução inicial ajuda a reduzir a complexidade dos dados de entrada, deixando-os prontos para o processamento mais profundo da rede (Goodfellow; Bengio; Courville, 2016).

CAMADA DE SAÍDA (*OUTPUT LAYER*)

A camada de saída é responsável por transformar as características extraídas pelas camadas anteriores em uma predição final. Normalmente, ela inclui uma operação de *pooling* global que reduz a dimensão espacial dos mapas de características para um vetor compacto, seguido por uma camada totalmente conectada (*fully connected*). Esta, por sua vez, gera as probabilidades de cada classe, usando uma função de ativação adequada, como *softmax*, aos problemas de classificação multiclasse. Essa estrutura permite que a rede entregue uma saída possível de ser interpretada para tomada de decisão Goodfellow; Bengio; Courville, 2016).

EU INDICO

O artigo de Aman Arora, intitulado *DenseNet Architecture Explained with PyTorch Implementation from TorchVision*, oferece uma explicação detalhada da arquitetura DenseNet, desde os blocos densos até a implementação prática utilizando PyTorch e TorchVision. Esse material é altamente recomendável para quem busca compreender profundamente o funcionamento da DenseNet e sua aplicação em projetos. Acesse:

O fluxo da DenseNet começa com a imagem de entrada passando por uma convolução inicial, que prepara os mapas de características para o processamento. Em seguida, esses mapas entram no primeiro *dense block*, onde várias camadas convolucionais estão conectadas densamente, permitindo a reutilização eficiente das informações extraídas.

Após o bloco, a saída passa por uma camada de transição que realiza a redução dimensional, controlando o crescimento dos mapas de características e diminuindo a resolução espacial. Esse processo de blocos densos seguidos por camadas de transição repete-se para os demais blocos da rede. Ao final, os mapas de características são processados por operações finais, como *pooling* global e uma camada totalmente conectada, com intuito de gerar a predição da rede (Huang *et al.*, 2017).

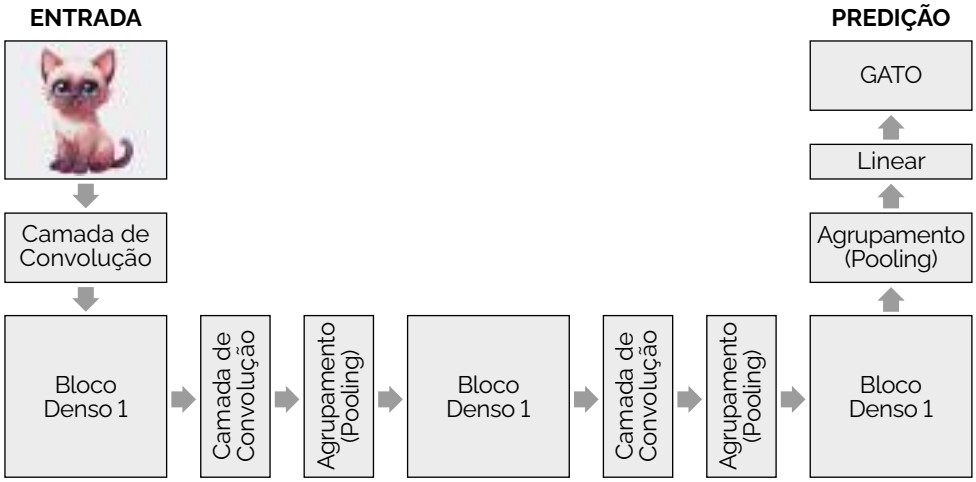

Figura 1 – Mapa de característica para o processamento / Fonte: a autora.

Descrição da Imagem: um fluxo em linha horizontal, da esquerda para a direita. No início, há a ilustração de um gato, representando a entrada da rede. Em seguida, essa informação entra no primeiro *dense block*, onde várias camadas convolucionais estão conectadas densamente. Depois, os dados passam por uma camada de transição, que inclui convolução e agrupamento (*pooling*). Na sequência, a informação entra em um segundo *dense block*, este extrai características mais complexas a partir do aprendizado anterior, passando novamente por uma camada de transição, que, agora, realiza *pooling* para diminuir ainda mais as dimensões. Por fim, os dados passam por uma camada linear que realiza a interpretação final e gera a predição, identificando o contexto: a imagem corresponde a um gato. Fim da descrição.

Como visto na Figura 1, na DenseNet, o processo começa com a camada de entrada, que transforma a imagem em dados numéricos para análise. Em seguida, camadas de convolução extraem características simples, por exemplo, bordas e texturas, preparando os dados para os *dense blocks*, onde várias camadas compartilham informações entre si com intuito de refinar as características aprendidas.

Entre esses blocos, existem as camadas de transição, cuja função é reduzir o tamanho e a quantidade de canais dos dados, usando convolução e *pooling*, para evitar sobrecarga de informações.

Por fim, os dados passam por uma camada linear, a qual interpreta os padrões extraídos e realiza a predição final, indicando o que é a imagem: trata-se de um gato.

REUTILIZAÇÃO DE CARACTERÍSTICAS E EFICIÊNCIA COMPUTACIONAL EM REDES PROFUNDAS

Uma das principais vantagens da DenseNet está na sua maneira inteligente de reutilizar informações ao longo de toda a rede.

VOCÊ SABE RESPONDER?

Mas o que, exatamente, são essas informações?

Em redes neurais, chamamos de características os padrões ou detalhes que a rede identifica nos dados de entrada. Por exemplo, em uma imagem, as primeiras camadas detectam bordas, formas e texturas, ou seja, detalhes básicos, enquanto as camadas mais profundas combinam essas informações para reconhecer objetos mais complexos, como rostos ou tumores (Huang *et al.*, 2017).

Diferentemente de arquiteturas tradicionais, onde cada camada recebe apenas o resultado da anterior, a DenseNet conecta cada camada a todas as seguintes, compartilhando todas as características já apreendidas. Isso significa que detalhes simples e importantes permanecem acessíveis até nas camadas mais profundas, permitindo que a rede construa um conhecimento progressivamente mais detalhado. Essa reutilização eficiente de características é como montar um quebra-cabeça: você aproveita as peças já encaixadas para avançar e, assim, torna o aprendizado mais rápido e eficaz.

A DenseNet é muito econômica no uso dos chamados parâmetros. Estes são os "ajustes" que a rede aprende durante o treinamento, números que definem a força das conexões entre os neurônios, por exemplo. Quanto mais parâmetros, mais complexa e capaz de aprender a rede é, mas também maior é o consumo de memória e de poder de processamento. Como a DenseNet reaproveita as características já extraídas, ela precisa de menos parâmetros para alcançar bons resultados, consequentemente, reduz a redundância, além de tornar o modelo mais leve e eficiente (Huang *et al.*, 2017).

Essa forma de conectar as camadas traz várias vantagens práticas: o treinamento da rede é facilitado porque o fluxo das informações e dos gradientes — que guiam o aprendizado — não se perde ao longo das camadas profundas, a rede aprende mais rápido e com menos desperdício de recursos e, ainda, consegue capturar detalhes minuciosos, essenciais às tarefas que exigem alta precisão (Huang *et al.*, 2017).

Na prática, essa estrutura faz a DenseNet ser especialmente eficaz em aplicações dependentes da detecção de detalhes pequenos e importantes. Assim, a DenseNet une precisão, eficiência computacional e profundidade de aprendizado, tornando-se uma ferramenta poderosa para profissionais e pesquisadores que buscam soluções avançadas em visão computacional, principalmente em contextos cujos recursos são limitados, e a qualidade dos detalhes, essencial (Kumar; Sankar, 2024).

COMPARAÇÃO ENTRE DENSENET E RESNET: DIFERENÇAS E APLICAÇÕES PRÁTICAS

ResNet e DenseNet são arquiteturas de redes neurais profundas que resolvem o problema do desaparecimento do gradiente, mas utilizam estratégias diferentes.

A ResNet usa conexões residuais (atalhos) que somam a entrada diretamente na saída de blocos de camadas, possibilitando treinar redes muito profundas sem degradação de desempenho. Já a DenseNet conecta cada camada a todas as camadas seguintes, concatenando suas saídas, o que facilita a reutilização de características e reduz a quantidade de parâmetros, por diminuir a necessidade de aprender características redundantes (Kumar; Sankar, 2024).

Na prática, a ResNet é eficiente em tarefas gerais de classificação e detecção de objetos devido à sua simplicidade e à estabilidade de treinamento em redes profundas. Essas características vêm do fato de as conexões dessa arquitetura residuais fazerem os gradientes fluírem sem bloqueios durante o treinamento, facilitando o ajuste de redes com dezenas ou centenas de camadas. Por isso, a ResNet é amplamente utilizada em sistemas de visão computacional em tempo real, como câmeras de segurança inteligentes, sistemas de monitoramento de tráfego e classificação de imagens em larga escala, na qual a velocidade de processamento bem como a facilidade de implementação são essenciais (Kumar; Sankar, 2024).

Segundo esses mesmos autores, a DenseNet destaca-se em cenários que exigem alta eficiência de parâmetros e melhor propagação de características entre as camadas, pois cada camada recebe como entrada os mapas de características de todas as camadas anteriores. Essa característica torna a DenseNet altamente eficaz em tarefas em que cada detalhe da imagem pode impactar o resultado, como em diagnósticos médicos por imagem (detecção de tumores, análise de radiografias ou ressonâncias), análise de imagens de satélite para identificar pequenas alterações ambientais e inspeção de qualidade em linhas de produção, onde detalhes mínimos podem indicar defeitos.

Além disso, a DenseNet tende a possuir menos parâmetros que redes tradicionais de profundidade semelhante, portanto, ela utiliza a informação extraída de forma mais eficiente e reduz redundâncias no aprendizado de características. Tal fato contribui para maior generalização em conjuntos de dados menores, um cenário comum em aplicações médicas (Kumar; Sankar, 2024).

Por exemplo, Kumar e Sankar (2024), em seu estudo *Comparative Analysis of Convolutional Neural Networks for Brain Tumor Detection: A Study of VGG16, ResNet, Inception, and DenseNet Models*, abordaram as arquiteturas **ResNet** e **DenseNet** no contexto de detecção de tumores cerebrais. Eles demonstraram que, ao utilizar a ResNet, obtiveram mais velocidade de treinamento, sendo efi-

ciente para sistemas com necessidade de processamento rápido. Já com a DenseNet, alcançaram melhor extração de características sutis nas imagens médicas, essencial para diagnósticos mais detalhados e precisos.

Esse estudo evidenciou que cada arquitetura traz vantagens específicas: a ResNet favorece a rapidez e estabilidade em tarefas gerais, enquanto a DenseNet é a preferida quando se busca máxima riqueza de detalhes na análise de imagens.

A seguir, apresentaremos um quadro comparativo entre as diferentes arquiteturas:

ASPECTOS	RESNET	DENSENET
Conexão entre camadas	Soma residual (atalhos).	Concatenação densa entre todas as camadas.
Uso de parâmetros	Mais parâmetros.	Menos parâmetros pela reutilização.
Treinamento	Estável, rápido.	Mais lento, porém detalhado.
Aplicações práticas	Classificação geral, detecção em tempo real.	Diagnóstico por imagem, tarefas detalhadas.

Quadro 1 – Análise comparativa das arquiteturas ResNet e DenseNet
Fonte: adaptado de Kumar e Sankar (2024).

Portanto, a escolha entre ResNet e DenseNet deve ser guiada pelo objetivo prático da aplicação: se a prioridade for velocidade de processamento e facilidade de implementação, a ResNet mostra-se uma opção robusta; mas, se o foco estiver na captura de detalhes finos e no aproveitamento máximo das características extraídas, a DenseNet representa a escolha mais indicada.

EM FOCO

Confira a aula referente a este tema. **Recursos de mídia disponíveis no conteúdo digital do ambiente virtual de aprendizagem.**

NOVOS DESAFIOS

Para aprender de verdade a DenseNet, não basta apenas decorar conceitos teóricos, é preciso conectar esse conhecimento à prática, para que ele faça sentido e se transforme em habilidade real. Quando a teoria está atrelada à prática, o aprendizado torna-se mais palpável, dinâmico e capaz de ser aplicado a problemas concretos do dia a dia.

A DenseNet é uma arquitetura avançada de redes neurais que conecta cada camada da rede a todas as outras anteriores. Essa característica faz toda a diferença em aplicações reais que você, talvez, use ou veja no cotidiano. Por exemplo, em sistemas de reconhecimento facial usados para desbloquear smartphones ou em câmeras de segurança, a DenseNet ajuda a identificar rostos mesmo quando há pouca luz ou ângulos difíceis.

Na área da saúde, ela contribui para a análise de imagens médicas, auxiliando na detecção precoce de doenças como câncer, por meio da identificação de padrões que seriam difíceis de um olhar humano perceber rapidamente.

Em veículos autônomos, a DenseNet possibilita que o carro "enxergue" o ambiente ao redor e tome decisões em frações de segundo, a fim de evitar acidentes. Além disso, a DenseNet também está presente em assistentes virtuais que entendem melhor as perguntas feitas por você, em sistemas de tradução automática que quebram barreiras linguísticas e em plataformas de streaming cujas recomendações de conteúdos personalizados são realizados com mais precisão.

O impacto dessas tecnologias só tende a crescer. Com a capacidade de processar informações complexas de maneira mais eficiente, a DenseNet está moldando o futuro da IA, abrindo caminho às inovações que podem melhorar a qualidade de vida, otimizar processos industriais, revolucionar o agronegócio e transformar a educação.

Portanto, entender a DenseNet não é somente uma questão acadêmica, é preparar-se para um mercado de trabalho que exige, cada vez mais, profissionais capazes de aplicar teoria em projetos reais, por meio do desenvolvimento de soluções tão inovadoras quanto competitivas. Ao unir teoria e prática, você constrói uma base sólida para se destacar, contribuir com avanços tecnológicos e estar à frente nas carreiras do futuro.

VAMOS PRATICAR

1. **Durante o estudo de CNN profundas, você depara-se com as DenseNets (Densely Connected Convolutional Networks), que surgiram em 2017, no trabalho de Gao Huang e colaboradores. Ao pesquisá-las, vê que possuem um arranjo de conexões diferenciado em relação a outras arquiteturas.**

   Com base nesse texto, qual é a definição correta das DenseNets?

   a) Redes convolucionais que utilizam apenas conexões residuais simples, onde a saída de cada camada é somada diretamente à entrada da próxima camada
   b) Redes em que cada camada é conectada apenas à camada imediatamente anterior e posterior, com o objetivo de reduzir drasticamente o número de parâmetros.
   c) Redes convolucionais que utilizam camadas independentes entre si, visando à especialização de cada uma delas em uma única característica.
   d) Redes em que as camadas compartilham pesos entre si para reduzir a complexidade computacional durante o treinamento
   e) Redes em que cada camada recebe, como entrada, as saídas de todas as camadas anteriores, permitindo reutilização de características e melhor fluxo de gradiente durante o treinamento.

2. **As DenseNets, devido à sua arquitetura inovadora e eficiência no treinamento, têm sido aplicadas em diversas áreas de IA e visão computacional.**

   Considerando as principais aplicações dessa arquitetura, assinale a alternativa correta:

   a) DenseNets são exclusivamente utilizadas para processamento de linguagem natural, sem aplicação significativa em imagens.
   b) DenseNets são usadas apenas em redes superficiais para reconhecimento simples, não sendo adequadas para tarefas complexas.
   c) DenseNets são indicadas principalmente para sistemas de recomendação, sem impacto em tarefas de classificação visual.
   d) DenseNets são amplamente aplicadas em tarefas de visão computacional, como reconhecimento de objetos, segmentação de imagens e diagnóstico médico por imagens.
   e) DenseNets são empregadas apenas para compressão de dados, sem uso em aprendizado profundo.

3. As DenseNets (Densely Connected Convolutional Networks) utilizam a conectividade densa como característica central de sua arquitetura, trazendo benefícios importantes para o treinamento e desempenho de redes profundas. Essa estratégia de conectividade impacta diretamente na qualidade do aprendizado e na capacidade de generalização da rede em tarefas práticas de visão computacional e outras aplicações (Huang *et al.*, 2017).

   Analise as afirmativas, a seguir, em relação aos benefícios da conectividade densa em DenseNets:

   I - Melhora o fluxo de gradientes durante o treinamento, evitando o desvanecimento de gradientes em redes profundas.
   II - Permite reutilização eficiente de características, reduzindo redundâncias e evitando reaprendizagem de padrões já extraídos.
   III - Contribui para a redução do número de parâmetros, tornando o modelo mais leve e menos propenso a *overfitting*.
   IV - Melhora a capacidade de generalização em dados não vistos, favorecendo o desempenho em situações reais.

   É correto o que se afirma em:

   a) I, apenas.
   b) II e IV, apenas.
   c) III e IV, apenas.
   d) I, II e III, apenas.
   e) I, II, III e IV.

REFERÊNCIAS

BENGIO, Y.; SIMARD, P.; FRASCONI, P. Learning long-term dependencies with gradient descent is difficult. **IEEE Transactions on Neural Networks**, v. 5, n. 2, p. 157-166, 1994.

GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. **Deep learning**. Cambridge: The MIT Press, 2016.

HE, K. *et al.* Deep residual learning for image recognition. *In:* CVPR – CONFERENCE ON COMPUTER VISION AND PATTERN RECOGNITION, 28., 2016, Las Vegas. **Proceedings** [...]. Las Vegas: CVPR, 2016. p. 770-778.

HUANG, G. *et al.* Densely connected convolutional networks. *In:* CVPR – CONFERENCE ON COMPUTER VISION AND PATTERN RECOGNITION, 29., 2017, Honolulu. **Proceedings** [...]. Honolulu: CVPR, 2017. p. 4700-4708.

KUMAR, C. M.; SANKAR, J. S. Comparative analysis of convolutional neural networks for brain tumor detection: a study of VGG16, ResNet, Inception, and DenseNet models. *In:* ICAAIC – INTERNATIONAL CONFERENCE ON APPLIED ARTIFICIAL INTELLIGENCE AND COMPUTING, 3., 2024, Salem, India. **Proceedings** [...]. Salem, India: IEEE, 2024. p. 41-46.

YU, J. et al. Fully convolutional densenets for polyp segmentation in colonoscopy. *In*: ICDEW – INTERNATIONAL CONFERENCE ON DATA ENGINEERING WORKSHOPS, 35., 2019, Macao. **Proceedings** [...]. Macao: IEEE, 2019. p. 306-311.

CONFIRA SUAS RESPOSTAS

1. Alternativa E.

   As DenseNets são redes em que cada camada recebe, como entrada, as saídas de todas as camadas anteriores dentro de um bloco, por concatenação, permitindo reutilização de características, melhor propagação de gradientes durante o treinamento, além de reduzir o problema do desaparecimento do gradiente em redes muito profundas.
   A alternativa A está incorreta, pois as DenseNets não utilizam apenas conexões residuais simples, como em ResNets, onde a saída é somada à entrada da próxima camada. Em DenseNets, as saídas são concatenadas (não somadas) e passadas para todas as camadas seguintes, formando conexões densas em vez de simples atalhos.
   A alternativa B está incorreta, pois as DenseNets não se conectam apenas à camada imediatamente anterior e posterior. Pelo contrário, cada camada recebe, como entrada, as saídas de todas as camadas anteriores no mesmo bloco, justamente para aumentar a reutilização de características e melhorar o fluxo de gradiente, mesmo que isso mantenha a quantidade de conexões elevada.
   A alternativa C está incorreta, pois as DenseNets não possuem camadas independentes entre si. Na realidade, o princípio central das DenseNets é interligar todas as camadas densamente em vez de isolar cada uma para se especializar em uma única característica. Essa conexão densa aumenta a eficiência do uso das características extraídas.
   A alternativa D está incorreta, pois as DenseNets não compartilham pesos entre as camadas. Cada camada possui seus próprios filtros e parâmetros, mas recebe, como entrada, todas as saídas anteriores por concatenação, o que é diferente de compartilhar pesos, como em algumas redes recorrentes ou arquiteturas específicas de compressão.

2. Alternativa D.

   As DenseNets são amplamente aplicadas em visão computacional, incluindo reconhecimento de objetos, segmentação de imagens e diagnóstico médico por imagens, graças à sua capacidade de reutilizar características e melhorar o fluxo de informações em redes profundas.
   A alternativa A está incorreta, pois DenseNets são arquiteturas projetadas para as CNN, especialmente focadas em processamento de imagens, não sendo exclusivas ao processamento de linguagem natural.
   A alternativa B está incorreta, pois DenseNets são projetadas para redes profundas e conseguem lidar muito bem com tarefas complexas de reconhecimento e extração de características em imagens, não apenas redes superficiais.
   A alternativa C está incorreta, pois DenseNets têm impacto significativo em tarefas de visão computacional, como classificação e segmentação de imagens, e não são indicadas principalmente para sistemas de recomendação.
   A alternativa E está incorreta, pois DenseNets não são usadas apenas para compressão de dados, seu principal uso está em aprendizado profundo à extração eficiente de características em imagens.

3. Alternativa E.

A afirmativa I está correta, pois a conectividade densa melhora o fluxo de gradientes durante o treinamento, assim, evita que os gradientes desapareçam em redes profundas. Isso ocorre porque cada camada recebe conexões diretas de todas as camadas anteriores, facilitando a retropropagação dos gradientes e permitindo o aprendizado eficaz mesmo em redes muito profundas.
A afirmativa II está correta, pois, com a conectividade densa, cada camada tem acesso a todas as características previamente extraídas, podendo reutilizar padrões sem precisar reaprendê-los em cada camada. Esse aspecto aumenta a eficiência, reduz redundâncias e aproveita melhor o que foi aprendido.
A afirmativa III está correta, pois a conectividade densa possibilita a redução do número de parâmetros, afinal, o modelo pode ser projetado com menos filtros por camada, aproveitando as características já disponíveis pelas conexões densas. Isso gera modelos mais compactos, rápidos e com menor risco de *overfitting*.
A afirmativa IV está correta, pois a conectividade densa melhora a capacidade de generalização, afinal, ao facilitar o treinamento e evitar redundâncias, a rede consegue aprender representações mais robustas que se aplicam bem a dados não vistos, o que é crucial para o desempenho em aplicações reais.

MEU ESPAÇO

TEMA DE APRENDIZAGEM 9

APLICAÇÕES E FUTURO DAS REDES CONVOLUCIONAIS

MINHAS METAS

- Explicar como as CNN são utilizadas em diagnósticos médicos por imagem.
- Apresentar aplicações das CNN em sistemas de segurança e vigilância.
- Analisar os avanços de arquiteturas eficientes, como a EfficientNet.
- Discutir o papel da *Attention* em redes convolucionais.
- Apontar a integração dos Transformers na visão computacional.
- Explorar desafios atuais nas aplicações das CNN no mundo real.
- Refletir sobre tendências futuras e pesquisa em CNN para visão computacional.

INICIE SUA JORNADA

Você já parou para pensar que, há alguns anos, seria impossível imaginar câmeras de segurança identificando sozinhas movimentos suspeitos, em tempo real, sem a supervisão constante de uma pessoa? Ou que um simples exame de imagem poderia ser analisado tão rapidamente por um sistema detector de sinais de doenças a ponto de auxiliar os médicos a salvarem vidas? Essas situações que, antes, pareciam ficção, hoje fazem parte do nosso cotidiano e estão cada vez mais presentes nos lugares onde trabalhamos, estudamos ou circulamos.

As redes convolucionais são uma das tecnologias que tornam isso possível, permitindo máquinas "verem" e analisarem imagens, vídeos e padrões de movimento, de forma autônoma e precisa. Para quem está se preparando à atuação no mercado de trabalho nas áreas de tecnologia, saúde, segurança ou automação, conhecer essas aplicações vai além de saber como elas funcionam: significa entender como elas facilitam o dia a dia de empresas, profissionais e cidadãos, transformando desafios em soluções eficientes.

Você pode vivenciar isso na prática, ao desenvolver pequenos projetos que classificam imagens, monitoram ambientes ou detectam objetos em tempo real. Esses projetos costumam ser feitos em sala, em feiras de tecnologia, ou como trabalhos integradores, assim, estimulam a criatividade, a lógica e a autonomia. Experimentar o uso de redes convolucionais em situações reais possibilita que você sinta como essas tecnologias se conectam ao seu aprendizado, transformando teoria em prática, significativamente.

Pensar no futuro dessas tecnologias é, também, pensar no seu próprio futuro profissional: como você pode usar o conhecimento em redes convolucionais para melhorar serviços de saúde na sua comunidade? Como pode contribuir com a segurança de espaços públicos ou privados? De que maneira tornar o atendimento ao cliente mais ágil e humanizado, por meio de sistemas de visão computacional?

Ao refletir sobre essas questões, você posiciona-se como um **profissional preparado** para aplicar soluções tecnológicas de forma ética, responsável e com impacto positivo na sociedade.

PLAY NO CONHECIMENTO

Quer saber se a inteligência artificial (IA) pode criar, sozinha, outras IA? Descubra como a tecnologia dos Transformers está revolucionando o mundo da IA, os avanços incríveis já existentes e os desafios que ainda precisamos enfrentar. Prepare-se para uma viagem pelo futuro das máquinas autônomas, de forma simples e dinâmica, para você, estudante. Ouça já esse podcast. **Recursos de mídia disponíveis no conteúdo digital do ambiente virtual de aprendizagem.**

VAMOS RECORDAR?

Para um aplicativo conseguir identificar diferentes tipos de doenças em exames médicos por imagem, ele precisa analisar cada detalhe da imagem, extraindo e reutilizando informações relevantes para fazer um diagnóstico preciso. Essa capacidade de reconhecimento exige sistemas inteligentes, capazes de aprender com uma grande quantidade de dados e identificar padrões sutis possíveis de passarem despercebidos até mesmo por especialistas. As redes neurais artificiais, inspiradas no funcionamento do cérebro humano, permitem que o sistema melhore o desempenho conforme recebe mais informações. Esse tipo de aplicação tem transformado a medicina, ao acelerar diagnósticos, aumentar a precisão e contribuir para tratamentos mais eficazes. Além da saúde, redes neurais são amplamente usadas em segurança, no monitoramento de ambientes e detecção de comportamentos suspeitos, e no setor industrial, para inspecionar a qualidade de produtos em linhas de produção. Compreender esses fundamentos é essencial a você, que está se preparando para atuar em um mercado cada vez mais tecnológico e dinâmico.

DESENVOLVA SEU POTENCIAL

INTRODUÇÃO ÀS REDES CONVOLUCIONAIS E SUAS APLICAÇÕES

As Redes Neurais Convolucionais (CNN) viraram o jogo na análise de dados visuais. Elas são modelos de aprendizado profundo incrivelmente eficazes para trabalhar com imagens e vídeos. Pense nelas como um cérebro digital que aprende a identificar padrões, desde os mais simples até os mais complexos. Por isso, as CNN são a ferramenta perfeita às tarefas cuja necessidade seja um computador "ver" e "interpretar" o que está em uma imagem (LeCun *et al.*, 1998). Onde as CNN estão fazendo a diferença? Elas estão impulsionando a transformação digital em diversos setores. Podemos citar alguns exemplos:

NA MEDICINA

As CNN já estão ajudando a diagnosticar precocemente o câncer de mama em mamografias, identificar tumores cerebrais em ressonâncias magnéticas e detectar retinopatias diabéticas em exames de retina. Isso significa diagnósticos mais rápidos e precisos, que podem salvar vidas (Litjens *et al.*, 2017).

NA SEGURANÇA

Elas são usadas em sistemas de segurança para reconhecimento facial, monitoramento de comportamentos suspeitos e detecção automática de intrusos. Imagine a eficiência e a rapidez na resposta proporcionada (Zhao *et al.*, 2003).

NA INDÚSTRIA AUTOMOTIVA

Carros autônomos dependem totalmente das CNN para "enxergar" o mundo ao redor. Elas fazem os veículos reconhecer sinais de trânsito, detectar pedestres e obstáculos, e compreender o ambiente, com intuito de tomar decisões em tempo real, tornando a direção autônoma uma realidade (Chen *et al.*, 2015).

NO COMÉRCIO ELETRÔNICO

Comprar on-line ficou mais fácil e intuitivo. As CNN são usadas para reconhecimento visual de produtos, permitindo buscas por imagem e recomendações superpersonalizadas. Elas até mesmo ajudam a analisar o comportamento do consumidor em lojas físicas, por meio de vídeos (Krizhevsky; Sutskever; Hinton, 2012).

NO ENTRETENIMENTO E NAS MÍDIAS SOCIAIS

A diversão e a segurança andam juntas. As CNN estão por trás de recursos como reconhecimento automático de rostos, filtros de realidade aumentada divertidos e moderação de conteúdo visual, garantindo experiências mais interativas e seguras para todos os usuários (Simonyan; Zisserman, 2015).

Essas aplicações mostram o quão impactantes as CNN são. Além de uma tecnologia promissora, também são a força motriz por trás de uma revolução silenciosa que está redefinindo as possibilidades na era digital. A precisão que elas trazem aos diagnósticos médicos, à segurança ou à navegação de veículos autônomos não é apenas uma melhoria incremental, mas sim uma mudança de paradigma que salva vidas e otimiza recursos (LeCun *et al.*, 1998).

INDICAÇÃO DE LIVRO

Artificial Intelligence in Healthcare

Esse livro de Adam Bohr e Kaveh Memarzadeh explora as aplicações práticas da IA na área médica. O conteúdo aborda, entre outros temas, o uso de visão computacional e CNN na análise de exames por imagem, uso esse que auxilia no diagnóstico preciso de diversas doenças. A obra é fundamental para entender como a IA está transformando a medicina e melhorando tanto a eficiência quanto a acurácia dos tratamentos.

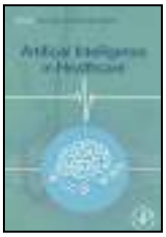

CNN NA MEDICINA: DIAGNÓSTICO E ANÁLISE DE IMAGENS

Máquinas já estão ajudando médicos a detectar doenças graves muito antes do surgimento dos sintomas. As CNN tornam esse cenário possível, ao analisar imagens médicas com alta precisão, identificando padrões sutis que podem indicar o início de diversas condições de saúde. As CNN são sistemas de IA capazes de analisar imagens médicas com uma precisão impressionante, ajudando a salvar vidas (Esteva *et al.*, 2017).

Diferentemente dos humanos, que precisam treinar por anos para reconhecer sinais sutis em uma radiografia ou ressonância, as CNN aprendem sozinhas a identificar padrões em imagens, desde bordas simples até estruturas complexas, tais como tumores ou vasos sanguíneos (Pereira *et al.*, 2016).

As CNN aprendem sozinhas a identificar padrões em imagens

Alguns exemplos práticos dessa aplicação incluem:

CÂNCER DE MAMA

Em mamografias, detectar microcalcificações pode ser um grande desafio para radiologistas. Pesquisas mostram que as CNN conseguem identificar essas alterações com precisão comparável ou até superior a especialistas humanos, a fim de auxiliar no diagnóstico precoce e aumentar as chances de cura (Esteva *et al.*, 2017).

TUMORES CEREBRAIS

Imagens de ressonância magnética (MRI) são analisadas por CNN para localizar e classificar tumores, como gliomas. Essa iniciativa acelera o processo e permite tratamentos mais rápidos (Pereira *et al.*, 2016).

RETINOPATIA DIABÉTICA

Essa doença pode levar à cegueira se não diagnosticada a tempo. Sistemas baseados em CNN foram treinados para examinar imagens da retina e identificar sinais da doença com alta acurácia, possibilitando triagens em larga escala (Gulshan *et al.*, 2016).

PATOLOGIA DIGITAL

Na análise de lâminas histológicas, as CNN ajudam a reconhecer células cancerígenas e diferenciar tipos de tecidos, o que torna os exames mais rápidos bem como reduz erros humanos (Cireşan *et al.*, 2013).

As CNN conseguem trabalhar com grandes volumes de dados, pois aprendem com exemplos e evoluem suas "habilidades" sem descanso. Imagine um sistema que analisa milhares de exames diariamente, para os médicos focarem em casos mais complexos e otimizem recursos da saúde (Esteva *et al.*, 2017; Pereira *et al.*, 2016).

INDICAÇÃO DE FILME

Coded Bias

Documentário que aborda os vieses presentes em sistemas de reconhecimento facial e IA usados em segurança e outras áreas. A partir da descoberta da pesquisadora Joy Buolamwini, o filme mostra como essas tecnologias podem falhar na identificação correta de pessoas negras e mulheres, revelando problemas éticos e sociais.

Refletindo sobre a história: a relação com redes neurais e *deep learning* é importante, porque essas redes são a base dos algoritmos que processam as imagens e dados, e os vieses nos dados de treinamento arriscam causar erros com impactos na vida real.

Para que essas redes sejam realmente confiáveis, é fundamental serem treinadas com grandes volumes de dados de alta qualidade e submetidas a rigorosos testes, a fim de minimizar erros capazes de comprometer a segurança dos pacientes. Além disso, é crucial que os médicos compreendam os critérios usados pela IA para chegar às suas conclusões, garantindo tanto transparência quanto confiança nas recomendações. Por isso, pesquisadores têm dedicado esforços que tornem essas redes mais interpretáveis e as integrem eficazmente ao cotidiano clínico.

A união do conhecimento humano com a velocidade e precisão das CNN abre caminho a uma medicina cada vez mais personalizada, eficiente e acessível (Doshi-Velez; Kim, 2017).

USO DE CNN EM SEGURANÇA E MONITORAMENTO

Sistemas de vigilância já conseguem identificar pessoas suspeitas em meio a multidões e detectar comportamentos anormais antes que algo aconteça. As CNN possibilitam essa revolução na segurança tanto pública quanto privada, tornando os sistemas de monitoramento mais inteligentes e eficazes (Zhao *et al.*, 2003).

As CNN analisam imagens e vídeos em tempo real, com objetivo de aprender a reconhecer rostos, movimentos e situações específicas. Diferentemente dos sistemas tradicionais, que dependem da observação humana constante e podem falhar devido à fadiga ou à distração, as CNN mantêm a vigilância 24 horas por dia, com alta precisão e velocidade (Hasan *et al.*, 2016).

As aplicações reais dessa tecnologia envolvem:

RECONHECIMENTO FACIAL

Em aeroportos, estádios e eventos públicos, as CNN são usadas para identificar indivíduos em listas de procurados, com objetivo de aumentar a segurança e prevenir crimes. Esses sistemas também aceleram processos de identificação, como em controles de acesso (Zhao *et al.*, 2003).

DETECÇÃO DE COMPORTAMENTOS SUSPEITOS

Em ambientes urbanos, as redes convolucionais podem analisar imagens para detectar ações incomuns, como brigas, quedas ou invasões, permitindo respostas rápidas das autoridades (Hasan *et al.*, 2016).

MONITORAMENTO DE TRÁFEGO

Câmeras equipadas com CNN identificam automaticamente infrações, por exemplo, avanço de sinal vermelho, excesso de velocidade e veículos estacionados irregularmente, contribuindo para a organização e a segurança nas cidades (Chen *et al.*, 2015).

CONTROLE DE PERÍMETROS

Em instalações industriais ou áreas restritas, as CNN monitoram continuamente cercas e entradas, detectando tentativas de invasão ou atividades suspeitas mesmo em condições adversas, como baixa luminosidade (Li *et al.*, 2018).

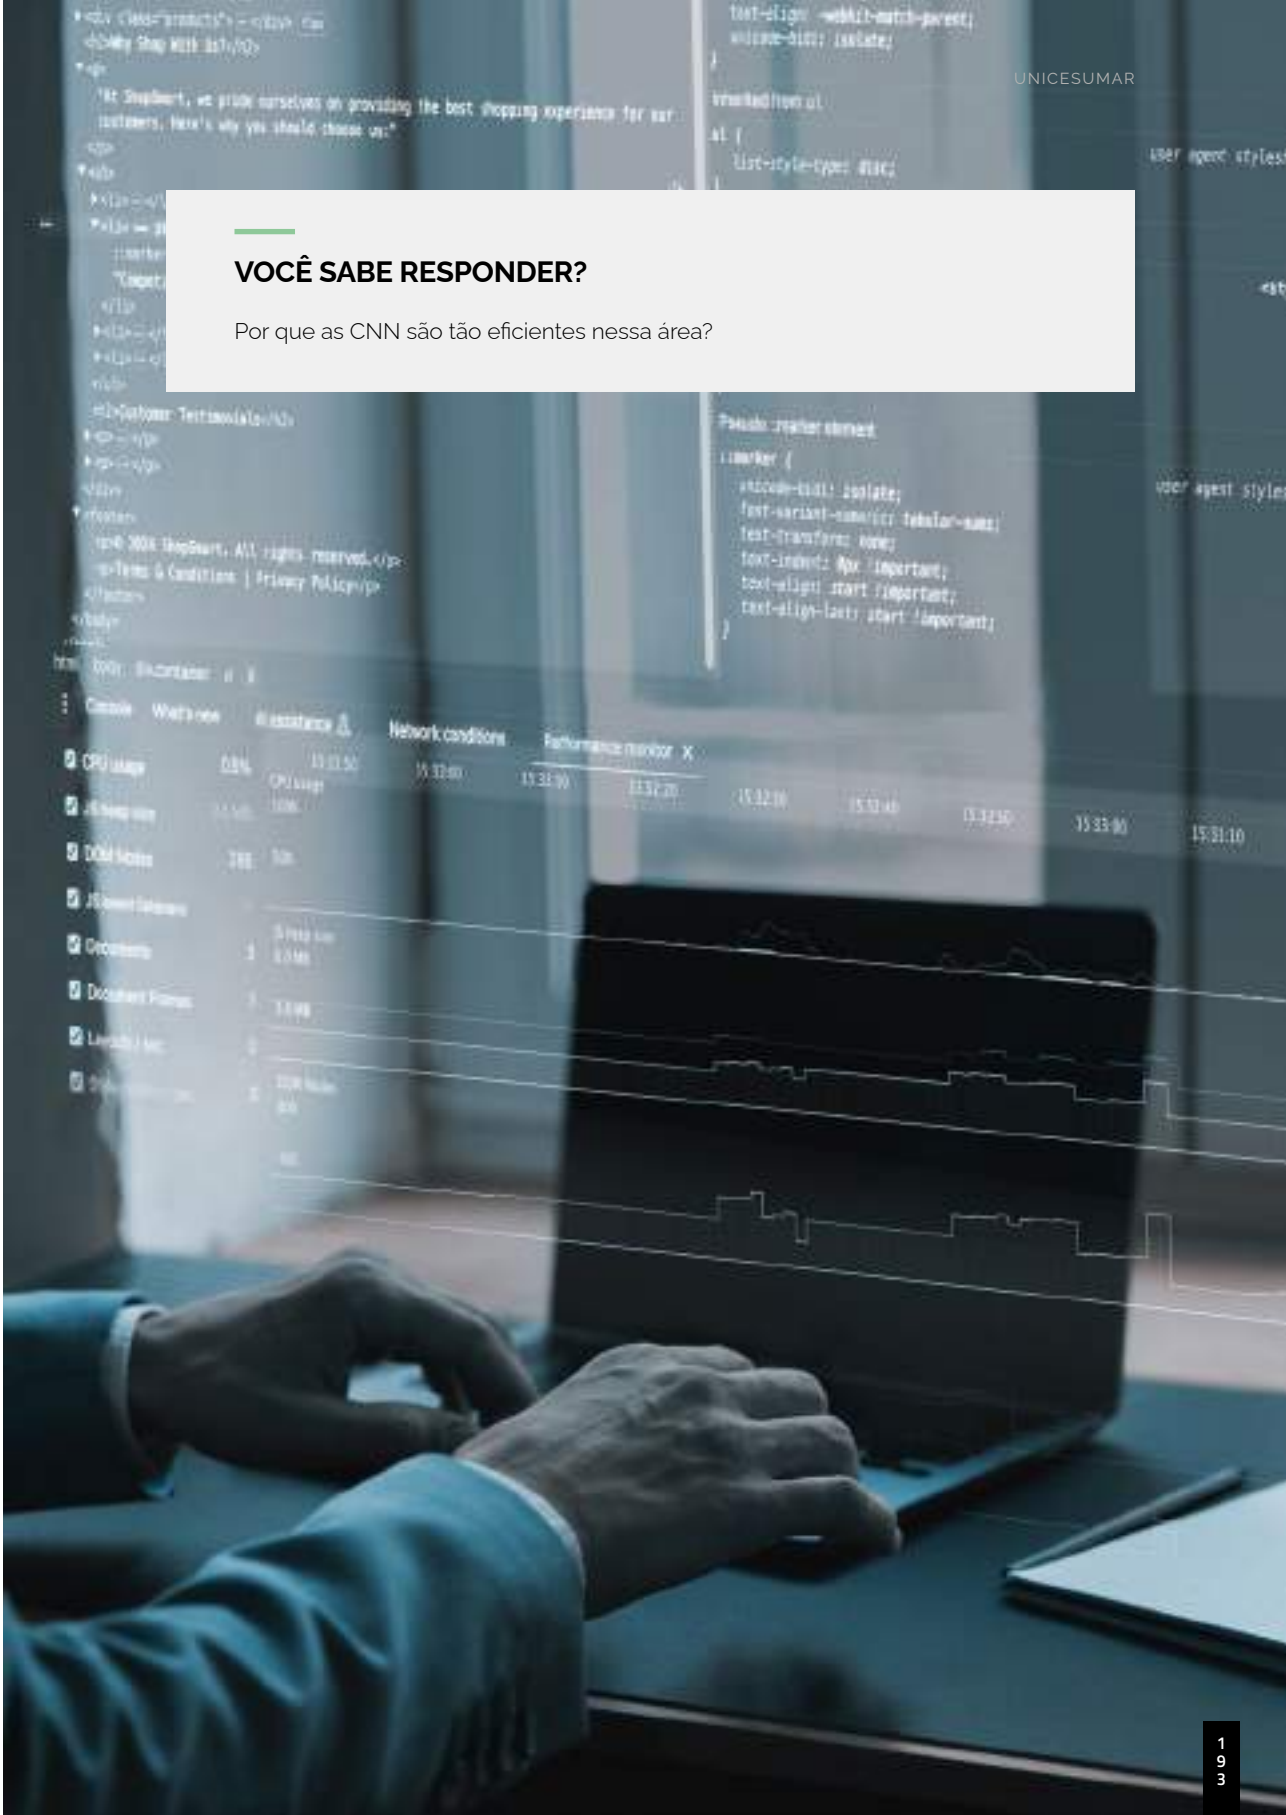

VOCÊ SABE RESPONDER?

Por que as CNN são tão eficientes nessa área?

Porque elas aprendem com grandes volumes de imagens reais e conseguem adaptar-se a diferentes cenários, desde ambientes internos até espaços abertos, funcionando em tempo real e com alta capacidade de processamento (Hasan *et al.*, 2016; Li *et al.*, 2018).

A privacidade, todavia, é um dos principais pontos de debate. É fundamental que o uso dessas tecnologias respeite direitos individuais e seja regulado para evitar abusos. Além disso, o sistema precisa lidar com imagens de baixa qualidade, ângulos diferentes e condições climáticas variadas, o que exige modelos robustos e treinados constantemente (Hasan *et al.*, 2016; Zhao *et al.*, 2003).

O futuro da segurança com as CNN promete ainda mais integração, por meio de sistemas capazes de combinar dados de múltiplas fontes, câmeras, sensores e até drones para criar ambientes mais seguros e responsivos (Li *et al.*, 2018).

AVANÇOS RECENTES: EFFICIENTNET E MECANISMOS DE *ATTENTION*

Os últimos anos trouxeram importantes avanços em redes convolucionais, tornando a IA mais precisa, rápida e eficiente. Dois desses avanços são: o EfficientNet, que aprimora a forma de escalar redes equilibradamente; e os mecanismos de *Attention*, os quais ajudam os modelos a focar em regiões mais relevantes de uma imagem, otimizando a análise e os resultados (Tan; Le, 2019; Vaswani *et al.*, 2023).

O EfficientNet foi desenvolvido por pesquisadores do Google com o objetivo de melhorar a performance das CNN por meio da utilização de menos parâmetros e menos memória. Ao utilizar uma técnica chamada *compound scaling*, o EfficientNet aumenta, equilibradamente, a profundidade, a largura e a resolução das redes, alcançando alta precisão em tarefas de classificação de imagens sem consumir grandes recursos computacionais. Esse modelo tem sido utilizado em aplicações como diagnósticos de doenças de pele e oculares, sendo eficiente para análise em tempo real e em larga escala, inclusive em dispositivos móveis (Tan; Le, 2019).

ZOOM NO CONHECIMENTO

Compound scaling é uma técnica que ajusta equilibradamente largura, profundidade e resolução de uma rede neural, permitindo aumentar a capacidade dela sem desperdício de recursos, como feito no EfficientNet (Tan; Le, 2019).

Os mecanismos de *Attention* revolucionaram o processamento de dados ao permitir que os modelos priorizem informações mais relevantes durante o aprendizado. Introduzidos em 2017 com a arquitetura Transformers, esses mecanismos possibilitaram avanços significativos no processamento de linguagem natural e, posteriormente, na visão computacional.

Na prática, esses mecanismos fazem as redes CNN focarem em regiões específicas de imagens, o que melhora a identificação de padrões e estruturas importantes em exames médicos, como lesões em tomografias e ressonâncias magnéticas (Vaswani *et al.*, 2023).

Arquiteturas como *Vision Transformer* (ViT) e *Attention Augmented Convolutional Networks* têm combinado a capacidade de análise global dos Transformers com a eficiência de extração local das CNN, resultando em modelos mais robustos e interpretáveis para uso em saúde, segurança e monitoramento de tráfego.

Essas integrações tornam as CNN mais flexíveis, precisas e alinhadas às necessidades de aplicações em ambientes reais, com resultados consistentes e explicáveis (Dosovitskiy *et al.*, 2021).

EU INDICO

O artigo *Attention Mechanism for Image Classification* explica, de forma prática, como mecanismos de Attention podem ser integrados em redes convolucionais para melhorar a classificação de imagens. O texto inclui exemplos visuais, explicações simples e código em PyTorch. Acesse:

A utilização de modelos como o EfficientNet e os mecanismos de *Attention* representa um passo importante para tornar a IA mais acessível e eficaz em diversas áreas, desde a saúde até cidades inteligentes, a fim de democratizar o uso de tecnologias avançadas às instituições que necessitam de eficiência, precisão e economia de recursos computacionais em seus processos de análise de imagens (Tan; Le, 2019; Vaswani *et al.*, 2023).

O FUTURO: TRANSFORMERS NA VISÃO COMPUTACIONAL

Os Transformers estão revolucionando a área de visão computacional, permitindo que sistemas de IA analisem imagens e vídeos com ainda mais precisão. Originalmente criados para entender e gerar textos, os Transformers foram adaptados para lidar com imagens, por meio da identificação automática de quais partes merecem mais atenção durante o processamento. Essa capacidade torna o modelo mais eficiente na hora de encontrar detalhes importantes em imagens complexas, algo essencial em diagnósticos médicos e sistemas de monitoramento (Vaswani *et al.*, 2023).

Um exemplo dessa evolução é o *Vision Transformer* (ViT), que divide uma imagem em pequenos blocos, como se fossem "**palavras**", assim, o sistema entende as relações entre diferentes partes da imagem, globalmente. Isso significa que, em vez de olhar somente para detalhes, o Transformer consegue, ao mesmo tempo, analisar o "todo" da imagem. Essa abordagem já tem sido usada em diagnóstico de câncer, mediante detecção de padrões sutis em exames de ressonância e mamografias, para auxiliar médicos em diagnósticos mais rápidos e precisos (Dosovitskiy *et al.*, 2021).

EU INDICO

O material *Transformers in Medical Image Analysis* oferece uma explicação clara e atual sobre como os Transformers estão sendo utilizados em imagens médicas. O artigo aborda as seguintes aplicações: reconstrução e síntese de imagens, segmentação de órgãos, detecção de anomalias e apoio ao diagnóstico clínico, mostrando como esses mecanismos ajudam a melhorar a precisão e a eficiência em diferentes tarefas médicas. Acesse:

Em segurança e monitoramento, Transformers estão sendo aplicados em câmeras de vigilância para identificar comportamentos suspeitos, como aglomerações incomuns ou movimentos bruscos, acionando alertas em tempo real. Em estádios e aeroportos, esses sistemas reconhecem rostos em multidões, assim, localizam pessoas procuradas ou monitoram fluxos de entrada, de forma ágil e precisa (Carion *et al.*, 2020).

Na indústria automotiva, Transformers estão sendo utilizados em carros autônomos para reconhecer semáforos, placas e pedestres, mesmo em condições de baixa luminosidade. Essa característica é essencial para tornar os veículos mais seguros e inteligentes, pois permite uma leitura mais detalhada do ambiente ao redor e facilita a tomada de decisão em tempo real (Chen; Xie; He, 2021).

Os Transformers estão revolucionando a área de visão computacional, permitindo que sistemas de IA analisem imagens e vídeos com ainda mais precisão

Com o surgimento de variações como o *Swin Transformer*, que analisa imagens em janelas deslizantes de diferentes tamanhos, e o DETR (*Detection Transformer*), o qual detecta objetos em imagens de forma *end-to-end* sem processos manuais complexos, o uso de Transformers na visão computacional promete democratizar o acesso a tecnologias avançadas em hospitais, indústrias, cidades inteligentes e sistemas de segurança, combinando eficiência com precisão (Carion *et al.*, 2020; Liu *et al.*, 2021).

A utilização de Transformers na visão computacional representa o futuro da IA, por oferecer modelos que aprendem de forma robusta, analisar dados em larga escala e ter a possibilidade de aplicação em diversas áreas, tornando a IA cada vez mais útil no cotidiano (Dosovitskiy *et al.*, 2021).

EM FOCO

Confira a aula referente a este tema. **Recursos de mídia disponíveis no conteúdo digital do ambiente virtual de aprendizagem.**

NOVOS DESAFIOS

Ao longo da sua jornada, você estudou algoritmos, lógica, programação e fundamentos de redes neurais. Pode ter parecido, em alguns momentos, que eram apenas códigos e conceitos isolados. Agora, é hora de perceber como cada aprendizado conecta-se ao seu futuro profissional.

As redes convolucionais, por exemplo, são um exemplo prático de como a teoria transforma-se em soluções concretas no mercado de trabalho. Empresas de saúde utilizam esses sistemas para agilizar diagnósticos por imagem, hospitais os usam para detectar sinais de doenças de forma mais precisa, enquanto empresas de segurança empregam a tecnologia para monitorar ambientes e identificar comportamentos suspeitos em tempo real. Essa mesma base teórica, que você aprendeu em aulas de matrizes, álgebra e programação, é aplicada no desenvolvimento de sistemas que impactam diretamente a vida das pessoas.

Na prática, quando você programa um classificador de imagens, está dando o primeiro passo para compreender como grandes empresas criam sistemas de inspeção de qualidade em linhas de produção, por meio da detecção automática de falhas. Quando aprende a treinar e avaliar um modelo, você está desenvolvendo habilidades que serão cobradas em entrevistas técnicas, projetos integradores e desafios práticos em estágios e empregos.

O mercado de trabalho valoriza profissionais que conseguem conectar teoria e prática, transformando conceitos em soluções aplicáveis. Dominar redes convolucionais e entender a evolução delas, como o uso de arquiteturas eficientes (EfficientNet) e mecanismos de *Attention* e Transformers, colocam-lhe à frente em entrevistas, concursos e processos seletivos em empresas de tecnologia, hospitais, *startups* de inovação e centros de pesquisa.

Mais do que programar por programar, o conhecimento que você construiu até agora permite-lhe atuar de **forma crítica e criativa**, por meio da proposta de melhorias em processos, da criação de protótipos de sistemas inteligentes e da resolução de problemas reais com tecnologia. Isso significa estar preparado para um mercado que exige, cada vez mais, profissionais capazes de unir teoria, prática e propósito em soluções que transformam a sociedade.

1. O escalonamento de redes neurais é fundamental para melhorar o desempenho delas em tarefas complexas. A técnica conhecida como *compound scaling* busca otimizar o crescimento das redes neurais (Tan; Le, 2019).

   Sobre essa técnica, assinale a alternativa correta:

   a) Ajusta simultaneamente a largura, a profundidade e a resolução da rede, para melhorar o desempenho.
   b) Foca exclusivamente no aumento da profundidade da rede neural, sem alterar largura ou resolução.
   c) Pode ser aplicada com foco apenas no aumento da resolução das imagens de entrada, sem modificar a arquitetura da rede.
   d) Reduz a largura da rede para economizar recursos, mesmo que isso prejudique o desempenho.
   e) É uma técnica utilizada para diminuir o tamanho do conjunto de dados durante o treinamento das redes.

2. As Redes Neurais Convolucionais (CNN) vêm transformando a medicina, ao oferecer suporte avançado na interpretação de imagens médicas, contribuindo para diagnósticos mais rápidos e precisos em várias doenças (Esteva *et al.*, 2017).

   Analise as afirmativas, a seguir, sobre algumas dessas aplicações:

   I - Em mamografias, as CNN apresentam dificuldades para detectar microcalcificações, sendo menos precisas do que radiologistas experientes.
   II - Em imagens de ressonância magnética (MRI), as CNN conseguem localizar e classificar tumores cerebrais, como gliomas, acelerando o diagnóstico e o início do tratamento.
   III - Sistemas baseados em CNN não são eficazes para identificar sinais de retinopatia diabética em imagens da retina, devido à complexidade da doença.
   IV - Na patologia digital, as CNN ajudam a reconhecer células cancerígenas e diferenciar tipos de tecidos em lâminas histológicas, tornando os exames mais rápidos, além de reduzir erros humanos.

   É correto o que se afirma em:

   a) I, apenas.
   b) II e IV, apenas.
   c) III e IV, apenas.
   d) I, II e III, apenas.
   e) I, II, III e IV.

3. O *Vision Transformer* (ViT) representa uma inovação no processamento de imagens, que tem sido aplicada na área médica para auxiliar na detecção precoce de câncer em exames de ressonância magnética e mamografia (Dosovitskiy *et al.*, 2021).

Com base nas informações apresentadas, avalie as asserções, a seguir, e a relação proposta entre elas:

I - O Vision *Transformer (ViT)* divide a imagem em pequenos blocos, semelhantes a "palavras", o que permite o modelo analisar simultaneamente relações globais entre diferentes regiões da imagem.

PORQUE

II - O *Vision Transformer* já é aplicado em diagnósticos médicos, como na detecção de câncer em exames de ressonância magnética e mamografias, auxiliando na identificação de padrões sutis, para diagnósticos mais rápidos e precisos.

A respeito dessas asserções, assinale a alternativa correta:

a) As asserções I e II são verdadeiras, e a II é uma justificativa correta da I.
b) As asserções I e II são verdadeiras, mas a II não é uma justificativa correta da I.
c) A asserção I é uma proposição verdadeira, e a II é uma proposição falsa.
d) A asserção I é uma proposição falsa, e a II é uma proposição verdadeira.
e) As asserções I e II são falsas.

REFERÊNCIAS

CARION, N. *et al*. **End-to-end object detection with Transformers**. arXiv, preprint arXiv: 2005.12872, v. 3, p. 1-26, 2020. Disponível em: https://arxiv.org/abs/2005.12872. Acesso em: 29 ago. 2025.

CHEN, C. *et al.* DeepDriving: learning affordance for direct perception in autonomous driving. *In:* ICCV – IEEE INTERNATIONAL CONFERENCE ON COMPUTER VISION, 2015, Santiago. **Proceedings** [...]. Santiago: IEEE, 2015.

CHEN, X.; XIE, S.; HE, K. An empirical study of training self-supervised vision Transformers. **arXiv, preprint arXiv: 2104.02057**, v. 4, p. 1-10, 2021. Disponível em: https://arxiv.org/abs/2104.02057. Acesso em: 1 set. 2025.

CIREȘAN, D. C. *et al.* Mitosis detection in breast cancer histology images with deep neural networks. *In:* MICCAI – INTERNATIONAL CONFERENCE ON MEDICAL IMAGE COMPUTING AND COMPUTER-ASSISTED INTERVENTION, 16., 2013, Nagoya. **Proceedings** [...]. Nagoya: Miccai, 2013. p. 411-418. Disponível em: https://doi.org/10.1007/978-3-642-40763-5_51. Acesso em: 29 ago. 2025.

DOSHI-VELEZ, F.; KIM, B. T**owards a rigorous science of interpretable machine learning**. arXiv, preprint arXiv: 1702.08608, v. 1, p. 1-13, 2019. Disponível em: https://arxiv.org/abs/1702.08608. Acesso em: 29 ago. 2025.

DOSOVITSKIY, A. *et al.* An image is worth 16x16 words: Transformers for image recognition at scale. **arXiv, preprint arXiv: 2010.11929**, v. 1, p. 1-22, 2021. Disponível em: https://arxiv.org/abs/2010.11929. Acesso em: 29 ago. 2025.

ESTEVA, A. *et al.* Dermatologist-level classification of skin cancer with deep neural networks. **Nature**, London, v. 542, n. 7639, p. 115-118, 2017. Disponível em: https://doi.org/10.1038/nature21056. Acesso em: 29 ago. 2025.

GULSHAN, V. *et al.* Development and validation of a deep learning algorithm for detection of diabetic retinopathy in retinal fundus photographs. **JAMA**, v. 316, n. 22, p. 2402-2410, 2016. Disponível em: https://doi.org/10.1001/jama.2016.17216. Acesso em: 29 ago. 2025.

HASAN, M. *et al.* Learning temporal regularity in video sequences. *In:* CVPR – CONFERENCE ON COMPUTER VISION AND PATTERN RECOGNITION, 28., 2016, Las Vegas. **Proceedings** [...]. Las Vegas: CVPR, 2016.

KRIZHEVSKY, A.; SUTSKEVER, I.; HINTON, G. E. ImageNet classification with deep convolutional neural networks. *In:* NEURIPS – ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS, 25., Lake Tahoe, 2012. **Proceedings** [...]. Lake Tahoe: NeurIPS, 2012. p. 1097-1105. Disponível em: https://papers.nips.cc/paper/2012/hash/c399862d3b9d6b76c8436e924a68c45b-Abstract.html. Acesso em: 29 ago. 2025.

REFERÊNCIAS

LECUN, Y. *et al.* Gradient-based learning applied to document recognition. **Proceedings of the IEEE**, v. 86, n. 11, p. 2278-2324, 1998.

LI, H. *et al.* A robust CNN-based approach for intrusion detection in surveillance videos under varying conditions. **Sensors**, v. 18, n. 8, 2018.

LITJENS, G. *et al.* A survey on deep learning in medical image analysis. **Medical Image Analysis**, v. 42, p. 60-88, 2017.

LIU, Z. *et al*. Swin Transformer: hierarchical Vision Transformer using shifted Windows. **arXiv, preprint arXiv**: 2103.14030, v. 2, p. 1-14, 2021. Disponível em: https://arxiv.org/abs/2103.14030. Acesso em: 1 set. 2025.

PEREIRA, S. *et al.* Brain tumor segmentation using convolutional neural networks in MRI images. **IEEE Transactions on Medical Imaging**, v. 35, n. 5, p. 1240-1251, 2016. Disponível em: https://doi.org/10.1109/TMI.2016.2538465. Acesso em: 29 ago. 2025.

SIMONYAN, K.; ZISSERMAN, A. Very deep convolutional networks for large-scale image recognition. **arXiv, preprint arXiv:1409.1556**, v. 6, p. 1-14, 2015. Disponível em: https://arxiv.org/pdf/1409.1556. Acesso em: 29 ago. 2025.

TAN, M.; LE, Q. V. **EfficientNet**: Rethinking model scaling for convolutional neural networks. arXiv, preprint arXiv:1905.11946, v. 1, p. 1-11, 2019. Disponível em: https://arxiv.org/abs/1905.11946. Acesso em: 29 ago. 2025.

VASWANI, A. *et al.* **Attention is all you need**. arXiv, preprint arXiv:1706.0372, v. 7, p. 1-15, 2023. Disponível em: https://arxiv.org/abs/1706.03762. Acesso em: 29 ago. 2025.

ZHAO, W. *et al.* Face recognition: a literature survey. **ACM Computing Surveys**, v. 35, n. 4, p. 399-458, 2003.

CONFIRA SUAS RESPOSTAS

1. Alternativa C.

   Em certas abordagens, a *compound scaling* pode priorizar o aumento da resolução das imagens de entrada, mantendo a arquitetura da rede fixa para otimizar o desempenho.
   A alternativa A está incorreta, pois embora o escalonamento composto clássico envolva largura, profundidade e resolução, em algumas aplicações, ele pode ser aplicado com foco apenas na resolução, sem alterar a arquitetura da rede.
   A alternativa B está incorreta, pois o método não se limita a aumentar apenas a profundidade, ele pode atuar em outros aspectos.
   A alternativa D está incorreta, pois a *compound scaling* não reduz a largura para economizar recursos, e sim busca equilíbrio para aumentar a eficiência.
   A alternativa E está incorreta, pois a técnica não está relacionada ao tamanho do conjunto de dados, mas ao ajuste da arquitetura e/ou resolução da entrada.

2. Alternativa B.

   A afirmativa I está incorreta, pois pesquisas mostram que as CNN conseguem detectar microcalcificações em mamografias com precisão comparável ou até superior a especialistas humanos, auxiliando no diagnóstico precoce.
   A afirmativa II está correta, pois as CNN analisam imagens de ressonância magnética para localizar e classificar tumores cerebrais, como gliomas, acelerando o diagnóstico e possibilitando tratamentos mais rápidos.
   A afirmativa III está incorreta, pois sistemas baseados em CNN foram treinados com alta acurácia para identificar sinais de retinopatia diabética em imagens da retina, permitindo triagens em larga escala.
   A afirmativa IV está correta, pois, na patologia digital, as CNN auxiliam no reconhecimento de células cancerígenas e na diferenciação de tecidos em lâminas histológicas, tornando os exames mais rápidos e reduzindo erros humanos.

3. Alternativa B.

   A asserção I é verdadeira ao descrever como o Vision Transformer (ViT) processa imagens, dividindo-as em blocos e analisando as relações globais entre eles.
   A asserção II também é verdadeira, pois o ViT tem sido aplicado, com sucesso, no diagnóstico médico para detectar padrões sutis em exames de ressonâncias e mamografias. A segunda asserção, contudo, não justifica a primeira, já que o uso do ViT em diagnósticos explica que o seu funcionamento técnico de dividir a imagem em blocos e analisar globalmente não são fatos relacionados, mas independentes em termos de justificativa.

MEU ESPAÇO

MEU ESPAÇO

MEU ESPAÇO

MEU ESPAÇO